Açıklanabilir Makine Öğrenmesi

Christoph Molnar — Bölüm 25 & 26 (Türkçe Çeviri)

Bölüm 25: Vekil Modeller (Surrogate Models)

Küresel bir vekil model (global surrogate model), karakutu (black box) bir modelin tahminlerine yaklaşmak üzere eğitilmiş, kendi içinde açıklanabilir bir modeldir. Vekil modeli yorumlayarak karakutu model hakkında sonuçlar çıkarabiliriz. Daha fazla makine öğrenmesi kullanarak makine öğrenmesi açıklanabilirliğini çözmek!

Matematiksel olarak şu şekilde ifade edebiliriz: Karakutu tahmin fonksiyonunu **f(x)** ve vekil modeli **g(x)** olarak adlandıralım. Eğitilen **g** modelinin kısıtı, açıklanabilir bir model türü olmasıdır (örneğin lineer model veya karar ağacı).

> Lineer Model: $g(x) = \beta_0 + \beta_1 x_1 + ... + \beta_p x_p$
>
> Karar Ağacı: $g(x) = \sum_{m=1}^{M} c_m \, I\{x \in R_m\}$

Vekil model eğitimi modelden bağımsız (model-agnostic) bir yöntemdir; çünkü karakutu modelin iç çalışma mekanizması hakkında herhangi bir bilgi gerektirmez, yalnızca verilere ve tahmin fonksiyonuna erişim yeterlidir.

VEKİL MODEL ELDE ETME ADIMLARI

Bir vekil model eğitmek için aşağıdaki adımlar izlenir:

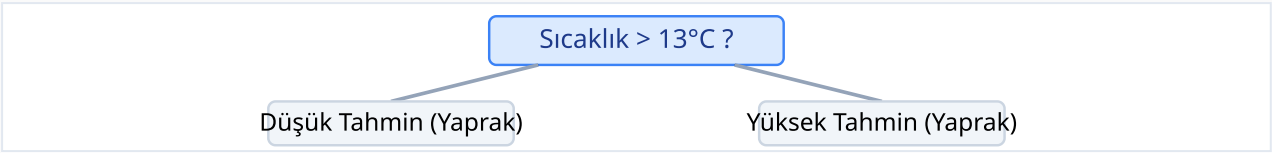
1. **Veri Kümesi Seçimi:** Bu, karakutu modeli eğitmek için kullanılan veri kümesinin aynısı veya aynı dağılımdan yeni bir veri kümesi olabilir. Uygulamanıza bağlı olarak verilerin bir alt kümesini veya bir nokta ızgarasını (grid) dahi seçebilirsiniz.
2. **Tahminleri Alma:** Seçilen veri kümesi için karakutu modelin tahminlerini ($\hat{y}$) elde edin.
3. **Açıklanabilir Model Seçimi:** Açıklanabilir bir model türü seçin (lineer model, karar ağacı vb.).
4. **Modeli Eğitme:** Açıklanabilir modeli, seçilen veri kümesi ve karakutu modelin tahminleri (hedef değişken olarak) üzerinde eğitin.
5. **Değerlendirme:** Vekil modelin karakutu modelin tahminlerini ne kadar iyi kopyaladığını (yaklaştığını) ölçün (örneğin R-kare metriği ile).
6. **Yorumlama:** Vekil modeli yorumlayın.

> 📌 **Önemli Kavram: Sadakat (Fidelity)**
>
> Vekil modelin hedefi gerçek dünya etiketlerini (y) tahmin etmek değil, karakutu modelin çıktılarını ($\hat{y}$) birebir taklit etmektir. Vekil modelin başarısı, karakutuya ne kadar sadık kaldığı ile ölçülür.

Vekil Modeller: Örnekler, Güçlü ve Zayıf Yönler

Örnek 1 (Regresyon): Bisiklet kiralama veri kümesinde günlük kiralanan bisiklet sayısını tahmin etmek için bir Destek Vektör Makinesi (SVM) eğitilmiştir. SVM doğrudan yorumlanamadığı için, SVM'nin davranışına yaklaşmak adına bir CART karar ağacı vekil model olarak eğitilmiştir. Vekil ağaç, test verilerinde 0.76 R-kare (açıklanan varyans) değerine ulaşmıştır; bu da karakutu davranışına oldukça iyi yaklaştığını gösterir.

ŞEKİL 25.1: SVM TAHMİNLERİNE YAKLAŞAN VEKİL KARAR AĞACI YAPISI



Örnek 2 (Sınıflandırma): Penguenlerin cinsiyetini (dişi/erkek) Rastgele Orman (Random Forest) ile sınıflandırdığımız ikinci bir örnekte, karar ağacı vekil modeli R-kare = 0.71 değerine ulaşmıştır.

💪 Güçlü Yönleri (Strengths)

- **Esneklik:** Herhangi bir açıklanabilir model türü ve her türlü karakutu model ile kullanılabilir.
- **Sezgisel ve Kolay:** Mantığı son derece basittir, teknik olmayan kişilere anlatması ve uygulaması kolaydır.
- **Sadakat Ölçümü:** R-kare gibi standart metriklerle vekilin karakutuyu ne kadar başardığı kolayca ölçülebilir.
- **İletişim Esnekliği:** Farklı paydaşlara (ör. lineer model sevenler vs. ağaç sevenler) aynı karakutu için farklı vekiller sunulabilir.

⚠️ Zayıf Yönleri (Limitations)

- **İllüzyon Riski:** Vekil model karakutunun ne yaptığını açıklar, *gerçek dünyanın nasıl çalıştığını değil*.
- **Mükemmel Olmayan Uyum:** R-kare %100 değilse, vekil model karakutunun bazı karmaşık kararlarını kaçırıyor demektir.
- **Kesim Noktası İkilemi:** Vekil model karakutuyu çok iyi açıklıyorsa ($R^2 \approx 1$), karakutuyu çöpe atıp doğrudan vekil modeli kullanmamak için bir sebep kalmaz.

Bölüm 26: Prototipler ve Eleştiriler (Prototypes and Criticisms)

Bir **prototip**, tüm verileri temsil eden/simgelleyen tipik bir veri örneğidir. Bir **eleştiri (criticism)** ise prototipler kümesi tarafından iyi temsil edilemeyen, sıra dışı veya aykırı bir veri örneğidir. Prototipler ve eleştiriler her zaman verinin kendisinden seçilen gerçek örneklerdir (instances).

Veri dağılımlarını anlamak veya karmaşık karakutu modellerin kararlarını veri örnekleri üzerinden açıklamak için prototip ve eleştiri çiftleri kullanılır.

MMD-CRİTİC YÖNTEMİ

Kim et al. (2016) tarafından önerilen **MMD-critic** algoritması, Maksimum Minimum Sapma (Maximum Mean Discrepancy - MMD) ölçütünü kullanarak veriden prototip ve eleştirileri otomatik olarak seçer.

> $MMD^2(F, X, P) = E[k(x, x')] - 2\ E[k(x, z)] + E[k(z, z')]$

Burada **X** tüm veri kümesini, **P** ise seçilen prototipler kümesini temsil eder. **k** bir çekirdek (kernel) fonksiyonudur (örneğin RBF çekirdeği). MMD ölçütü, prototiplerin dağılımı ile verinin gerçek dağılımı arasındaki farkı hesaplar.

> 💡 **MMD-critic Adım Adım İşleyişi**
>
> 1. **Açgözlü Arama (Greedy Search) ile Prototip Seçimi:** MMD^2 değerini en çok düşüren veri noktası adım adım prototip listesine eklenir. Yoğun bölgelerdeki tipik noktalar prototip olur.
> 2. **Eleştiri (Criticism) Seçimi:** Prototipler seçildikten sonra, prototip dağılımı ile gerçek veri yoğunluğu arasındaki farkın (yoğunluk oranının) en yüksek olduğu alanlardaki noktalar eleştiri olarak seçilir.

AÇIKLAMA OLARAK PROTOTİPLER VE ELEŞTİRİLER

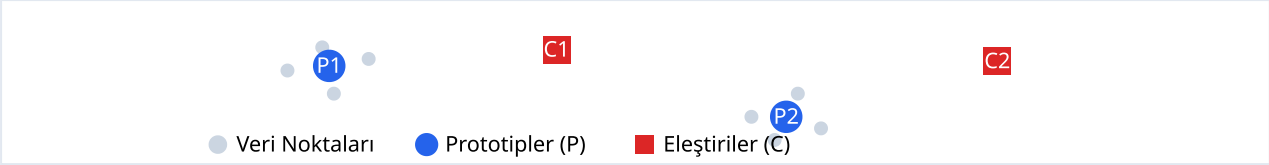
Bu yöntem üç temel senaryoda açıklama sunmak amacıyla kullanılabilir:

- **Karmaşık Veri Dağılımlarını Anlamak:** Yüksek boyutlu veri kümelerinin yapısını birkaç temsilci resim/örnek ile özetlemek.
- **Örnek Tabanlı Model Oluşturmak:** En Yakın Komşu (k-NN) gibi modellerde sadece prototipleri tutarak hızlı ve açıklanabilir tahminler yapmak.
- **Karakutu Modeli İncelemek:** Seçilen prototip ve eleştiriler üzerinde karakutunun nasıl tahminler yaptığını ve nerede hata yaptığını analiz etmek.

Prototipler ve Eleştiriler: Görselleştirme ve Örnek Uygulama

El yazısı rakamlar (MNIST benzeri) veri kümesinde MMD-critic uygulandığında, prototipler her rakam sınıfının standart yazım tarzlarını gösterirken; eleştiriler ise alışılmadık eğimle yazılmış, kalınlaştırılmış veya diğer rakamlarla karıştırılmaya müsait sıra dışı yazımları ortaya koyar.

ŞEKİL 26.1: 2D ÖZELLİK UZAYINDA PROTOTİP VE ELEŞTİRİ DAĞILIMI KURGUSU



✨ Avantajları (Strengths)

- **İnsan Odaklı Açıklama:** İnsanlar örnekler ve prototipler üzerinden düşünmeye yatkındır. Bu yöntem insan bilişsel yapısına son derece uygundur.
- **Tam Resim Sunumu:** Sadece ortalama/tipik durumları (prototip) değil, istisnaları ve sınır vakaları da (eleştiri) sunarak yanılsamayı önler.
- **Modelden Bağımsız (Model-Agnostic):** Yoğunluk tahminine dayandığı için her türlü veri tipi ve makine öğrenmesi modeli ile çalışır.
- **Deneylerle Kanıtlanmış:** Kullanıcı çalışmalarında prototip+eleştiri kombinasyonunun zihinsel modelleri geliştirdiği kanıtlanmıştır.

⚠️ Sınırlılıkları (Limitations)

- **Parametre Seçimi Zorluğu:** Kaç adet prototip ve kaç adet eleştiri seçileceğine karar vermek zordur (hiperparametre bağımlılığı).
- **Hesaplama Maliyeti:** MMD^2 matris hesaplamaları ve açgözlü arama büyük veri kümelerinde yavaş çalışabilir.
- **Özellik Ağırlıklandırması:** Çekirdek (kernel) fonksiyonunun tüm özellikleri eşit ağırlıkta değerlendirmesi her zaman uygun olmayabilir.

Bölüm 25 ve 26 Karşılaştırmalı Özet ve Sonuç

Her iki bölüm de karakutu makine öğrenmesi modellerini açıklamak ve küresel (global) düzeyde içgörü elde etmek için güçlü yöntemler sunmaktadır. Aşağıdaki tabloda vekil modeller ile prototip/eleştiri yöntemlerinin temel farkları özetlenmiştir.

Özellik	Bölüm 25: Vekil Modeller	Bölüm 26: Prototipler ve Eleştiriler
Yaklaşım Türü	Model Değişimi (Model Approximation)	Örnek Tabanlı Açıklama (Instance-based)
Çıktı Biçimi	Açıklanabilir Model (Karar Ağacı, Lineer Model)	Gerçek Veri Noktaları (Resimler, Satırlar)
Odak Noktası	Karakutunun genel karar kuralları ve ilişkileri	Verinin ve modelin tipik ve aykırı durumları
Doğrulama Metriği	R-kare (R^2) / Uyum Sadakati (Fidelity)	MMD^2 (Maksimum Minimum Sapma)

🎓 **Genel Değerlendirme**

Christoph Molnar'ın *Interpretable Machine Learning* kitabında vurgulandığı üzere; karmaşık bir yapay zeka sistemini açıklarken tek bir yöntem yeterli olmayabilir. Vekil modeller genel kural ve mantığı kavramada üstünlük sağlarken, Prototip ve Eleştiriler veri dağılımındaki uç noktaları ve modelin hata yapabileceği alanları somut örneklerle göstermede eşsizdir.