AÇIKLANABİLİR YAPAY ZEKA · 2026 GÜZ

Cam kutu modeller

Doğrusal regresyon, lojistik regresyon, GLM ve GAM: nasıl yorumlanır, nerede kırılır?

Ahmet Batuhan Kaya
20269348005

Molnar, *Interpretable Machine Learning*
Bölüm 6 · 7 · 8

YOL HARİTASI

Bugün neler var?

01	**Giriş**	Neden önce cam kutular? Üç bölüm tek bir aile.
02	**Bölüm 6 · Doğrusal regresyon**	Katsayı yorumu, güven aralığı, varsayımlar, çoklu bağlantı
03	**Bölüm 7 · Lojistik regresyon**	Odds ve odds oranı, penguenler, kredi verisi, tam ayrışma
04	**Bölüm 8 · GLM ve GAM**	Üç sorun: GLM, etkileşim, GAM · sigorta verisi · **üç bölümün canlı kodu**
05	**Makale yeniden üretimi**	Caruana ve ark. (2015): yorumlanabilir model kara kutu kadar iyi mi? · **canlı kod**

GİRİŞ

Cam kutunun tahmini bir fiş gibi okunur

TAHMİN FİŞİ · EV FİYATI

Başlangıç (sabit terim)	20
Alan: 100 m² × 1,5	+150
Oda: 4 × (−3)	−12
Tahmin	**158 bin $**

Bu bölümlerde

Fiş modelin kendisi. Her kalemi okuyabiliriz.

Dersin geri kalanında

LIME ve SHAP, kara kutular için fişi sonradan üretmeye çalışır. LIME yerel bir doğrusal model kurar; SHAP doğrusal modelde tek satırlık bir formüle iner.

Rudin (2019)

Yüksek riskli kararlarda kara kutuyu sonradan açıklamak yerine baştan yorumlanabilir model kullanılmalı.

GİRİŞ

Üç bölüm, tek motor: ağırlıklı toplam

$$\eta = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \ldots + \beta_p x_p$$

Model	Hedef (y)	η nasıl bağlanır?	x +1 olunca	Verimiz
Doğrusal regresyon	Sürekli sayı	Doğrudan: $y = \eta$	y +β	Ev fiyatı
Lojistik regresyon	Evet / hayır	Sigmoid: $p = 1/(1+e^{-\eta})$	odds × e^{β}	Kredi
Poisson GLM	Sayım	Üstel: $\mu = e^{\eta}$	μ × e^{β}	Sigorta hasarı
GAM	Herhangi biri	βx yerine f(x) eğrisi	Grafikten okunur	Sürücü yaşı

Her bölüm, bir öncekinin kırıldığı yerde başlar.

06

Doğrusal regresyon

Ağırlıklı toplam ne söyler, ne zaman yanıltır?

Veri: bisiklet kiralama (kitabın örneği) · Ames Housing, 2.930 ev

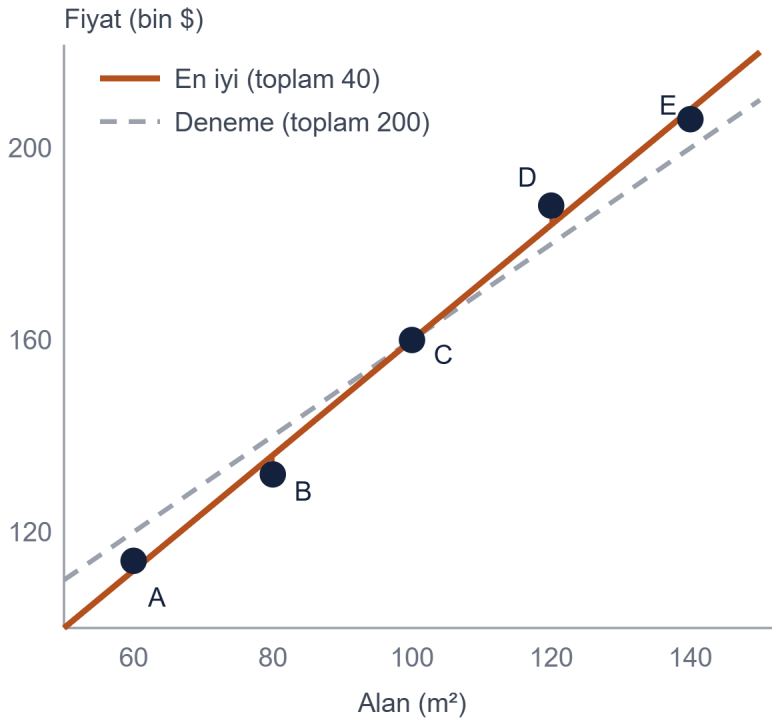
BÖLÜM 6 · DOĞRUSAL REGRESYON · 5 EVLİK ÖRNEK

En iyi çizgi, hata karelerini en küçük yapandır

Deneme = 60 + 1 · alan · **En iyi** = 40 + 1,2 · alan

Fiyat bin $ · hata = gerçek fiyat − tahmin

Ev	Alan	Fiyat	Deneme	(hata)²	En iyi	(hata)²
A	60	114	120	(−6)² = 36	112	2² = 4
B	80	132	140	(−8)² = 64	136	(−4)² = 16
C	100	160	160	0² = 0	160	0² = 0
D	120	188	180	8² = 64	184	4² = 16
E	140	206	200	6² = 36	208	(−2)² = 4
Toplam				200		40



$$\min \Sigma \text{ (gerçek} - \text{tahmin)}^2$$

Bu beş ev için toplamı 40'tan küçük yapan çizgi yok. Eğim 1,2: her m² fiyatı 1.200 $ artırır.

Katsayı: diğer her şey sabitken bir birimlik etki

Sayısal öznitelik

fiyat = 20 + 1,5 · alan − 3 · oda

Ev	Alan	Oda	Tahmin
X	100 m²	3	161
Y	100 m²	4	158
Z	120 m²	4	188

X ile Y: alan aynı, bir oda fazla → **−3**. Aynı alan daha küçük odalara bölünmüş.

Kategorik öznitelik

Bisiklet modeli, referans: iyi hava

Hava	Katsayı
İyi (referans)	0
Sisli	−531
Kötü	−2.204

Kötü havalı gün, **iyi havaya göre** 2.204 daha az kiralama. Sıcaklık: +1 °C → +55.

BÖLÜM 6 · NE KADAR EMİNİZ?

Katsayı bir tahmindir: yanında belirsizliği gelir

KİTABIN BİSİKLET MODELİ · PYTHON

Öznitelik	β	SE	|t|	%95 güven aralığı
Sıcaklık (+1 °C)	54,8	10,2	5,4	35 … 75
Kötü hava	−2.204	311	7,1	−2.815 … −1.592
Yaz (kışa göre)	108	219	0,5	−323 … 539

Aralık 0'ı içeriyorsa: fark olduğunu gösteremiyoruz

Kitabın yorumu: yaz ile kış arasında anlamlı bir fark yok. Sıcaklık zaten modelde; yaz katsayısı yazın **ek** etkisi.

SE: standart hata

Katsayı veriyle ne kadar oynar?

$t = \beta / SE$

Önem ölçüsü: 54,8 / 10,2 ≈ 5,4

$\%95\ GA \approx \beta \pm 2 \cdot SE$

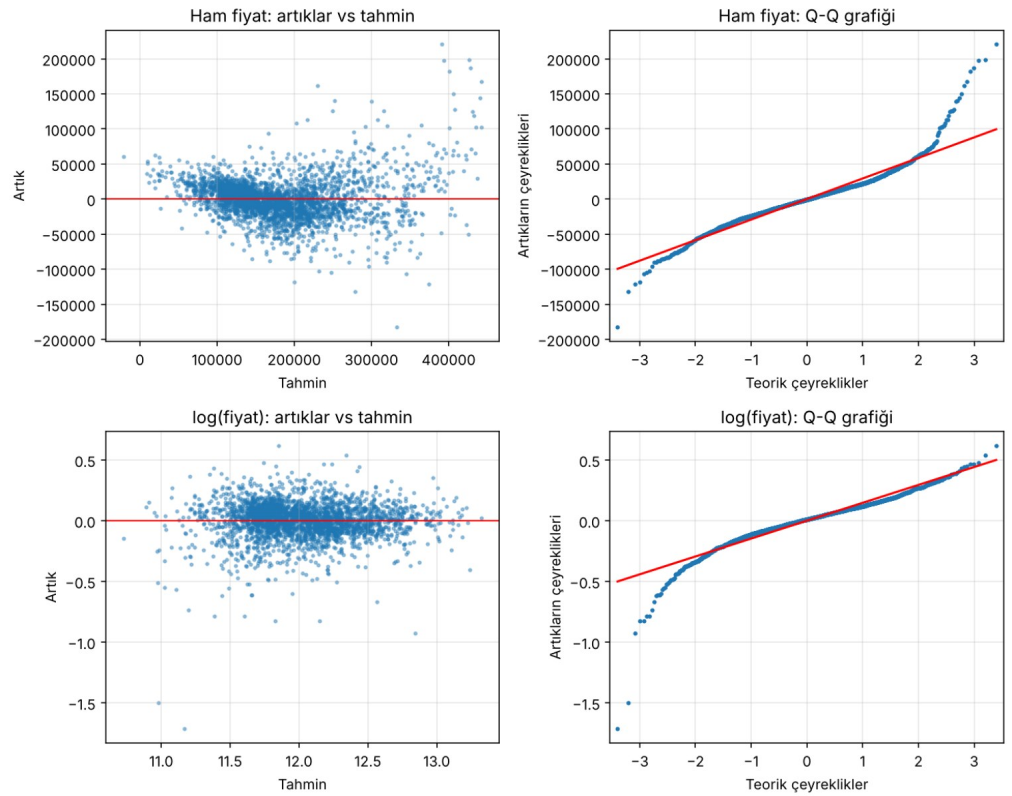
100 tekrarın ~95'inde gerçek değeri içerir.

$R^2 = 1 - SSE / SST$

Açıklanan fark payı (0 ile 1 arası)

BÖLÜM 6 · VARSAYIMLAR · KİTABIN EV ÖRNEĞİ, AMES VERİSİNDE

Varsayım bozulunca güven aralığı yanıltır



KİTABIN ÖRNEĞİ · EŞ VARYANSLILIK

Ortalama hata 50.000 €. Bu hata 1 milyon €'luk evde de, 40.000 €'luk evde de aynı mı? O zaman **negatif fiyat** beklemek gerekirdi.

AMES'TE: HAM FİYAT

Hata pahalı evlerde büyüyor (huni) · **1 eve negatif fiyat** · Breusch-Pagan **446**

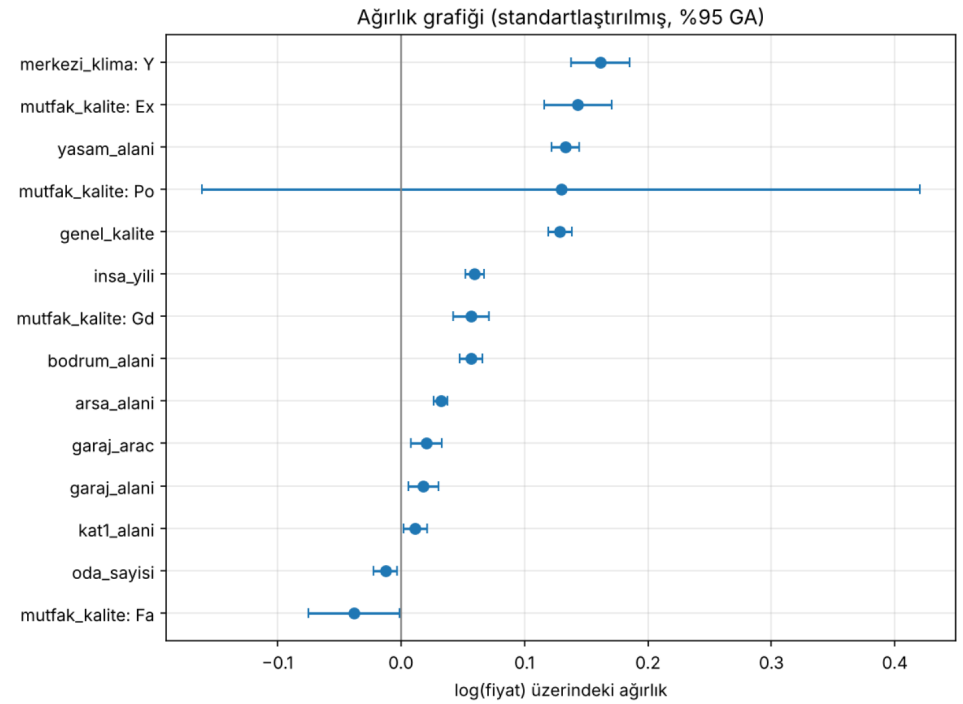
ÇÖZÜM: LOG(FİYAT)

Huni kapanıyor (BP **131**). Yorum çarpımsal: kalite +1 → fiyat × exp(0,092) ≈ **%9,6** artış

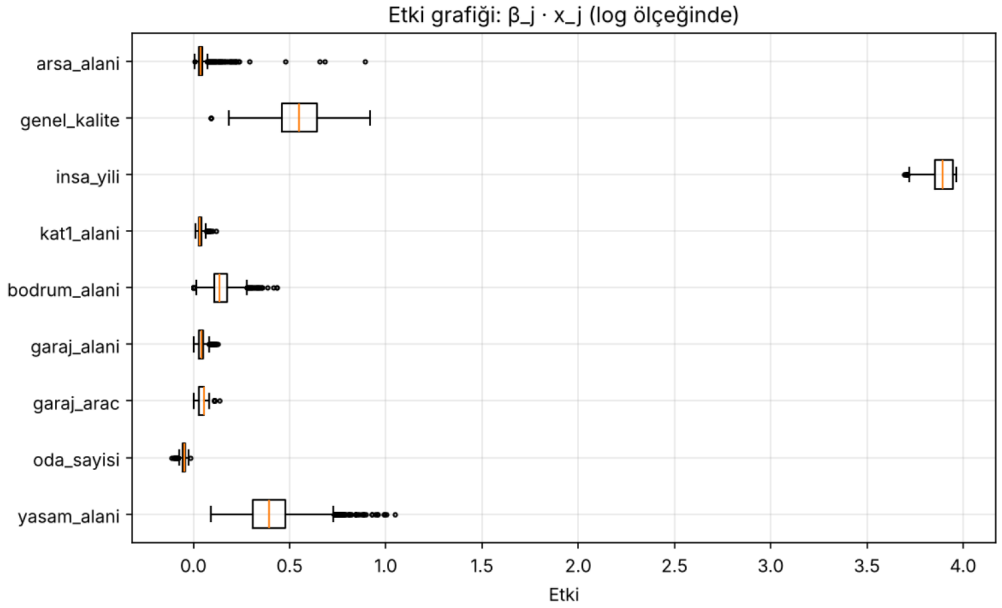
Kitabın 6 varsayımı: doğrusallık · normallik · eş varyanslılık · bağımsızlık · sabit öznitelikler · çoklu bağlantı yokluğu

BÖLÜM 6 · AĞIRLIK VE ETKİ GRAFİĞİ

Ağırlık mı, etki mi? Ölçek her şeyi değiştirir



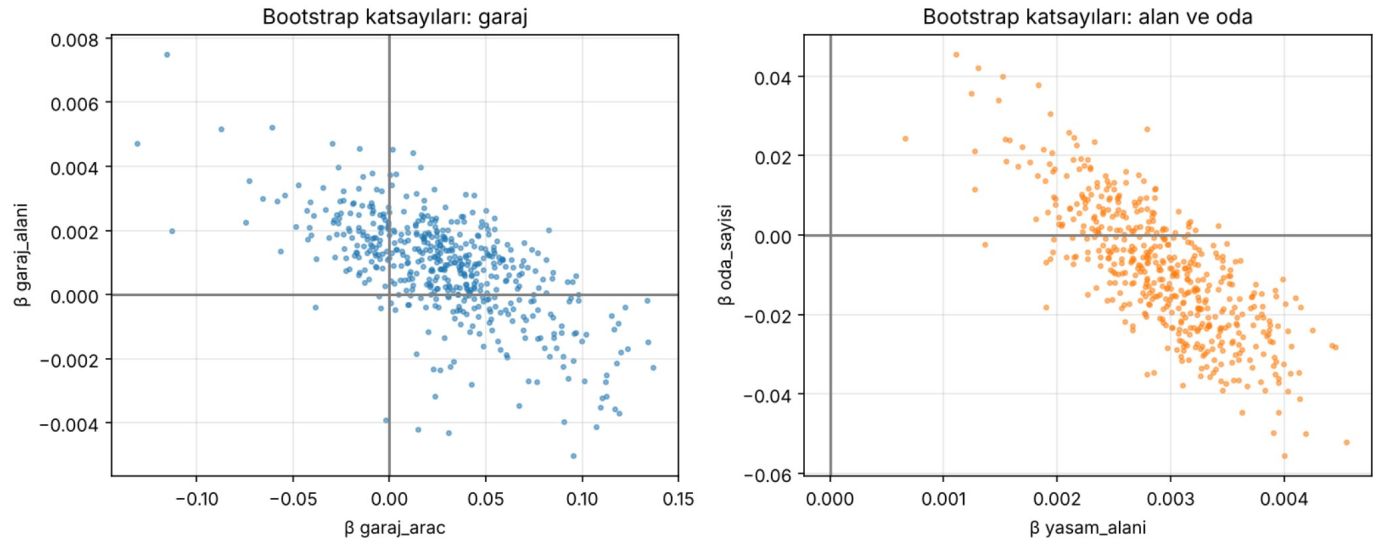
Ağırlık grafiği: kitabın uyarısı: birim değişince ağırlık değişir (kg → g: β / 1000). Bu yüzden standartlaştırdık. "Mutfak: Po" tek evden: aralığı devasa.



Etki grafiği: etki = β · x, yani gerçek katkı. İnşa yılı en büyük görünüyor ama kutusu dar: karşılaştırma noktası "0. yıl".

BÖLÜM 6 · KIRILMA · ÇOKLU BAĞLANTI

Veri biraz değişince katsayının işareti dönüyor



%72

oda sayısı katsayısı negatif: **kitabın örneği**

%24

garaj katsayıları negatif

0,89

garaj araç ~ garaj alanı korelasyonu

> Kitap: büyüklük ve oda sayısı birlikte modeldeyse, aynı büyüklükte oda eklemek evi küçük odalara bölmek demektir; oda sayısı negatif ağırlık alabilir.

Tahmin sağlam, yorum çöker. *500 bootstrap, her biri 150 ev*

07

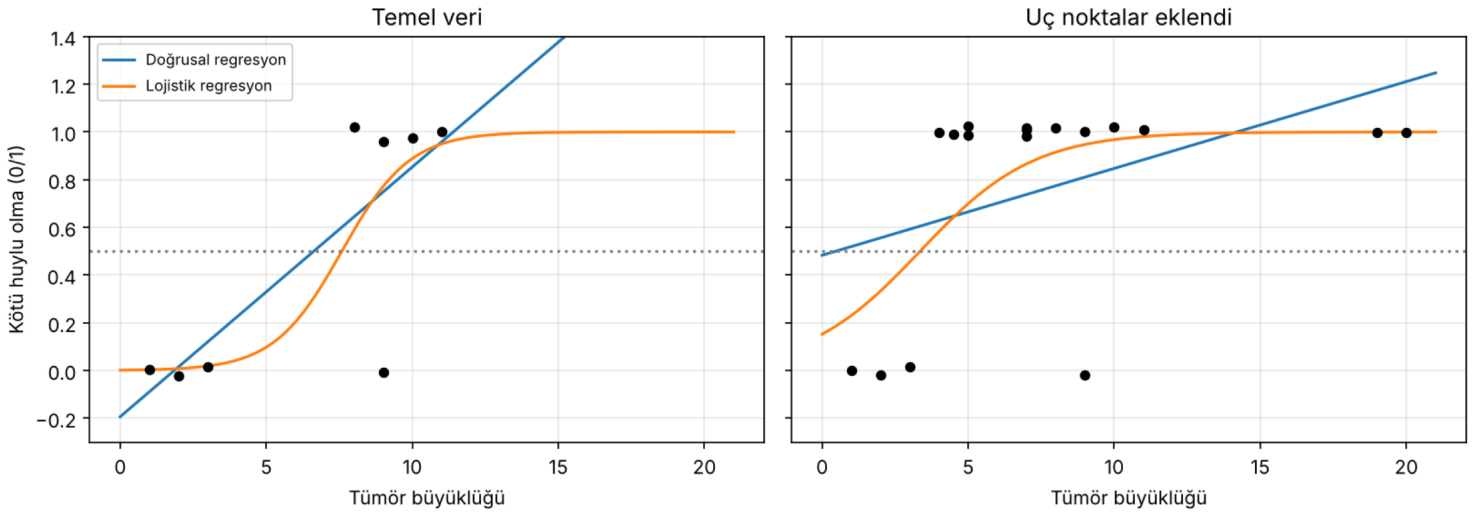
Lojistik regresyon

Hedef evet/hayır olunca: olasılık, odds ve odds oranı

Veri: Palmer penguenleri (kitabın örneği) · German Credit, 1.000 kredi başvurusu

BÖLÜM 7 · LOJİSTİK REGRESYON

Düz çizgi olasılık değildir: sigmoid ile 0–1'e sıkıştır



KİTAP: DOĞRUSAL MODEL NEDEN OLMAZ?

① Çıktı olasılık değil · ② 0'ın altına, 1'in üstüne taşar
③ İki nokta eklenince 0,5 eşiği kayar · ④ Çok sınıfa genişlemez

ÇÖZÜM: LOJİSTİK FONKSİYON

$$P(Y=1) = 1 / (1 + e^{-(\beta_0 + \beta_1 x_1 + \ldots)})$$

BÖLÜM 7 · YORUMLAMA

Model log-odds'ta doğrusal, etki çarpımsal

$$\ln(\, p \,/\, (1 - p)\,) = \beta_0 + \beta_1 x_1 + \ldots \Rightarrow x\ {+}1 : \text{odds} \times e^{\beta}$$

Odds = olur / olmaz

Olasılık p	Odds
0,20	0,25
0,50	1
0,80	4

e^{β} = **odds oranı**. 1'den büyükse risk artar, küçükse azalır.

Aynı odds oranı (2), farklı etki

Önce	Sonra	Fark
%5	%9,5	+4,5 puan
%50	%66,7	+16,7 puan
%90	%94,7	+4,7 puan

Olasılıktaki etki başlangıç riskine bağlı.

Kitabın örneği: odds = 2 iken β = 0,7 → x +1 → odds × exp(0,7) ≈ × 2 → odds = 4

BÖLÜM 7 · KİTABIN BULGUSUNU YENİDEN ÜRETMEK

Kitabın tablosu Python'da birebir çıktı

Chinstrap penguenleri · hedef: P(dişi)

Öznitelik	Kitap (R)	Python
Gaga uzunluğu	0,59	0,59
Gaga derinliği	0,13	0,13
Yüzgeç uzunluğu	0,85	0,85
Normal tombul	1,92	1,92
En tombul	0,43	0,43

Odds oranları · referans: ufak penguen

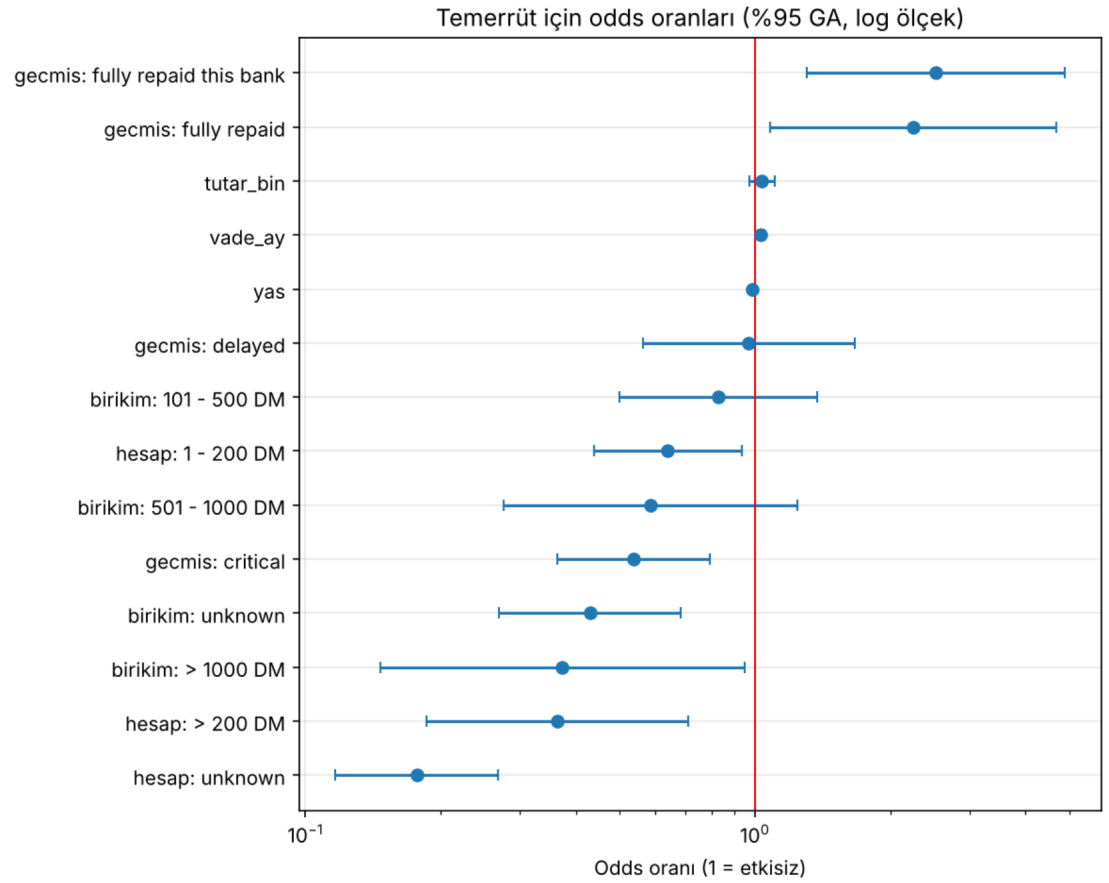
KİTAPTA BİR YÖN HATASI

*Gaga: "odds'u 0,59 çarpanı kadar **artırır**"*
*En tombul: "odds'u 0,43 çarpanı kadar **azaltır**"*

Çarpan doğru, fiil yanlış: 0,59 < 1 olduğu için odds **azalır**. Her mm'de yaklaşık %41 düşüş.

BÖLÜM 7 · GERMAN CREDIT

Cam kutu, verideki tuhaflığı görünür kılar



Vade +12 ay

odds × $1{,}031^{12}$ = **× 1,45**

Bakiye bilinmiyor

eksi bakiyeye göre **× 0,18**

Sezgiye aykırı

Kritik kredi geçmişi **× 0,54** (riski azaltıyor)
Tamamen ödemiş **× 2,25** (riski artırıyor)

Olası nedenler: seçilim yanlılığı ya da veri setindeki bilinen kodlama hataları (Grömping, 2019).

Test AUC ≈ 0,79

BÖLÜM 7 · KİTABIN UYARISI · TAM AYRIŞMA

Kusursuz ayıran değişkenin katsayısı sonsuza kaçar

Deney: veriye bir **"kara liste"** değişkeni ekledim. Kara listedeki herkes temerrüde düşmüş.

Kara liste	Ödedi	Temerrüt
Hayır	700	235
Evet	0	65

26,6 katsayı (β)

42.213 standart hata

Kitabın çözümü: ağırlıklara ceza ya da önsel dağılım.



Ceza azaldıkça katsayı durmadan büyüyor

08

GLM, GAM ve ötesi

Doğrusal modelin üç sorunu: Gauss dışı hedef, etkileşim, doğrusal olmayan ilişki

Veri: kahve simülasyonu ve bisiklet (kitabın örnekleri) · freMTPL2, 678.000 sigorta poliçesi

BÖLÜM 8 · GİRİŞ

Basit bıçaktan İsviçre çakısına: üç sorun, üç çözüm

SORUN 1 · GAUSS DIŞI HEDEF

"Bugün kaç dakika bisiklet süreceğim?"

Doğrusal model negatif dakika tahmin edebilir. Olasılıkta 0'ın altı ya da 1'in üstü çıkabilir.

Çözüm: GLM

SORUN 2 · ETKİLEŞİM

"Hafif yağmur isteğimi azaltır... ama yaz akşamı iş çıkışında yollar bana kalır."

Yağmurun etkisi saate ve mevsime bağlı. Toplamsal model bunu yakalayamaz.

Çözüm: etkileşim terimi

SORUN 3 · DOĞRUSAL OLMAYAN

"0–25 °C arası her derece isteğimi artırır; çok sıcakta binmem."

Tek bir eğim, 10 → 11 °C ile 30 → 31 °C'yi aynı sayar.

Çözüm: dönüşüm ya da GAM

> Kitabın ipucu: ihlali deneyerek kontrol edin. Etkileşim ya da eğri eklemek doğrulama verisinde performansı artırıyor mu?

BÖLÜM 8 · SORUN 1 · GAUSS DIŞI HEDEF

GLM'in üç parçası

1 · DAĞILIM

Üstel aileden: Normal, Bernoulli, Poisson...

+

2 · DOĞRUSAL YORDAYICI

$\eta = \beta_0 + \beta_1 x_1 + \ldots$ (aynı motor)

+

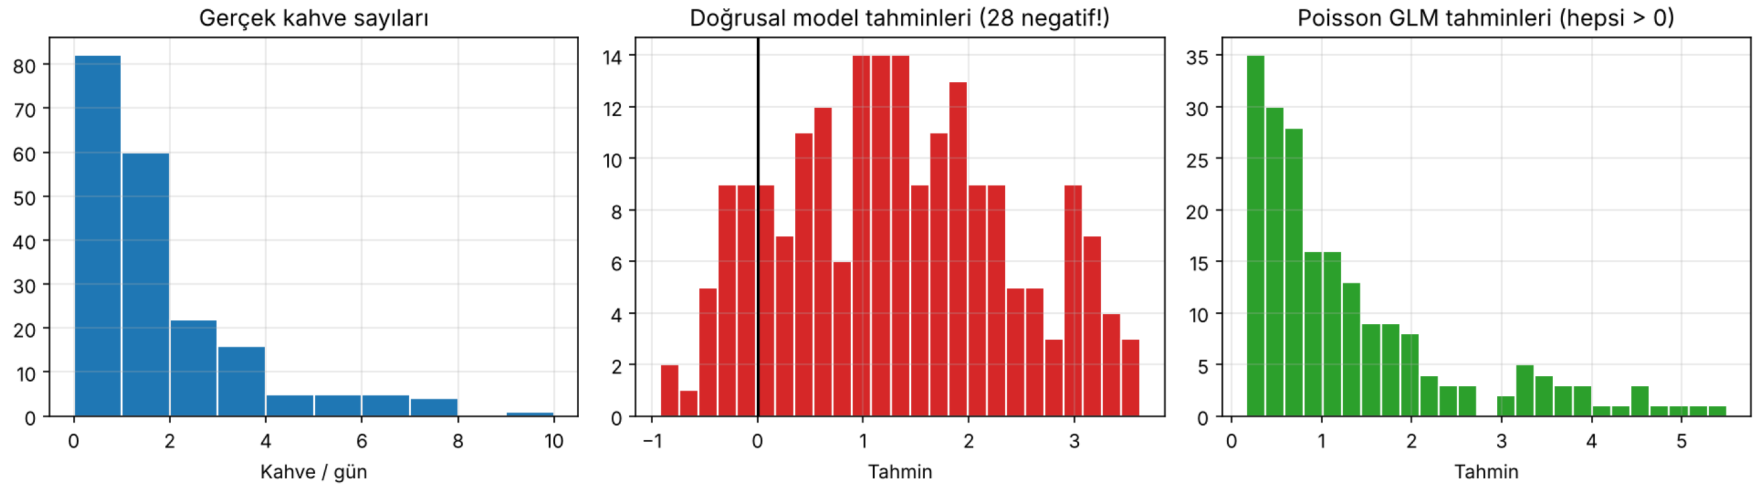
3 · BAĞLANTI g

$g(\,E[y]\,) = \eta$

Bölüm	Dağılım	Bağlantı	Tahmin
6 · Doğrusal	Normal	birim	$E[y] = \eta$
7 · Lojistik	Bernoulli	logit	$p = 1/(1+e^{-\eta})$
8 · Poisson	Poisson	log	$\mu = e^{\eta} > 0$

BÖLÜM 8 · KİTABIN KAHVE ÖRNEĞİ

Sayım verisinde doğrusal model negatif tahmin üretir



YORUM: ÇARPIMSAL

ln E[kahve] = β_0 + β·stres + …
Stres +1 → kahve × exp(0,13) ≈ **× 1,14**

GERÇEK → POISSON GLM

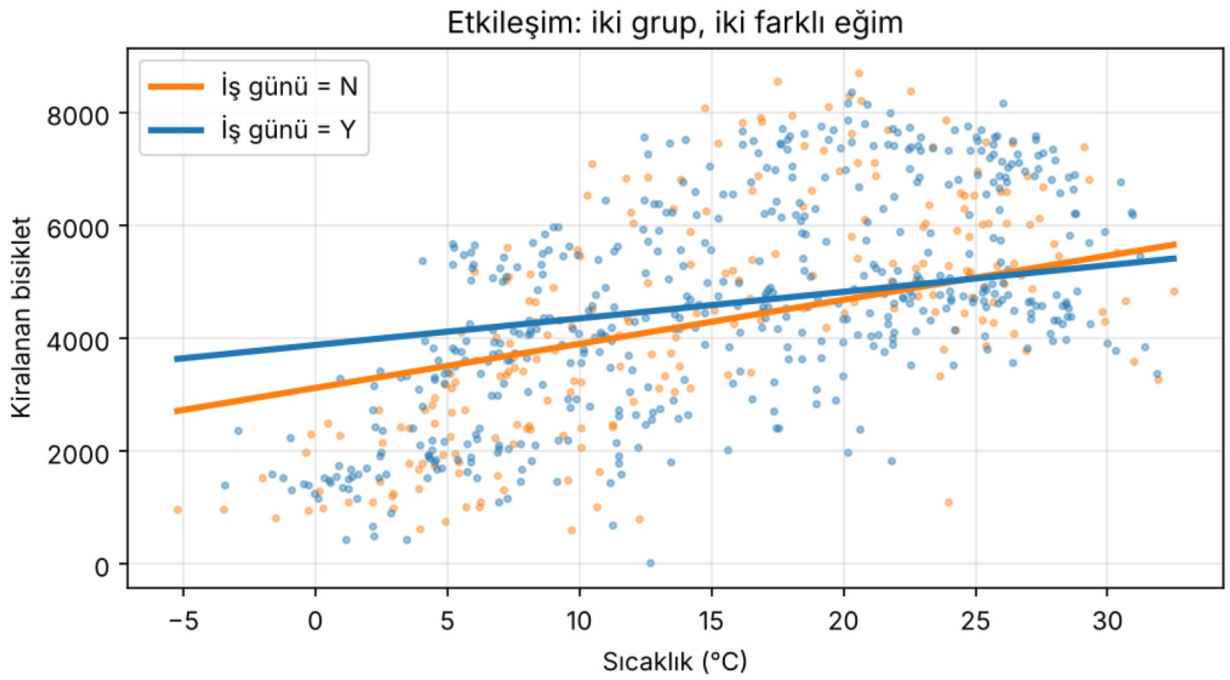
stres 0,10 → **0,13** · uyku −0,20 → **−0,18**
iş günü 1,00 → **1,17**

GÜVEN ARALIĞI DENEYİ

200 tekrarın **%95,5**'inde %95 GA gerçek değeri yakaladı.

BÖLÜM 8 · SORUN 2 · ETKİLEŞİM

Etkileşim katsayısı tek başına okunmaz



Model: … + sıcaklık × iş günü

Terim	Katsayı
Sıcaklık	78,1
Sıcaklık × iş günü	−31,0

İş gününde sıcaklık eğimi

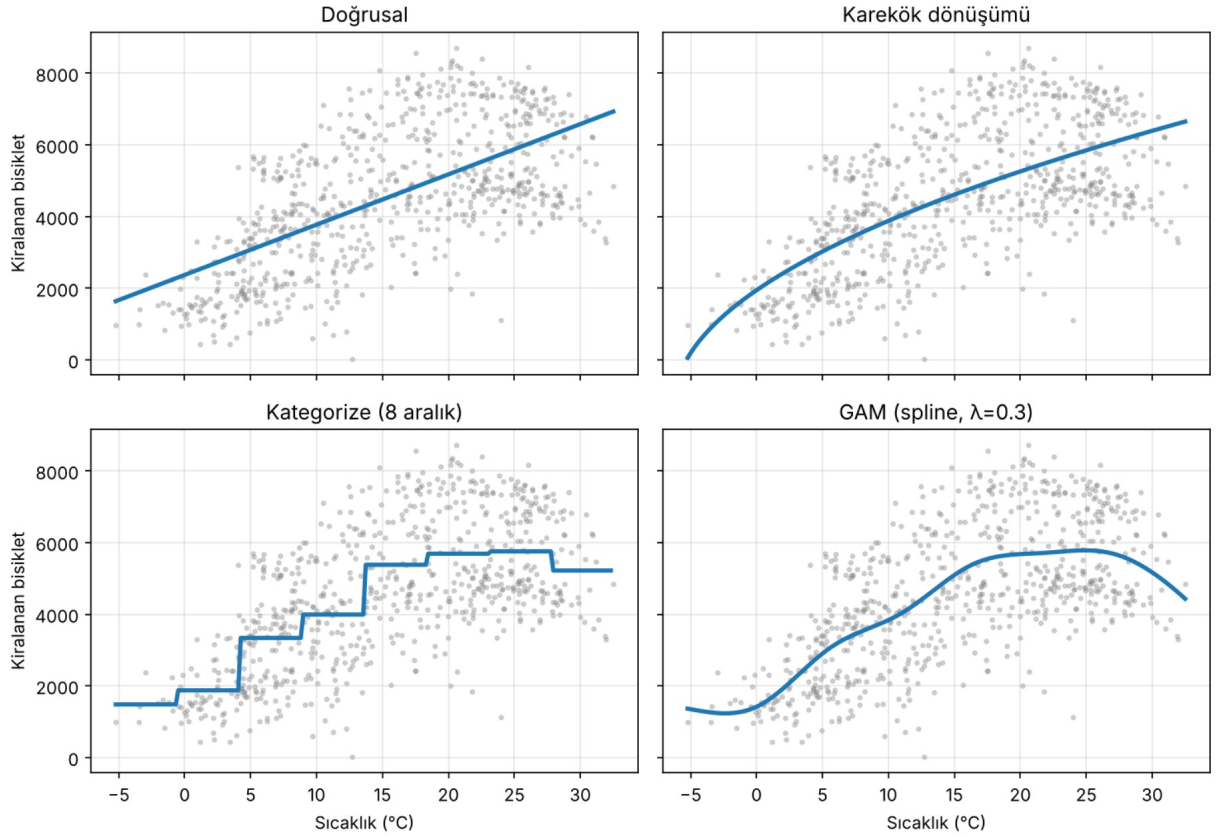
78,1 − 31,0 = 47,1

Hâlâ **pozitif**

Kitabın kuralı: etkileşimi eklerken ana etkileri (sıcaklık, iş günü) de modelde tut.

BÖLÜM 8 · SORUN 3 · DOĞRUSAL OLMAYAN İLİŞKİ

Dünya doğrusal değil: dört çözüm



Doğrusal
Tek eğim, sıcakta düşüşü kaçırır

Dönüşüm
Biçimi kısmen esnetir; yorum değişir

Kategorize
Basamak; kesim noktaları keyfi

GAM
Eğriyi spline'larla veriden öğrenir

$$g(E[y]) = \beta_0 + f_1(x_1) + \ldots + f_p(x_p)$$

BÖLÜM 8 · FREMTPL2 · POISSON GLM

Hasar sayısı: offset ile adil karşılaştırma

677.991

poliçe · Fransız araç sigortası

%96,3

poliçede hiç hasar yok

29

poliçe için doğrusal modelden negatif hasar sıklığı

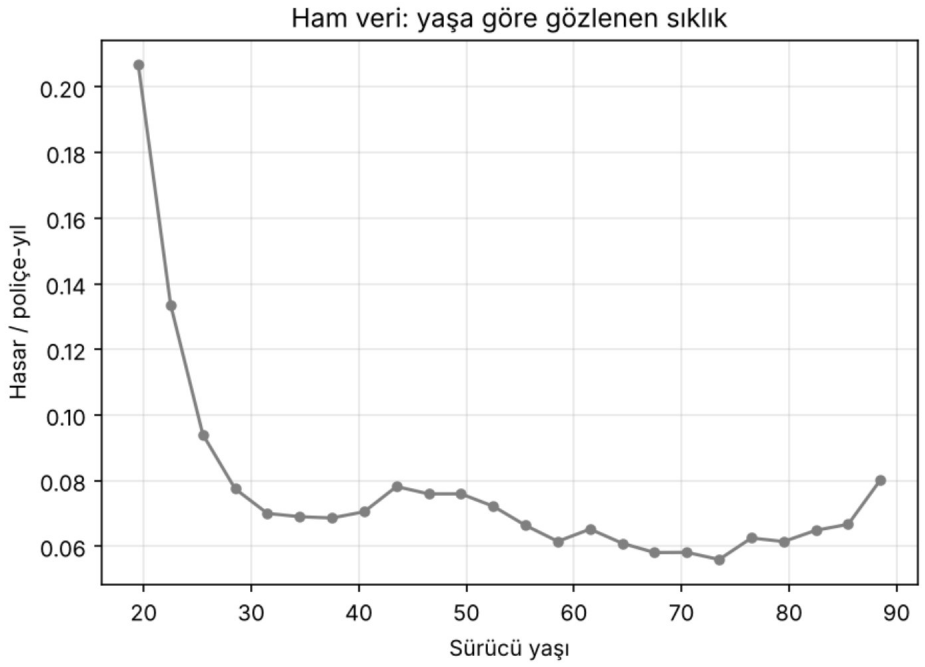
$$\ln E[\text{hasar}] = \ln(\text{süre}) + \beta_0 + \beta_1 x_1 + \ldots$$

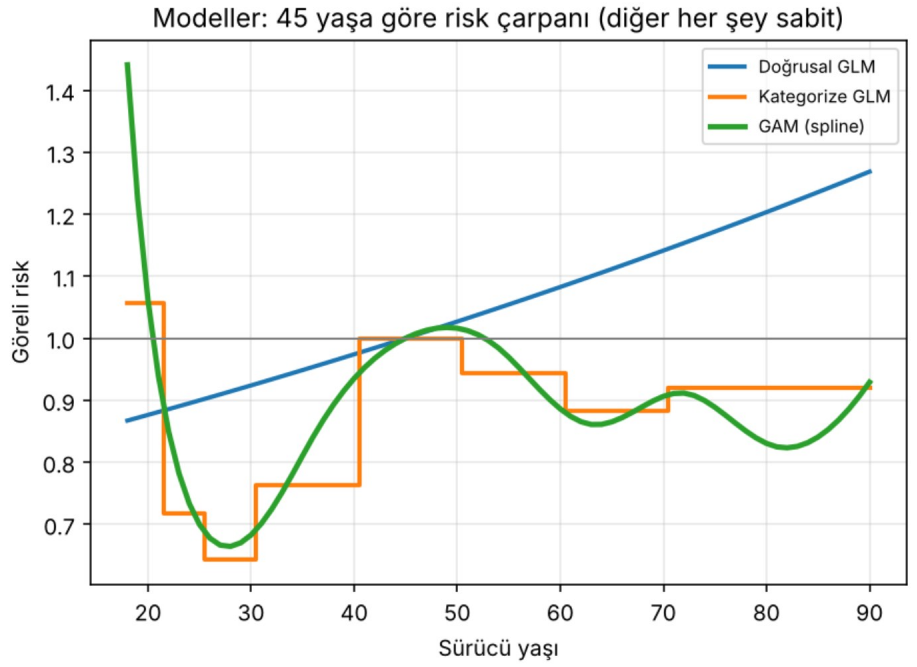
Değişiklik	Hasar sıklığı
BonusMalus +10 puan	× 1,30
Benzinli araç (dizele göre)	× 0,83
Nüfus yoğunluğu 2 katı	× 1,044

Diğer her şey sabitken · log(yoğunluk) kullanıldığı için son satır bir esneklik

BÖLÜM 8 · GAM · SÜRÜCÜ YAŞI

Doğrusal GLM genç sürücünün riskini tersine çeviriyor





18 yaş, 45 yaşa göre: Doğrusal GLM **× 0,87** GAM **× 1,44**

Ham veride fark daha büyük, çünkü gençlerin BonusMalus puanı da yüksek: model "diğer her şey sabitken" etkiyi ayırıyor.

CANLI KOD · BÖLÜM 6, 7 VE 8

Üç modeli zor verilerde kodda görelim

Bölüm 6	Ames, 3. hücre: huni grafiği, Breusch-Pagan 446 → 131, 1 negatif fiyat
Bölüm 7	German Credit, 6. hücre: kara liste deneyi, β = 26,6 ve SE = 42.213
Bölüm 8	Sigorta, 5a–5b. hücre: 29 negatif tahmin, Poisson GLM çarpanları

MAKALE YENİDEN ÜRETİMİ · SEÇENEK 2: KIYASLAMA

Yorumlanabilir model, kara kutu kadar iyi mi?

Caruana, Lou, Gehrke, Koch, Sturm ve Elhadad (2015) · KDD '15

Intelligible Models for HealthCare: Predicting Pneumonia Risk and Hospital 30-day Readmission · Bölüm 8'de atıf olarak geçiyor

GA²M = GAM + İKİLİ ETKİLEŞİMLER

$$g(E[y]) = \beta_0 + \Sigma f_j(x_j) + \Sigma f_{ij}(x_i, x_j)$$

Her eğri ayrı çizilebilir. Python'da: InterpretML **EBM** (aynı ekip).

ÜNLÜ BULGU: ASTIM

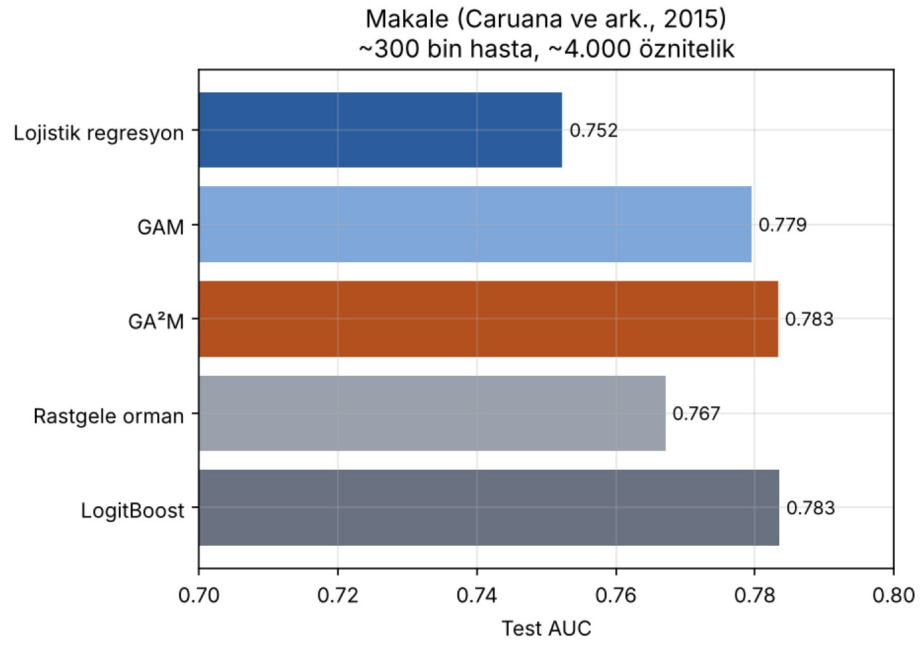
Model, astımlı zatürre hastalarını **daha az riskli** buluyor. Neden: doğrudan yoğun bakıma alınıyorlar.

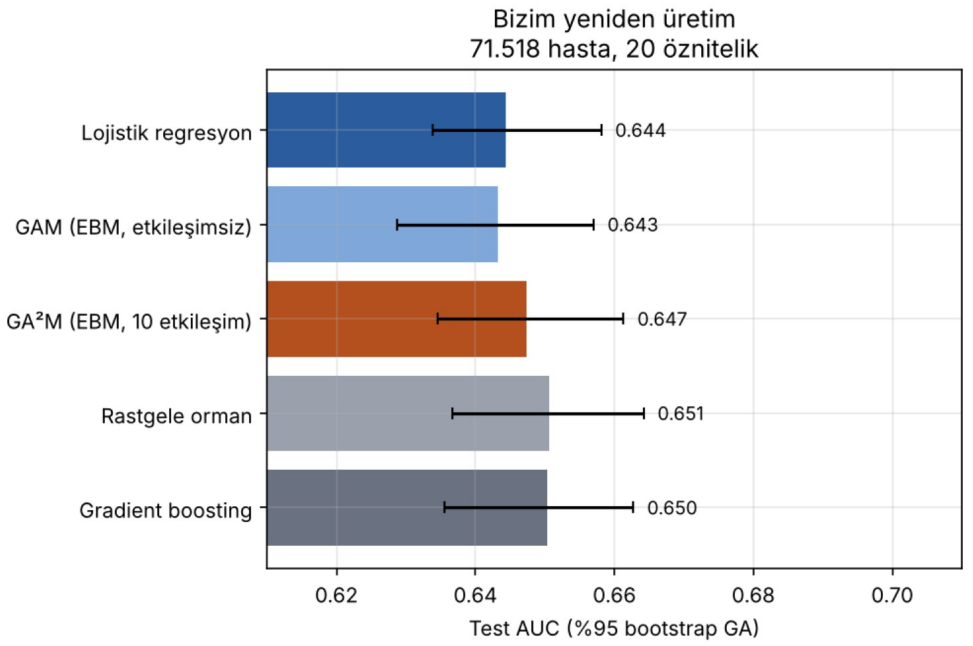
Veride doğru, karar için tehlikeli.

Yeniden üretim: 130 ABD hastanesi · 71.518 diyabet hastası · hedef 30 gün içinde yeniden yatış (%8,8; makalede %8,9)

MAKALE · İDDİA 1 · DOĞRULUK

Makalenin tablosu ve bizim yeniden üretimiz





Destekleniyor

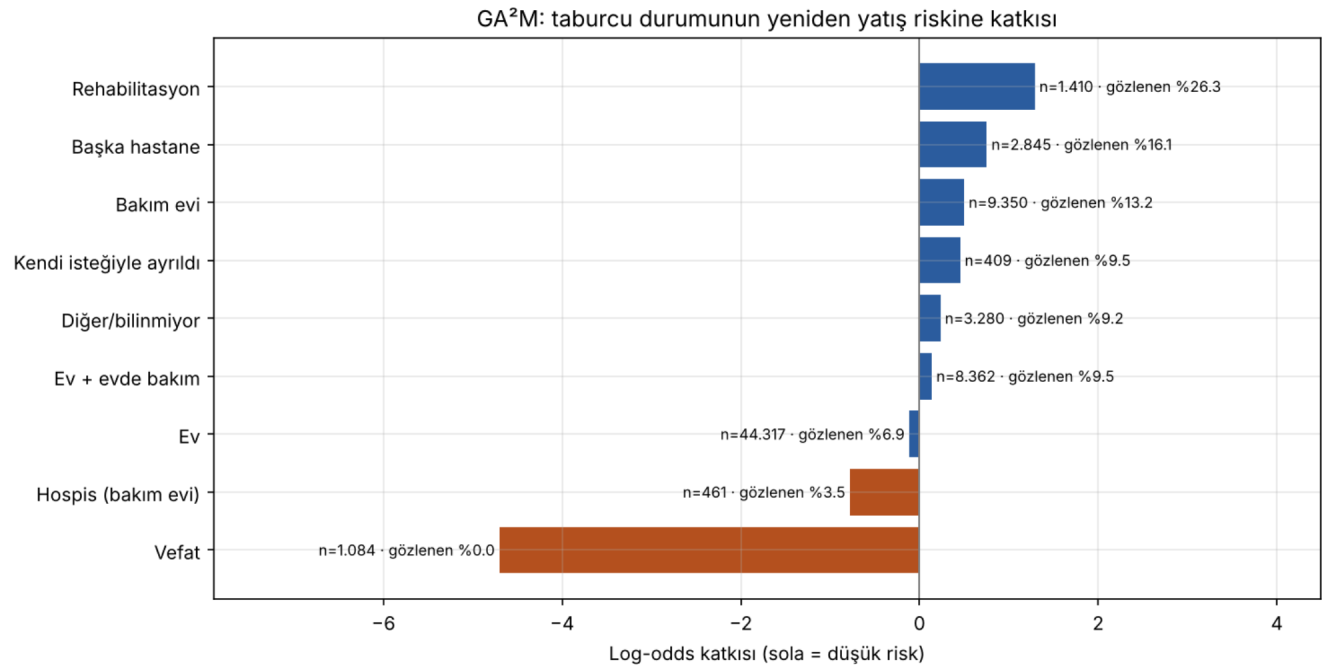
Yorumlanabilir modeller kara kutularla aynı düzeyde; güven aralıkları örtüşüyor.

Desteklenmiyor

GA²M lojistik regresyonu anlamlı biçimde geçemiyor: 0,647'ye 0,644 (makalede ~3 puan). Olası neden: 20 öznitelik, makalede ~4.000.

MAKALE · İDDİA 2 · TEHLİKELİ ÖRÜNTÜ

Astımın bu verideki karşılığı: ölüm "düşük risk"



%0

vefat eden 1.084 hastada yeniden yatış

En önemli öznitelik taburcu durumu. Model, en ağır hastaları **en düşük riskli** sanıyor.

Bölüm 7: tam ayrışma; lojistik regresyonda β = −6,94.

Düzeltme: vefat/hospis çıkarıldı; AUC 0,640 → 0,641.

Model veriyi açıklar, dünyayı değil. Bunu cam kutu sayesinde gördük.

CANLI KOD · MAKALE YENİDEN ÜRETİMİ

Yeniden üretimi kodda görelim: analiz.ipynb

1. bölüm	Veri: 71.518 hasta, yeniden yatış %8,8 · taburcu tablosu: Vefat 1.084 / 0
2. bölüm	Beş modelin AUC değerleri ve 200 bootstrap güven aralığı
4. bölüm	Vefat katkısı −4,7 · lojistik β = −6,94 · düzeltme sonrası AUC 0,640 → 0,641

ÖZET

Cam kutu da kırılır: nerede, nasıl?

Bölüm	Kırılma	Ders
6	Varsayım ihlali	Katsayı değil, güven aralığı yanıltır
6	Çoklu bağlantı	Tahmin sağlam, yorum çöker: işaret dönebilir
7	Odds oranı	Etki çarpımsal; olasılığa etkisi başlangıca bağlı
7	Tam ayrışma	Katsayı sonsuza kaçar; ceza gerekir
8	Etkileşim	Etkileşim katsayısı ana etkiyle birlikte okunur
8	Doğrusallık	Doğrusal GLM genç sürücünün riskini tersine çevirir
Makale	Taburcu = vefat	Model veriyi açıklar, dünyayı değil

Yorumlanabilir olmak, doğru yorumlanmak demek değildir.

KAYNAKLAR

Kaynaklar ve veri setleri

Molnar, C. *Interpretable Machine Learning*. christophm.github.io/interpretable-ml-book

Rudin, C. (2019). Stop explaining black box machine learning models for high stakes decisions… *Nature Machine Intelligence*, 1(5), 206–215.

Lundberg, S. M., & Lee, S.-I. (2017). A unified approach to interpreting model predictions. *NeurIPS*.

Mood, C. (2010). Logistic regression: Why we cannot do what we think we can do… *European Sociological Review*, 26(1), 67–82.

Caruana, R. ve ark. (2015). Intelligible models for healthcare. *KDD '15*, 1721–1730.

Meinshausen, N., & Bühlmann, P. (2010). Stability selection. *JRSS B*, 72(4), 417–473.

Strack, B. ve ark. (2014). Impact of HbA1c measurement on hospital readmission rates. *BioMed Research International*, 781670.

Wood, S. N. (2017). *Generalized Additive Models: An Introduction with R* (2. baskı). CRC Press.

Grömping, U. (2019). South German Credit Data: Correcting a widely used data set. Beuth Hochschule für Technik Berlin.

De Cock, D. (2011). Ames, Iowa: Alternative to the Boston Housing data. *Journal of Statistics Education*, 19(3).

Hofmann, H. (1994). Statlog (German Credit Data). UCI Machine Learning Repository.

Noll, A., Salzmann, R., & Wüthrich, M. V. (2020). Case study: French motor third-party liability claims. SSRN 3164764.

Çeviri ve kodlar: github.com/mesutpolatgil/xai-dersi-2026 · 2026-guz/06, 07, 08

Teşekkürler

Sorular?

Ahmet Batuhan Kaya · 20269348005

Ek

Soru gelirse

Odds ve risk oranı · non-collapsibility · log(y) · SHAP · Lasso · spline · aşırı yayılım · GA²M eğrileri · yedek canlı kod

EK 1 · BÖLÜM 7 · TUZAK

Odds oranı, risk oranı değildir

Temerrüt oranı: eksi bakiyeli müşteri **%49,3** · bakiyesi bilinmeyen müşteri **%11,7**

Risk oranı (RR)

4,2×

49,3 / 11,7

Odds oranı (OR)

7,3×

(0,493/0,507) / (0,117/0,883)

İkisi yalnızca olay nadirken birbirine yakındır. Burada temerrüt %30.

EK 2 · BÖLÜM 7 · NON-COLLAPSIBILITY

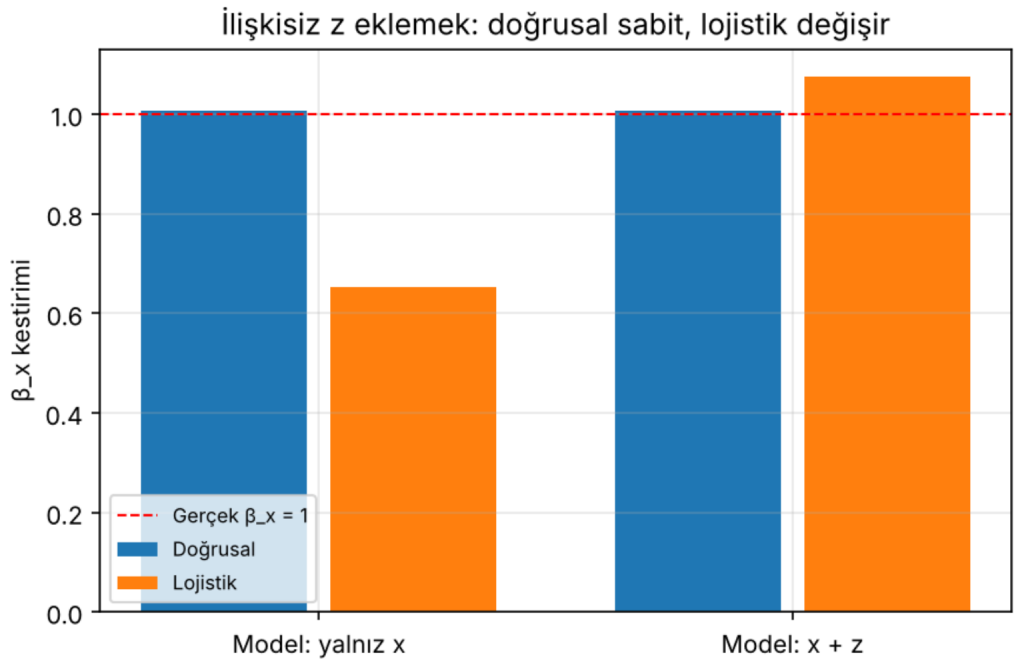
İlgisiz bir değişken eklemek bile katsayıyı değiştirir

Simülasyon: 20.000 gözlem, x ve z **bağımsız** (korelasyon 0,000), gerçek $\beta_x = 1$. Modele z'yi ekleyince x'in katsayısı ne olur?

Model	yalnız x	x + z
Doğrusal	1,01	1,01
Lojistik	0,65	1,08

Farklı değişken setleriyle kurulmuş lojistik modellerin (ya da farklı çalışmaların) odds oranları **doğrudan karşılaştırılamaz**.

Mood, C. (2010). European Sociological Review, 26(1).



EK 3 · BÖLÜM 8

İki sessiz tuzak

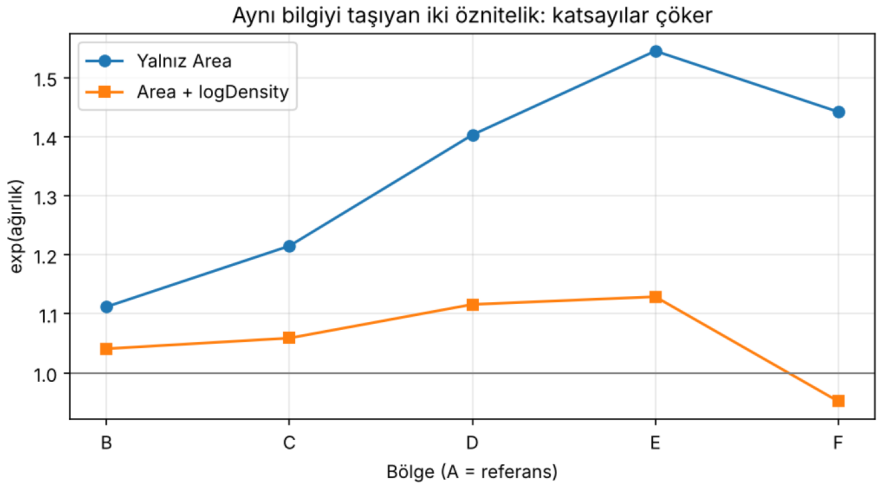
log(y) modellemek ≠ log bağlantı

$$E[\log y] \le \log E[y]$$

Bisiklet, toplam kiralama	Toplam
Gerçek	3.290.270
OLS log(y) → exp	3.157.960
Poisson GLM (log bağlantı)	3.290.270

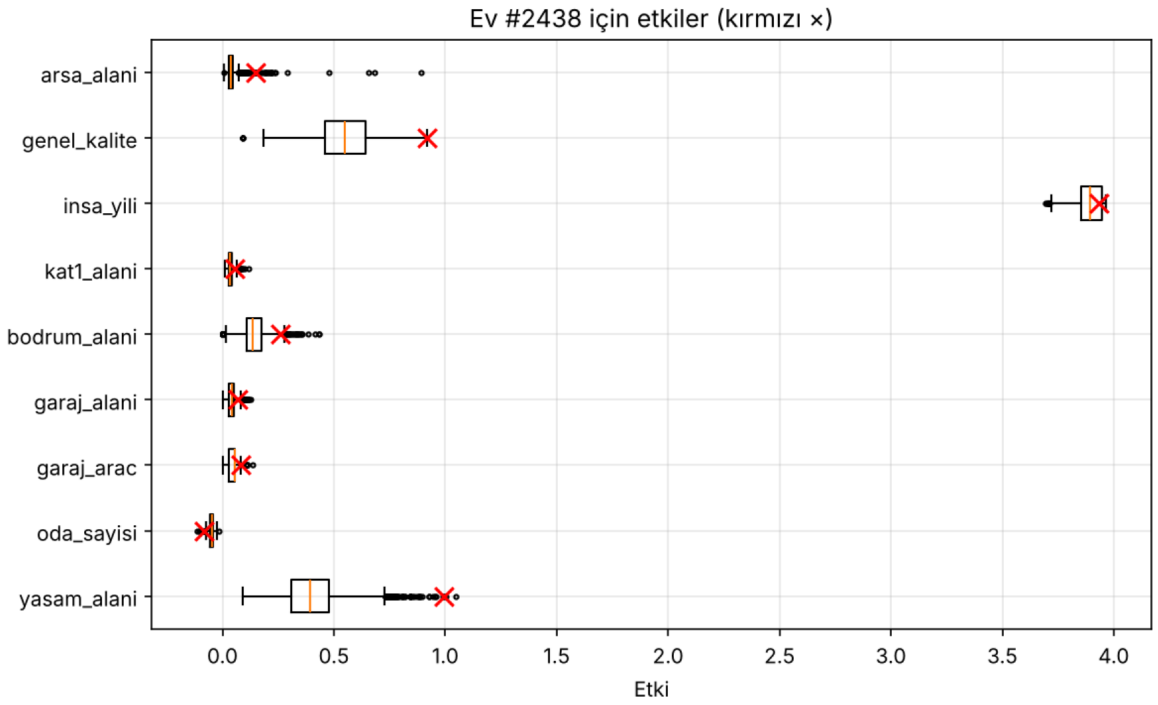
log(y) modeli ortalamayı sistematik olarak düşük tahmin ediyor: **132 bin eksik**.

Aynı bilgiyi taşıyan iki öznitelik



Area ~ Density: Spearman **0,98**. E bölgesi × 1,55 → × 1,13; hiçbiri anlamlı kalmıyor.

Referansı ortalamaya taşı: SHAP kendiliğinden çıkar



Ev #2438: gerçek 625.000 $ · tahmin 612.203 $

$$\phi_j = \beta_j \cdot (x_j - E[x_j])$$

Ev #2438	φ (log)
Yaşam alanı	+0,584
Genel kalite	+0,359
Bodrum alanı	+0,119
İnşa yılı	+0,047

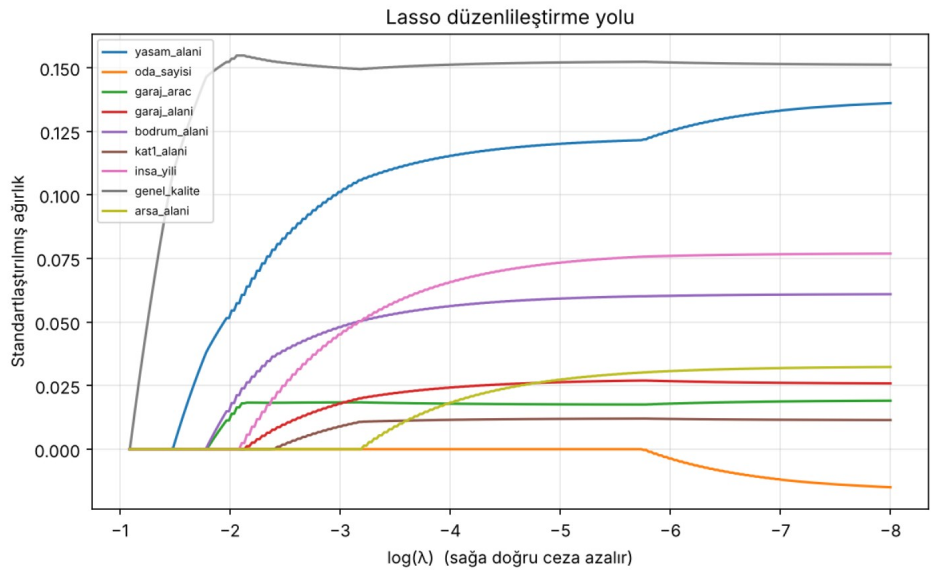
$\Sigma \varphi_j = f(x) - E[f(x)] = 1{,}3047$ · doğrulandı

Kitap: öznitelikler ortalamaya göre merkezlenirse referans "ortalama ev" olur.

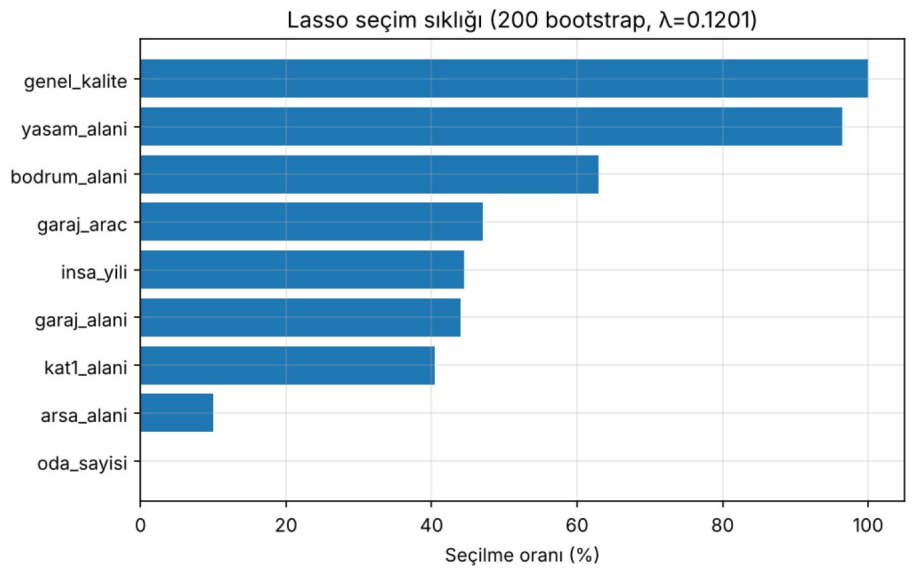
EK 5 · BÖLÜM 6 · LASSO

Lasso seyreklik getirir, ama seçimi kararsızdır

$$\min \Sigma (y - \hat{y})^2 / n + \lambda \cdot \Sigma |\beta| \cdot \lambda \text{ büyüdükçe daha çok } \beta \text{ tam 0 olur}$$

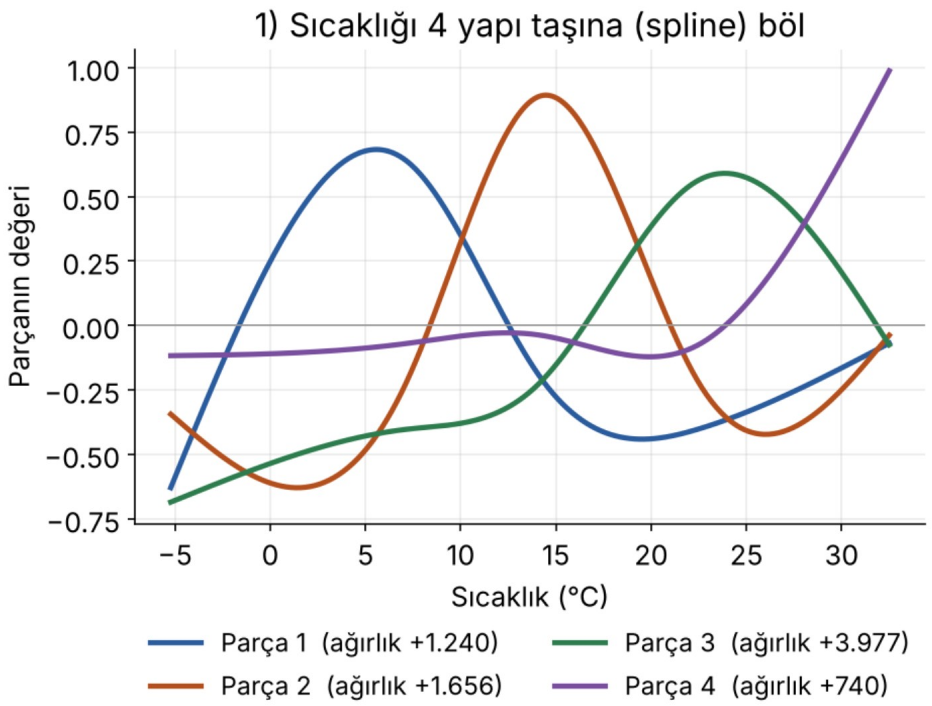


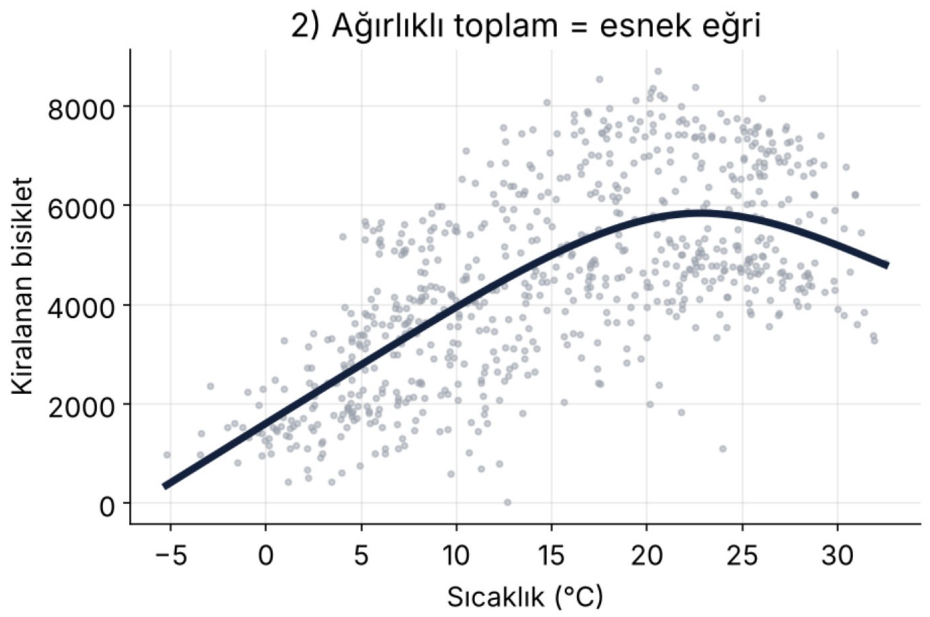
Düzenlileştirme yolu: λ küçüldükçe öznitelikler sırayla girer. İlk girenler: genel kalite, yaşam alanı.



200 bootstrap: tüm veride seçilen inşa yılı yalnızca %45 seçiliyor. Garaj çiftinden tek biri seçildi: **%54**.

Eğriyi Lego parçalarından kurmak: spline





$\beta \cdot x \rightarrow f(x)$

Sıcaklık sütunu yerine 4 spline sütunu; model her birine ağırlık verir. Bir **ceza terimi** eğrinin fazla kıvrılmasını engeller.

Poisson "varyans = ortalama" der, veri başka der

Pearson χ^2 / serbestlik derecesi

1,66

Poisson varsayımı: **1**

Standart hatalar $\sqrt{1{,}66} \approx 1{,}29$ kat küçük hesaplanıyor.

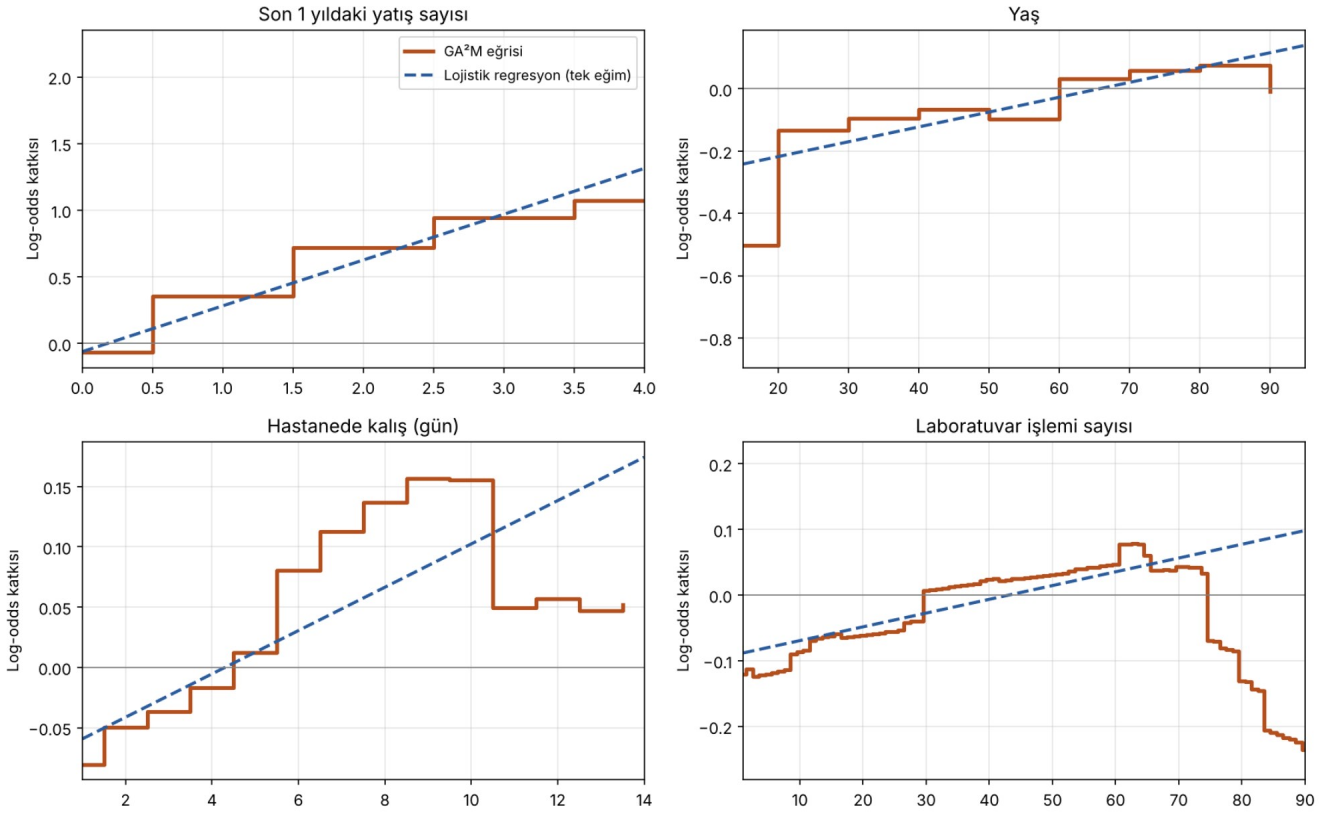
Öznitelik	Poisson SE	Quasi SE	z
log(yoğunluk)	0,0147	0,0189	4,2 → 3,2
Benzinli araç	0,0126	0,0163	−14,8 → −11,5
Bölge D	0,0587	0,0757	1,87 → 1,45

Katsayılar aynı kalır; **güven aralıkları gereğinden dar**, p-değerleri gereğinden iyi görünür.

Düzeltme: quasi-Poisson ya da Negatif Binom (AIC 215.534 → 215.008).

EK 8 · MAKALE · ŞEKİL FONKSİYONLARI

Tek eğim, eğrinin hikâyesini kaçırıyor



Hastanede kalış
Risk ~10 güne kadar artıyor, sonra düşüyor

Laboratuvar işlemi
~75'ten sonra keskin düşüş

Önceki yatış
En güçlü sayısal yordayıcı, basamaklı

Yaş
20 yaş altında belirgin düşük risk

YEDEK CANLI KOD · BÖLÜM 6

Kodda görelim: main.ipynb

1. hücre	Kitabın bisiklet modeli Python'da: katsayı tablosu
3. hücre	Ames: huni grafiği, Breusch-Pagan 446 → 131, negatif fiyat
6b. hücre	500 bootstrap: oda sayısı katsayısı %72 negatif

YEDEK CANLI KOD · BÖLÜM 7

Kodda görelim: main.ipynb

1. hücre	Kitabın penguen tablosu: odds oranları birebir aynı
4a. hücre	German Credit: odds oranları ve güven aralıkları
6. hücre	Kara liste deneyi: β = 26,6, standart hata 42.213