

Cam kutu modeller

Doğrusal regresyon, lojistik regresyon, GLM ve GAM: nasıl yorumlanır, nerede kırılır?

Ahmet Batuhan Kaya

20269348005

Molnar, *Interpretable Machine Learning*

Bölüm 6 · 7 · 8

Bugün neler var?

01	Giriş	Neden önce cam kutular? Üç bölüm tek bir aile.
02	Bölüm 6 · Doğrusal regresyon	Katsayı yorumu, güven aralığı, varsayımlar, çoklu bağlantı
03	Bölüm 7 · Lojistik regresyon	Odds ve odds oranı, penguenler, kredi verisi, tam ayrışma
04	Bölüm 8 · GLM ve GAM	Üç sorun: GLM, etkileşim, GAM · sigorta verisi · üç bölümün canlı kodu
05	Makale yeniden üretimi	Caruana ve ark. (2015): yorumlanabilir model kara kutu kadar iyi mi? · canlı kod

GİRİŞ

Cam kutunun tahmini bir fiş gibi okunur

TAHMİN FİŞİ · EV FİYATI

Başlangıç (sabit terim)	20
-------------------------	----

Alan: $100 \text{ m}^2 \times 1,5$	+150
------------------------------------	------

Oda: $4 \times (-3)$	-12
----------------------	-----

Tahmin	158 bin \$
---------------	-------------------

Bu bölümlerde

Fiş modelin kendisi. Her kalemi okuyabiliriz.

Dersin geri kalanında

LIME ve SHAP, kara kutular için fiş sonradan üretmeye çalışır. LIME yerel bir doğrusal model kurar; SHAP doğrusal modelde tek satırlık bir formüle iner.

Rudin (2019)

Yüksek riskli kararlarda kara kutuyu sonradan açıklamak yerine baştan yorumlanabilir model kullanılmalı.

GİRİŞ

Üç bölüm, tek motor: ağırlıklı toplam

$$\eta = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_p x_p$$

Model	Hedef (y)	η nasıl bağlanır?	x +1 olunca	Verimiz
Doğrusal regresyon	Sürekli sayı	Doğrudan: $y = \eta$	$y + \beta$	Ev fiyatı
Lojistik regresyon	Evet / hayır	Sigmoid: $p = 1/(1+e^{-\eta})$	$\text{odds} \times e^{\beta}$	Kredi
Poisson GLM	Sayım	Üstel: $\mu = e^{\eta}$	$\mu \times e^{\beta}$	Sigorta hasarı
GAM	Herhangi biri	βx yerine $f(x)$ eğrisi	Grafikten okunur	Sürücü yaşı

Her bölüm, bir öncekinin kırıldığı yerde başlar.

06

Doğrusal regresyon

Ağırlıklı toplam ne söyler, ne zaman yanıltır?


Veri: bisiklet kiralama (kitabın örneği) · Ames Housing, 2.930 ev

En iyi çizgi, hata karelerini en küçük yapandır

Deneme = $60 + 1 \cdot \text{alan}$ · **En iyi** = $40 + 1,2 \cdot \text{alan}$

Fiyat bin \$ · hata = gerçek fiyat – tahmin

Ev	Alan	Fiyat	Dene me	(hata) ²	En iyi	(hata) ²
A	60	114	120	$(-6)^2 = 36$	112	$2^2 = 4$
B	80	132	140	$(-8)^2 = 64$	136	$(-4)^2 = 16$
C	100	160	160	$0^2 = 0$	160	$0^2 = 0$
D	120	188	180	$8^2 = 64$	184	$4^2 = 16$
E	140	206	200	$6^2 = 36$	208	$(-2)^2 = 4$
To pla m				200		40



$\min \Sigma (\text{gerçek} - \text{tahmin})^2$

Bu beş ev için toplamı 40'tan küçük yapan çizgi yok. Eğim 1,2: her m² fiyatı 1.200 \$ artırır.

Katsayı: diğer her şey sabitken bir birimlik etki

Sayısal öznitelik

$$\text{fiyat} = 20 + 1,5 \cdot \text{alan} - 3 \cdot \text{oda}$$

Ev	Alan	Oda	Tahmin
X	100 m ²	3	161
Y	100 m ²	4	158
Z	120 m ²	4	188

X ile Y: alan aynı, bir oda fazla → **-3**. Aynı alan daha küçük odalara bölünmüş.

Kategorik öznitelik

Bisiklet modeli, referans: iyi hava

Hava	Katsayı
İyi (referans)	0
Sisli	-531
Kötü	-2.204

Kötü havalı gün, **iyi havaya göre** 2.204 daha az kiralama.
Sıcaklık: +1 °C → +55.

BÖLÜM 6 · NE KADAR EMİNİZ?

Katsayı bir tahmindir: yanında belirsizliği gelir

KİTABIN BİSİKLET MODELİ · PYTHON

Öznitelik	β	SE	t	%95 güven aralığı
Sıcaklık (+1 °C)	54,8	10,2	5,4	35 ... 75
Kötü hava	-2.204	311	7,1	-2.815 ... -1.592
Yaz (kışa göre)	108	219	0,5	-323 ... 539

Aralık 0'ı içeriyorsa: fark olduğunu gösteremiyoruz

Kitabın yorumu: yaz ile kış arasında anlamlı bir fark yok. Sıcaklık zaten modelde; yaz katsayısı yazın **ek** etkisi.

SE: standart hata

Katsayı veriyle ne kadar oynar?

$$t = \beta / SE$$

Önem ölçüsü: $54,8 / 10,2 \approx 5,4$


$$\%95 \text{ GA} \approx \beta \pm 2 \cdot SE$$

100 tekrarın ~95'inde gerçek değeri içerir.

$$R^2 = 1 - SSE / SST$$

Açıklanan fark payı (0 ile 1 arası)

Varsayım bozulunca güven aralığı yanılır



KİTABIN ÖRNEĞİ · EŞ VARYANSLILIK

Ortalama hata 50.000 €. Bu hata 1 milyon €'luk evde de, 40.000 €'luk evde de aynı mı? O zaman **negatif fiyat** beklemek gerekirdi.

AMES'TE: HAM FİYAT


Hata pahalı evlerde büyüyor (huni) · **1 eve negatif fiyat** · Breusch-Pagan **446**

ÇÖZÜM: LOG(FİYAT)


Huni kapanıyor (BP **131**). Yorum çarpımsal: kalite +1 → fiyat × $e^{0,092} \approx \text{\%9,6}$ artış

BÖLÜM 6 · AĞIRLIK VE ETKİ GRAFİĞİ

Ağırlık mı, etki mi? Ölçek her şeyi değiştirir





Ağırlık grafiği: kitabın uyarısı: birim değişince ağırlık değişir (kg → g: $\beta / 1000$). Bu yüzden standartlaştırdık. "Mutfak: Po" tek evden: aralığı devasa.



Etki grafiği: etki = $\beta \cdot x$, yani gerçek katkı. İnşa yılı en büyük görünüyor ama kutusu dar: karşılaştırma noktası "0. yıl".

Veri biraz değişince katsayının işareti dönüyor



%72

oda sayısı katsayısı negatif:
kitabın örneği

%24

garaj katsayıları negatif

0,89

garaj araç ~ garaj alanı
korelasyonu

Kitap: büyüklük ve oda sayısı birlikte modeldeyse, aynı büyüklükte oda eklemek evi küçük odalara bölmek demektir; oda sayısı negatif ağırlık alabilir.

Tahmin sağlam, yorum çöker. 500 bootstrap, her biri 150 ev

07


Lojistik regresyon

Hedef evet/hayır olunca: olasılık, odds ve odds oranı

Veri: Palmer penguenleri (kitabın örneği) · German Credit, 1.000 kredi başvurusu

BÖLÜM 7 · LOJİSTİK REGRESYON

Düz çizgi olasılık değildir: sigmoid ile 0–1'e sıkıştır



KİTAP: DOĞRUSAL MODEL NEDEN OLMUZ?

- ① Çıktı olasılık değil · ② 0'ın altına, 1'in üstüne taşar
- ③ İki nokta eklenince 0,5 eşiği kayar · ④ Çok sınıfa genişlemez

ÇÖZÜM: LOJİSTİK FONKSİYON

$$P(Y=1) = 1 / (1 + e^{-(\beta_0 + \beta_1 x_1 + ...)})$$

Model log-odds'ta doğrusal, etki çarpımsal

$$\ln(p / (1 - p)) = \beta_0 + \beta_1 x_1 + \dots \Rightarrow x + 1 : \text{odds} \times e^{\beta}$$

Odds = olur / olmaz

Olasılık p	Odds
0,20	0,25
0,50	1
0,80	4

e^{β} = **odds oranı**. 1'den büyükse risk artar, küçükse azalır.

Aynı odds oranı (2), farklı etki

Önce	Sonra	Fark
%5	%9,5	+4,5 puan
%50	%66,7	+16,7 puan
%90	%94,7	+4,7 puan

Olasılıktaki etki başlangıç riskine bağlı.

Kitabın örneği: odds = 2 iken $\beta = 0,7 \rightarrow x + 1 \rightarrow \text{odds} \times e^{0,7} \approx \times 2 \rightarrow \text{odds} = 4$

Kitabın tablosu Python'da birebir çıktı

Chinstrap penguenleri · hedef: P(dişi)

Öznitelik	Kitap (R)	Python
Gaga uzunluğu	0,59	0,59
Gaga derinliği	0,13	0,13
Yüzgeç uzunluğu	0,85	0,85
Normal tombul	1,92	1,92
En tombul	0,43	0,43


Odds oranları · referans: ufak penguen

KİTAPTA BİR YORUM HATASI

"Gaga uzunluğundaki artış, dişi olma odds'unu 0,59 çarpanı kadar **artırır**."

0,59 < 1 olduğu için odds **azalır**: her mm'de yaklaşık %41 düşüş.

Cam kutu, verideki tuhaflığı görünür kılar



Vade +12 ay

$\text{odds} \times 1,031^{12} = \times 1,45$

Bakiye bilinmiyor

eksi bakiyeye göre $\times 0,18$

Sezgiye aykırı

Kritik kredi geçmişi $\times 0,54$ (riski azaltıyor)

Tamamen ödemiş $\times 2,25$ (riski artırıyor)

Olası nedenler: seçim yanlılığı ya da veri setindeki bilinen kodlama hataları (Grömping, 2019).

Test AUC $\approx 0,79$

Kusursuz ayıran değişkenin katsayısı sonsuza kaçır

Deney: veriye bir "**kara liste**" değişkeni ekledim. Kara listedeki herkes temerrüde düşmüş.

Kara liste	Ödedi	Temerrüt
Hayır	700	235
Evet	0	65

26,6 **42.213**

katsayı (β) standart hata

Kitabın çözümü: ağırlıklara ceza ya da önsel dağılım.



Ceza azaldıkça katsayı durmadan büyüyor

08

GLM, GAM ve ötesi

Doğrusal modelin üç sorunu: Gauss dışı hedef, etkileşim, doğrusal olmayan ilişki

Veri: kahve simülasyonu ve bisiklet (kitabın örnekleri) · freMTPL2, 678.000 sigorta poliçesi

Basit bıçaktan İsviçre çakısına: üç sorun, üç çözüm

SORUN 1 · GAUSS DIŞI HEDEF

"Bugün kaç dakika bisiklet süreceğim?"

Doğrusal model negatif dakika tahmin edebilir. Olasılıkla 0'ın altı ya da 1'in üstü çıkabilir.

Çözüm: GLM

SORUN 2 · ETKİLEŞİM

"Hafif yağmur isteğimi azaltır... ama yaz akşamı iş çıkışında yollar bana kalır."

Yağmurun etkisi saate ve mevsime bağlı. Toplamsal model bunu yakalayamaz.

Çözüm: etkileşim terimi

SORUN 3 · DOĞRUSAL OLMAYAN

"0–25 °C arası her derece isteğimi artırır; çok sıcakta binmem."

Tek bir eğim, 10 → 11 °C ile 30 → 31 °C'yi aynı sayar.

Çözüm: dönüşüm ya da GAM

Kitabın ipucu: ihlali deneyerek kontrol edin. Etkileşim ya da eğri eklemek doğrulama verisinde performansı artırıyor mu?

GLM'in üç parçası

1 · DAĞILIM

Üstel aileden: Normal,
Bernoulli, Poisson...

+

2 · DOĞRUSAL YORDAYICI

$$\eta = \beta_0 + \beta_1 x_1 + \dots \text{ (aynı motor)}$$


+

3 · BAĞLANTI g

$$g(E[y]) = \eta$$

Bölüm	Dağılım	Bağlantı	Tahmin
6 · Doğrusal	Normal	birim	$E[y] = \eta$
7 · Lojistik	Bernoulli	logit	$p = 1/(1+e^{-\eta})$
8 · Poisson	Poisson	log	$\mu = e^{\eta} > 0$

Sayım verisinde doğrusal model negatif tahmin üretir



YORUM: ÇARPIMSAL

$\ln E[\text{kahve}] = \beta_0 + \beta \cdot \text{stres} + \dots$

Stres +1 $\rightarrow$ kahve $\times e^{0,13} \approx \times 1,14$

GERÇEK $\rightarrow$ POISSON GLM

stres 0,10 $\rightarrow$ **0,13** · uyku -0,20


$\rightarrow$ **-0,18**

iş günü 1,00 $\rightarrow$ **1,17**

GÜVEN ARALIĞI DENEYİ

200 tekrarın **%95,5**'inde %95 GA
gerçek değeri yakaladı.

Etkileşim katsayısı tek başına okunmaz



Model: ... + sıcaklık × iş günü

Terim	Katsayı
Sıcaklık	78,1
Sıcaklık × iş günü	-31,0


İş gününde sıcaklık eğimi

$$78,1 - 31,0 = 47,1$$

Hâlâ **pozitif**

Kitabın kuralı: etkileşimi eklerken ana etkileri (sıcaklık, iş günü) de modelde tut.

Dünya doğrusal değil: dört çözüm



Doğrusal

Tek eğim, sıcakta düşüşü kaçıırır

Dönüşüm

Biçimi kısmen esnetir; yorum değişir

Kategorize

Basamak; kesim noktaları keyfi

GAM

Eğriyi spline'larla veriden öğrenir

$$g(E[y]) = \beta_0 + f_1(x_1) + \dots + f_p(x_p)$$

Hasar sayısı: offset ile adil karşılaştırma

677.991

poliçe · Fransız araç sigortası

%96,3

poliçede hiç hasar yok

29



poliçe için doğrusal modelden negatif hasar sıklığı

$$\ln E[\text{hasar}] = \ln(\text{süre}) + \beta_0 + \beta_1 x_1 + \dots$$

Değişiklik	Hasar sıklığı
BonusMalus +10 puan	× 1,30
Benzinli araç (dizele göre)	× 0,83
Nüfus yoğunluğu 2 katı	× 1,044

Diğer her şey sabitken · log(yoğunluk) kullanıldığı için son satır bir esneklik

Doğrusal GLM genç sürücünün riskini tersine çeviriyor



18 yaş, 45 yaşa göre: Doğrusal GLM $\times 0,87$ GAM $\times 1,44$

Ham veride fark daha büyük, çünkü gençlerin BonusMalus puanı da yüksek: model "diğer her şey sabitken" etkiyi ayırıyor.

CANLI KOD · BÖLÜM 6, 7 VE 8

Üç modeli zor verilerde kodda görelim

Bölüm 6	Ames, 3. hücre: huni grafiği, Breusch-Pagan 446 → 131, 1 negatif fiyat
Bölüm 7	German Credit, 6. hücre: kara liste deneyi, $\beta = 26,6$ ve $SE = 42.213$
Bölüm 8	Sigorta, 5a–5b. hücre: 29 negatif tahmin, Poisson GLM çarpanları

Yorumlanabilir model, kara kutu kadar iyi mi?

Caruana, Lou, Gehrke, Koch, Sturm ve Elhadad (2015) · KDD '15

Intelligible Models for HealthCare: Predicting Pneumonia Risk and Hospital 30-day Readmission · Bölüm 8'de atıf olarak geçiyor

GA²M = GAM + İKİLİ ETKİLEŞİMLER

$$g(E[y]) = \beta_0 + \sum f_j(x_j) + \sum f_{ij}(x_i, x_j)$$

Her eğri ayrı çizilebilir. Python'da: InterpretML **EBM** (aynı ekip).



ÜNLÜ BULGU: ASTIM

Model, astımlı zatürre hastalarını **daha az riskli** buluyor.
Neden: doğrudan yoğun bakıma alınıyorlar.

Veride doğru, karar için tehlikeli.

Yeniden üretim: 130 ABD hastanesi · 71.518 diyabet hastası · hedef 30 gün içinde yeniden yatış (%8,8; makalede %8,9)

Makalenin tablosu ve bizim yeniden üretimimiz




Destekleniyor

Yorumlanabilir modeller kara kutularla aynı düzeyde; güven aralıkları örtüşüyor.

Desteklenmiyor

GA²M lojistik regresyonu anlamlı biçimde geçemiyor: 0,647'ye 0,644 (makalede ~3 puan). Olası neden: 20 öznitelik, makalede ~4.000.

Astımın bu verideki karşılığı: ölüm "düşük risk"



%0

vefat eden 1.084 hastada yeniden yatış

En önemli öznitelik taburcu durumu. Model, en ağır hastaları **en düşük riskli** sanıyor.

Bölüm 7: tam ayrışma; lojistik regresyonda $\beta = -6,94$.

Düzeltilme: vefat/hospis çıkarıldı; AUC 0,640 → 0,641.

Model veriyi açıklar, dünyayı değil. Bunu cam kutu sayesinde gördük.

CANLI KOD · MAKALE YENİDEN ÜRETİMİ

Yeniden üretimi kodda görelim: analiz.ipynb

- | | |
|----------|--|
| 1. bölüm | Veri: 71.518 hasta, yeniden yatış %8,8 · taburcu tablosu: Vefat 1.084 / 0 |
| 2. bölüm | Beş modelin AUC değerleri ve 200 bootstrap güven aralığı |
| 4. bölüm | Vefat katkısı $-4,7$ · lojistik $\beta = -6,94$ · düzeltme sonrası AUC $0,640 \rightarrow 0,641$ |

ÖZET

Cam kutu da kırılır: nerede, nasıl?

Bölüm	Kırılma	Ders
6	Varsayım ihlali	Katsayı değil, güven aralığı yanıltır
6	Çoklu bağlantı	Tahmin sağlam, yorum çöker: işaret dönebilir
7	Odds oranı	Etki çarpımsal; olasılığa etkisi başlangıca bağlı
7	Tam ayrışma	Katsayı sonsuza kaçır; ceza gerekir
8	Etkileşim	Etkileşim katsayısı ana etkiyle birlikte okunur
8	Doğrusallık	Doğrusal GLM genç sürücünün riskini tersine çevirir
Makale	Taburcu = vefat	Model veriyi açıklar, dünyayı değil

Yorumlanabilir olmak, doğru yorumlanmak demek değildir.

KAYNAKLAR

Kaynaklar ve veri setleri

Molnar, C. *Interpretable Machine Learning*.
christophm.github.io/interpretable-ml-book

Rudin, C. (2019). Stop explaining black box machine learning models for high stakes decisions... *Nature Machine Intelligence*, 1(5), 206–215.

Lundberg, S. M., & Lee, S.-I. (2017). A unified approach to interpreting model predictions. *NeurIPS*.

Mood, C. (2010). Logistic regression: Why we cannot do what we think we can do... *European Sociological Review*, 26(1), 67–82.

Caruana, R. ve ark. (2015). Intelligible models for healthcare. *KDD '15*, 1721–1730.

Meinshausen, N., & Bühlmann, P. (2010). Stability selection. *JRSS B*, 72(4), 417–473.

Strack, B. ve ark. (2014). Impact of HbA1c measurement on hospital readmission rates. *BioMed Research International*, 781670.

Wood, S. N. (2017). *Generalized Additive Models: An Introduction with R* (2. baskı). CRC Press.

Grömping, U. (2019). South German Credit Data: Correcting a widely used data set. Beuth Hochschule für Technik Berlin.

De Cock, D. (2011). Ames, Iowa: Alternative to the Boston Housing data. *Journal of Statistics Education*, 19(3).

Hofmann, H. (1994). Statlog (German Credit Data). UCI Machine Learning Repository.

Noll, A., Salzmann, R., & Wüthrich, M. V. (2020). Case study: French motor third-party liability claims. SSRN 3164764.

Çeviri ve kodlar: github.com/mesutpolatgil/xai-dersi-2026 · 2026-guz/06, 07, 08

Teşekkürler

Sorular?

Ahmet Batuhan Kaya · 20269348005

Ek

Soru gelirse

Odds ve risk oranı · non-collapsibility · $\log(y)$ · SHAP · Lasso · spline · aşırı yayılım · GA^2M eğrileri · yedek canlı kod

Odds oranı, risk oranı değildir

Temerrüt oranı: eksi bakiyeli müşteri %49,3 · bakiyesi bilinmeyen müşteri %11,7

Risk oranı (RR)

4,2×

49,3 / 11,7

Odds oranı (OR)

7,3×

(0,493/0,507) / (0,117/0,883)

İkisi yalnızca olay nadirken birbirine yakındır. Burada temerrüt %30.


İlgisiz bir değişken eklemek bile katsayıyı değiştirir

Simülasyon: 20.000 gözlem, x ve z **bağımsız** (korelasyon 0,000), gerçek $\beta_x = 1$. Modele z'yi ekleyince x'in katsayısı ne olur?

Model	yalnız x	x + z
Doğrusal	1,01	1,01
Lojistik	0,65	1,08

Farklı değişken setleriyle kurulmuş lojistik modellerin (ya da farklı çalışmaların) odds oranları **doğrudan karşılaştırılmaz**.

Mood, C. (2010). European Sociological Review, 26(1).



İki sessiz tuzak


$\log(y)$ modellemek $\neq$ log bağlantı

$$E[\log y] \leq \log E[y]$$

Bisiklet, toplam kiralama	Toplam
Gerçek	3.290.270
OLS $\log(y) \rightarrow \exp$	3.157.960
Poisson GLM (log bağlantı)	3.290.270


$\log(y)$ modeli ortalamayı sistematik olarak düşük tahmin ediyor: **132 bin eksik**.

Aynı bilgiyi taşıyan iki öznelik



Area ~ Density: Spearman **0,98**. E bölgesi $\times 1,55 \rightarrow \times 1,13$; hiçbirisi anlamlı kalmıyor.

Referansı ortalamaya taşı: SHAP kendiliğinden çıkar



Ev #2438: gerçek 625.000 \$ · tahmin 612.203 \$

$$\phi_j = \beta_j \cdot (x_j - E[x_j])$$


Ev #2438	ϕ (log)
Yaşam alanı	+0,584
Genel kalite	+0,359
Bodrum alanı	+0,119
İnşa yılı	+0,047

$$\sum \phi_j = f(x) - E[f(x)] = 1,3047 \cdot \text{doğrulandı}$$


Kitap: öznitelikler ortalamaya göre merkezlenirse referans "ortalama ev" olur.

Lasso seyreklik getirir, ama seçimi kararsızdır

$\min \Sigma (y - \hat{y})^2 / n + \lambda \cdot \Sigma |\beta|$ · λ büyüdükçe daha çok β tam 0 olur





Düzenleme yolu: λ küçüldükçe öznitelikler sırayla girer. İlk girenler: genel kalite, yaşam alanı.



200 bootstrap: tüm veride seçilen inşa yılı yalnızca %45 seçiliyor. Garaj çiftinden tek biri seçildi: **%54**.

Eğriyi Lego parçalarından kurmak: spline



$$\beta \cdot x \rightarrow f(x)$$

Sıcaklık sütunu yerine 4 spline sütunu; model her birine ağırlık verir. Bir **ceza terimi** eğrinin fazla kıvrılmasını engeller.

Poisson "varyans = ortalama" der, veri başka der

Pearson χ^2 / serbestlik derecesi

1,66

Poisson varsayımı: **1**


Standart hatalar $\sqrt{1,66} \approx 1,29$ kat
küçük hesaplanıyor.

Öznitelik	Poisson SE	Quasi SE	z
log(yoğunluk)	0,0147	0,0189	4,2 → 3,2
Benzinli araç	0,0126	0,0163	-14,8 → -11,5
Bölge D	0,0587	0,0757	1,87 → 1,45

Katsayılar aynı kalır; **güven aralıkları gereğinden dar**, p-değerleri gereğinden iyi görünür.

Düzeltilme: quasi-Poisson ya da Negatif Binom (AIC 215.534 → 215.008).

Tek eğim, eğrinin hikâyesini kaçırıyor



Hastanede kalış

Risk ~10 güne kadar artıyor, sonra düşüyor

Laboratuvar işlemi

~75'ten sonra keskin düşüş

Önceki yatış

En güçlü sayısal yordayıcı, basamaklı

Yaş

20 yaş altında belirgin düşük risk

YEDEK CANLI KOD · BÖLÜM 6

Kodda görelim: main.py

1. hücre	Kitabın bisiklet modeli Python'da: katsayı tablosu
3. hücre	Ames: huni grafiği, Breusch-Pagan 446 → 131, negatif fiyat
6b. hücre	500 bootstrap: oda sayısı katsayısı %72 negatif

YEDEK CANLI KOD · BÖLÜM 7

Kodda görelim: main.py

1. hücre

Kitabın penguen tablosu: odds oranları birebir aynı

4a. hücre

German Credit: odds oranları ve güven aralıkları

6. hücre

Kara liste deneyi: $\beta = 26,6$, standart hata 42.213
