AÇIKLANABİLİR YAPAY ZEKÂ

# Ceteris Paribus

Christoph Molnar
Interpretable Machine Learning
Bölüm 12

# Ceteris Paribus

## Diğer koşullar sabitken

**Tek gözlem, tek özellik**

Seçilen özelliği değiştirir, diğer özellikleri sabit tutarız.

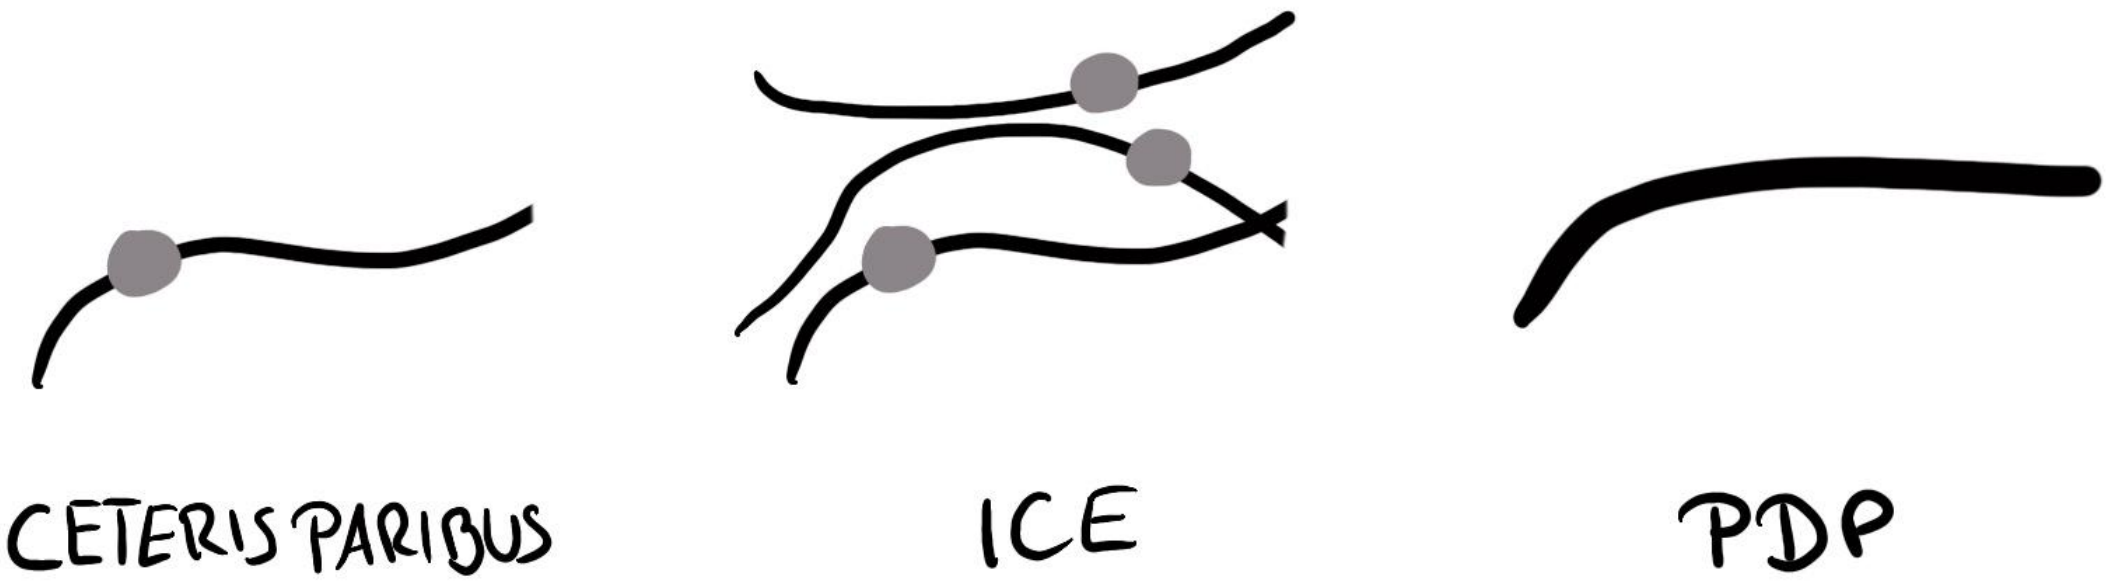
**Aynı model, yeni tahminler**

Modeli yeniden eğitmeden farklı girdiler için tahmin alırız.

**Modelden bağımsız açıklama**

Modelin iç yapısına erişmeden, tahmin fonksiyonunu kullanırız.

# CP, ICE ve PDP ilişkisi




**CP: tek gözlemin eğrisi**

**ICE: gözlemlerin eğrileri**

**PDP: tahminlerin ortalaması**

# CP algoritması

Başlangıç: Bir gözlem ve değiştirilecek özellik seçilir. $x^{(i)}, \; j$

## 1. Denenecek değerleri belirle

Sayısal özellik: eşit aralıklı değerler seçeriz.
Kategorik özellik: farklı kategorileri listeleriz.

$z_1, \ldots, z_K$

$z_1 = \min(x_j) \quad z_K = \max(x_j)$

## 2. Yalnızca seçilen özelliği değiştir

Diğer özellikleri, seçilen gözlemin kendi değerlerinde sabit tutarız.

$x^{(i)}_{x_j := z_k}$

## 3. Aynı modelden yeni tahmin al

Her deneme değeri için tahmin alırız.
Modeli yeniden eğitmeyiz.

$\hat{f}\left(x^{(i)}_{x_j := z_k}\right)$

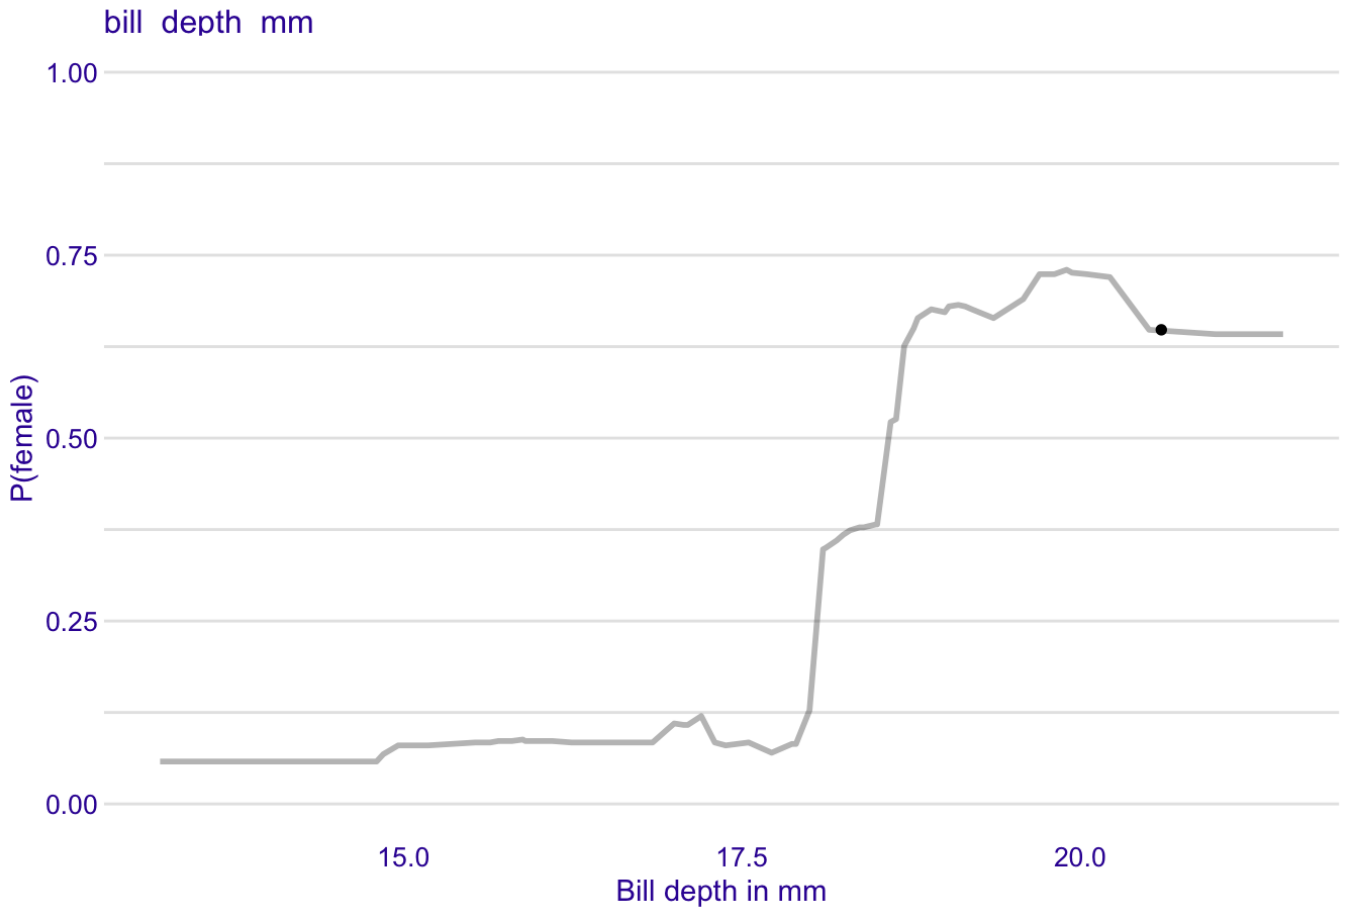
## 4. Değerleri ve tahminleri grafikte göster

Sayısal değerler için eğri, kategoriler için nokta veya sütun grafiği oluştururuz.

$\left(z_k, \hat{f}\left(x^{(i)}_{x_j := z_k}\right)\right)$

İşaretli nokta: orijinal özellik değeri ve modelin bu değerdeki tahmini.

# Penguenin gaga derinliği




**Rastgele orman**

Tahmin: dişi olma olasılığı

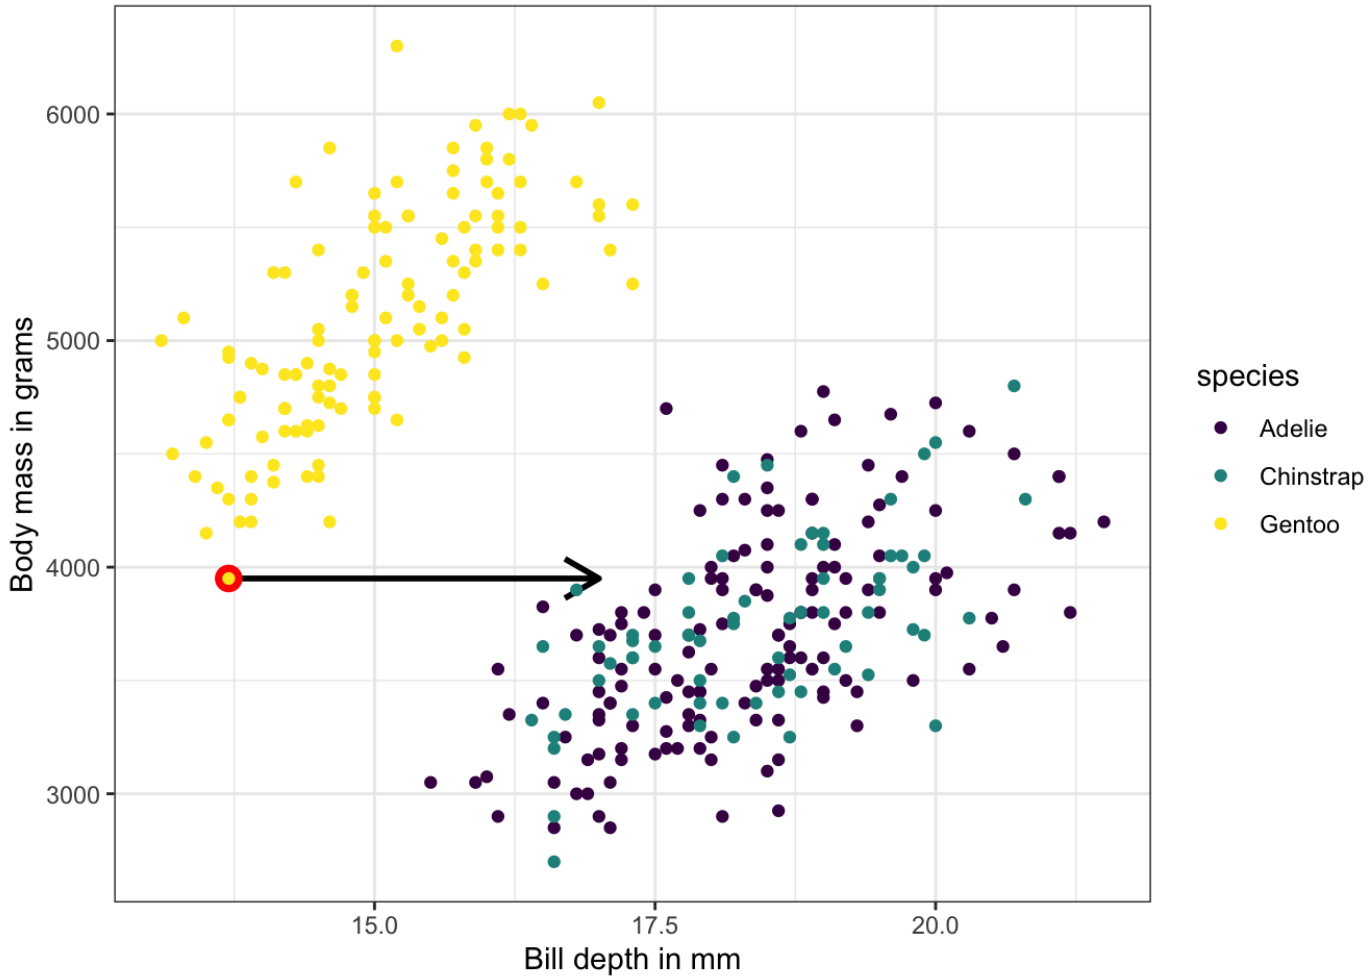
**Değişen özellik**

Gaga derinliği

**İşaretli nokta**

Orijinal gaga derinliği: 20,6 mm

# İkili ilişkiler yeterli olmayabilir



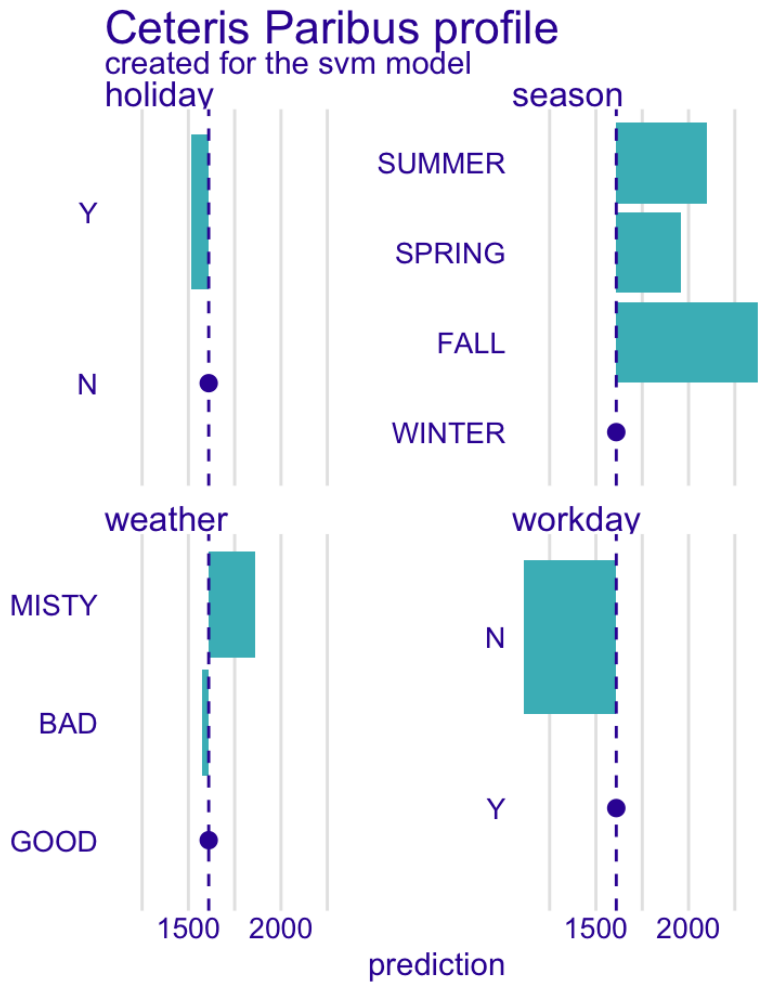

## Gentoo örneği

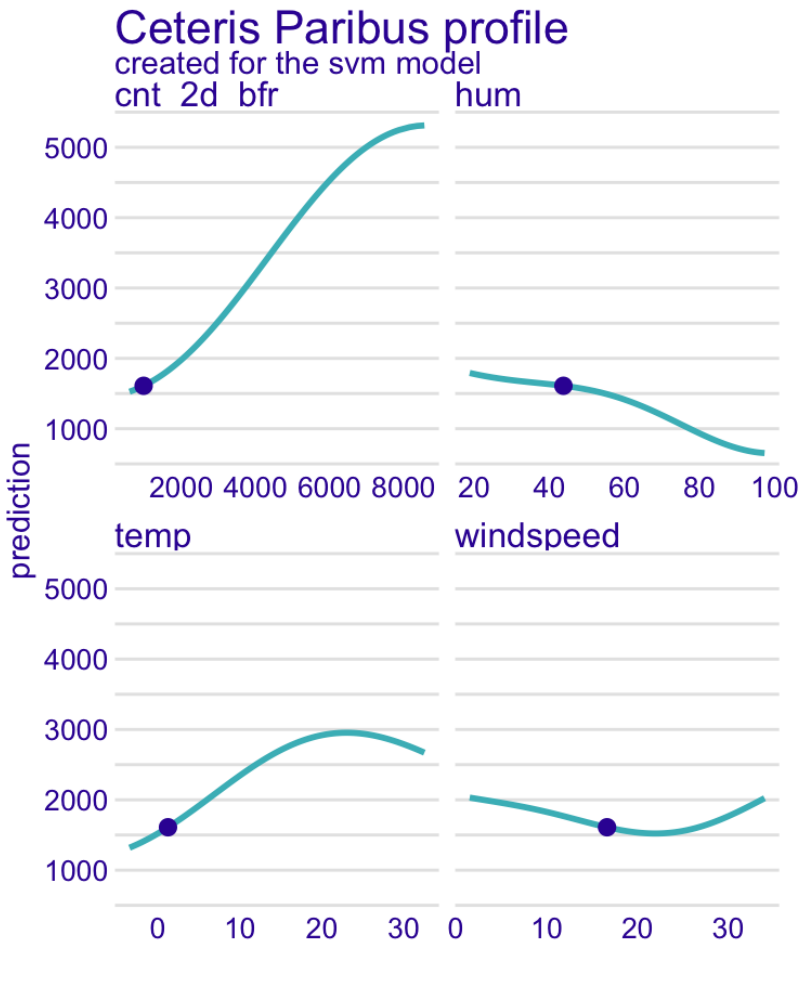
Tür ve ağırlık sabit.
Gaga derinliği değişiyor.

İkili birleşimler makul görünse bile üç özellik birlikte gerçekçi olmayabilir.

Bu şekil özellik dağılımını gösterir.

# Bisiklet kiralama tahmini




## SVM modeli

Hava koşulları iyi bir kış günü.

Her panelde yalnızca bir özellik değişir.

Diğer özellikler, seçilen günün kendi değerlerinde sabit kalır.

# Bisiklet panellerinin yorumu

## Sayısal paneller

Sıcaklık: önce artış, çok yüksek sıcaklıkta hafif düşüş.

Nem: arttıkça tahminde azalma.

Rüzgâr: hafif azalma, ardından yükseliş.

En büyük değişim: iki gün önceki kiralama sayısı.

## Kategorik paneller

Kategoriler dikeyde, tahminler yatayda.

İş günü olmayan seçenek, bu gün için daha düşük tahmin veriyor.

Tatil, mevsim ve hava durumu ayrı ayrı deneniyor.

**Yorumlar seçilen güne ve bu modele aittir.**

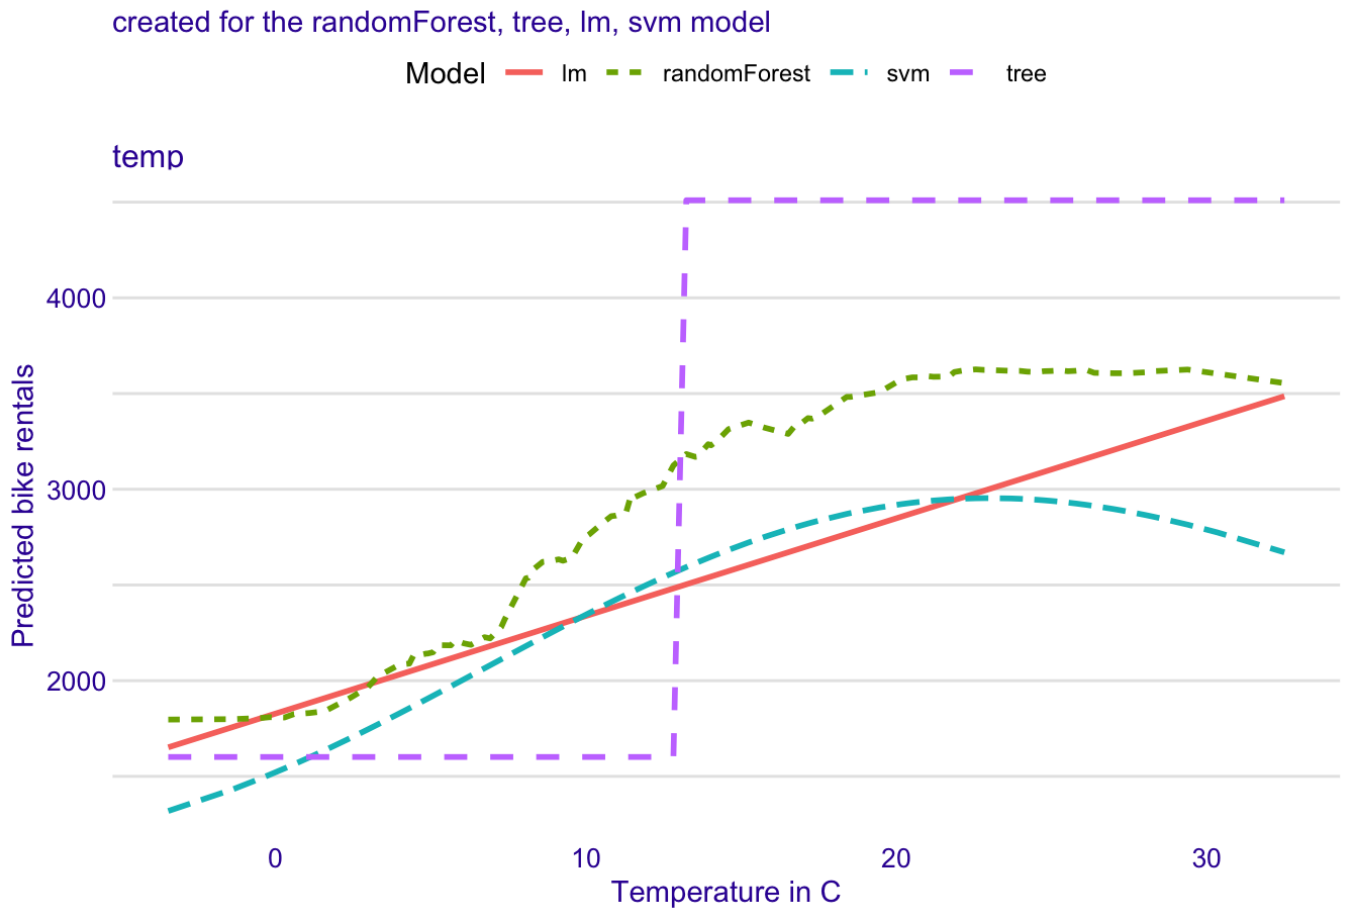
# Küçük çizgilerle CP gösterimi




## Sparkline gösterimi

Aynı tahmin eğrileri daha az yer kaplar.
Nokta, gözlemin orijinal özellik değerindeki tahminini gösterir.

# Aynı gün, farklı modeller




## Doğrusal model

Düz çizgi

## Karar ağacı

Sıçrama

## RF ve SVM

Daha yumuşak artış ve yüksek sıcaklıkta yataylaşma

# Güçlü yönler ve sınırlılıklar

## Güçlü yönler

Uygulaması ve anlaşılması kolay.

Farklı özellik ve modelleri karşılaştırabilir.

Yerel değişimlere duyarlılığı göstererek SHAP ve LIME açıklamalarını tamamlar.

## Sınırlılıklar

Standart eğri tek özellik değişimini inceler.

İlişkili özellikler gerçekçi olmayan girdiler oluşturabilir.

Modelin tepkisi tek başına nedensel sonuç vermez.

# CP için yazılım seçenekleri

## R: ceterisParibus

Kitaptaki bölümün grafiklerini üretmek için kullanılan paket.

## Python uygulaması

Ceteris Paribus profilleri Python ile de oluşturulabilir.

## ICE araçlarıyla tek gözlem

iml ve ICEbox gibi araçlar, tek gözlemle CP grafiği üretebilir.

AÇIKLANABİLİR YAPAY ZEKÂ

# ICE

## Individual Conditional Expectation

Christoph Molnar
Interpretable Machine Learning
Bölüm 13

# Individual Conditional Expectation

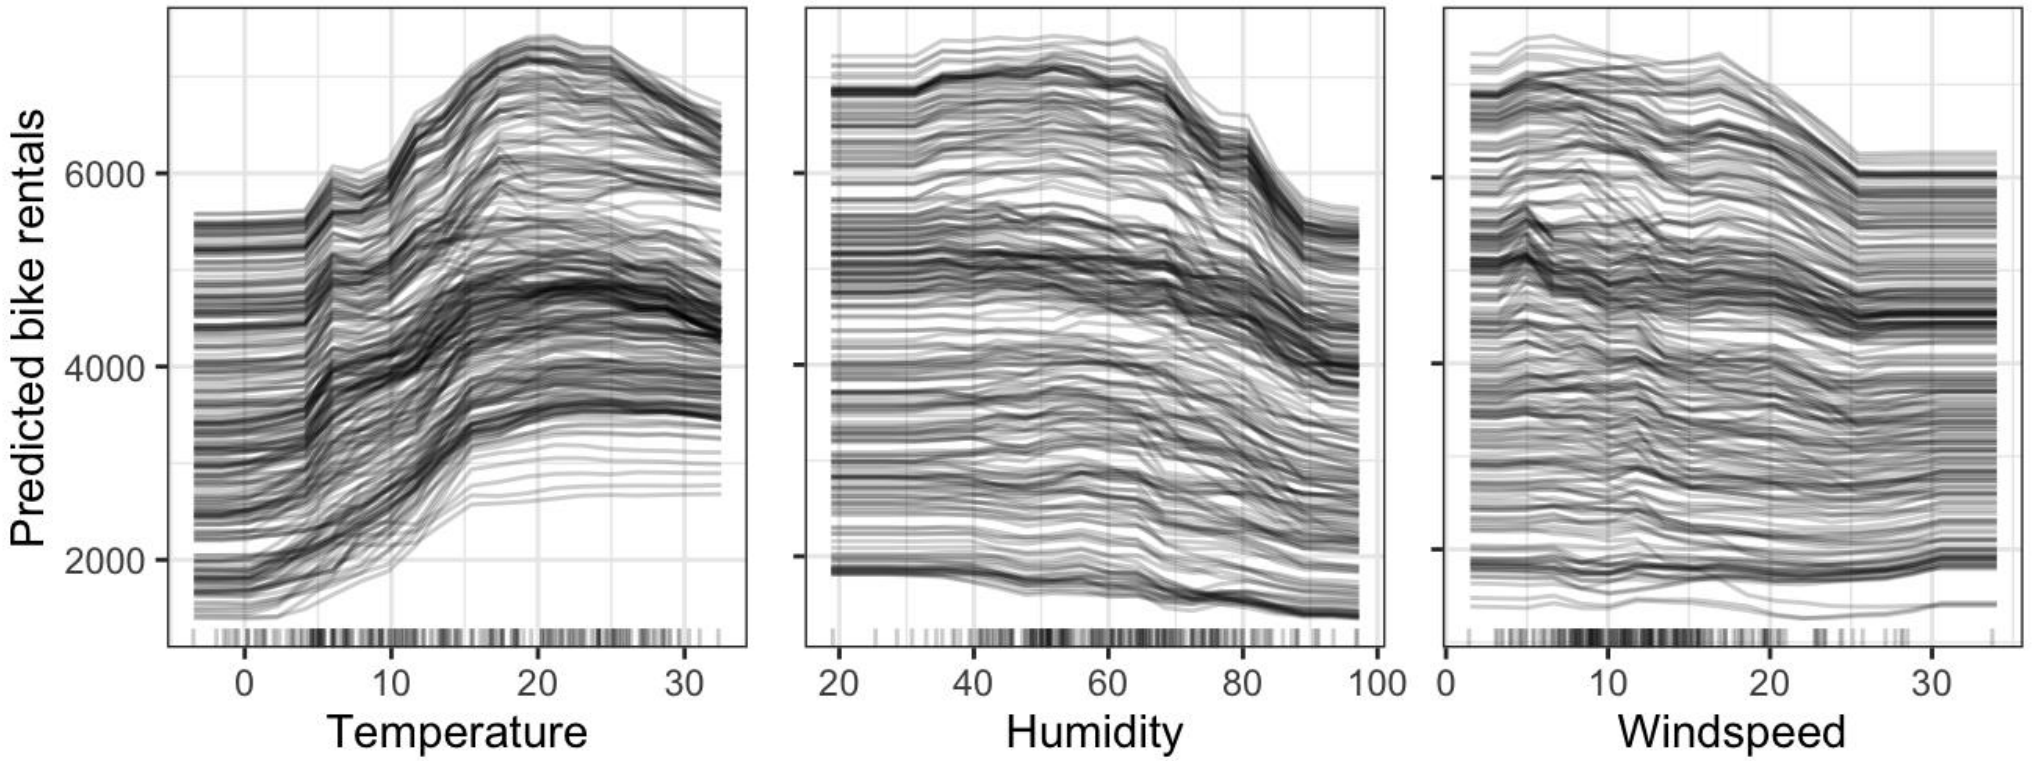
## Birden fazla gözlemin CP eğrileri

Her çizgi bir gözlemi temsil eder.

Her gözlem için aynı özellik değişir.
Diğer özellikler, o gözlemin kendi değerlerinde sabit kalır.

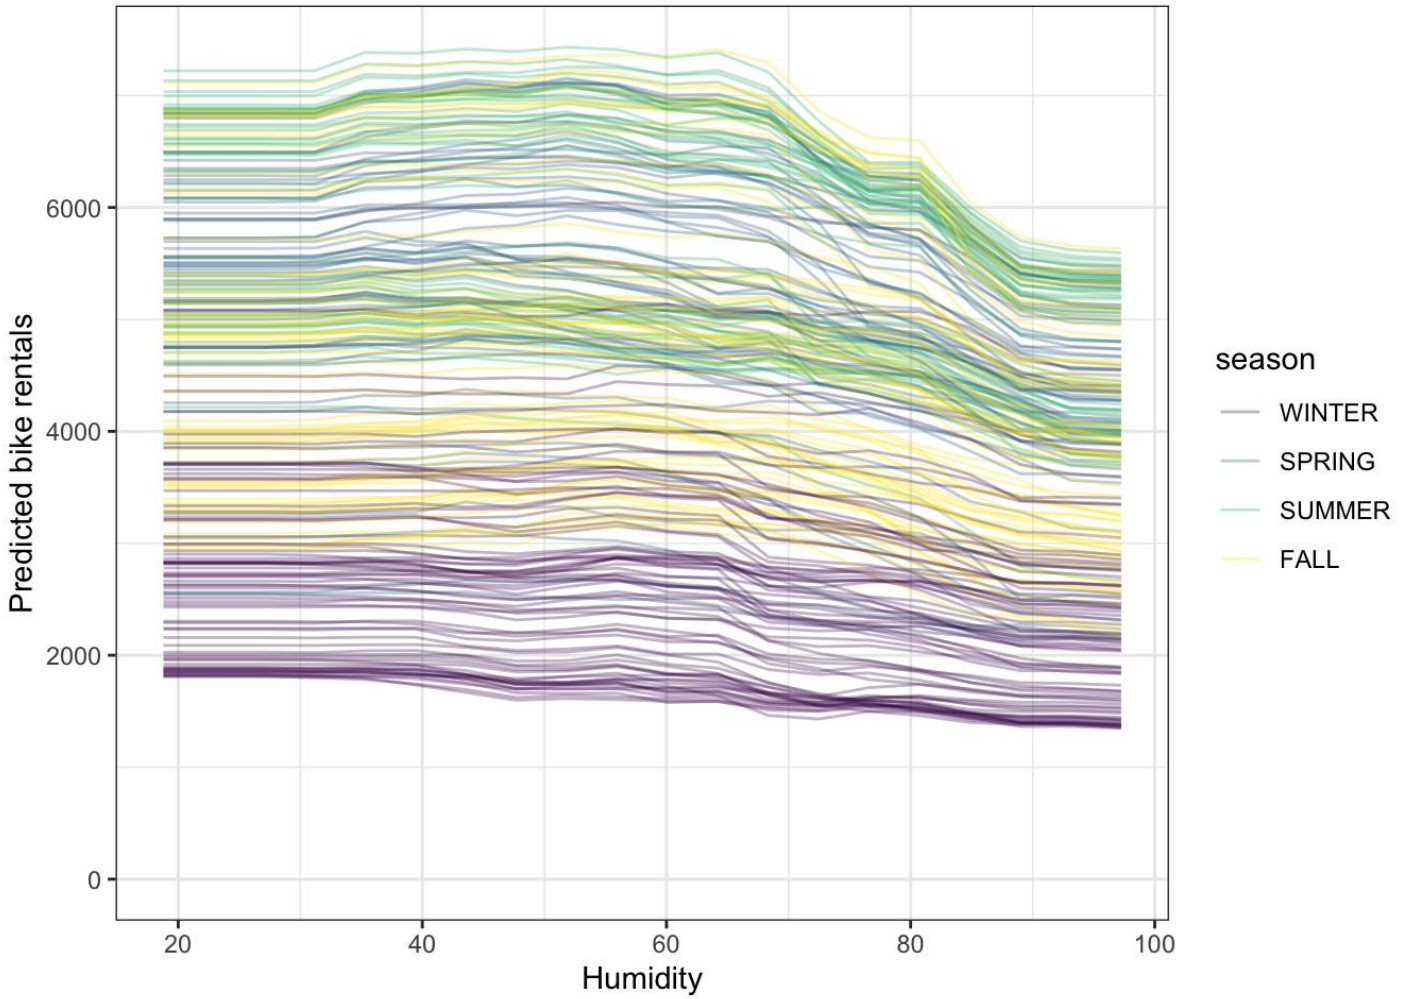
**Amaç: gözlemler arasındaki model tepkilerini karşılaştırmak.**

# Bisiklet kiralamada ICE




**Rastgele orman modeli. Her çizgi bir gün. Her panelde tek özellik değişir.**

# Nemin etkisi ve mevsimler




## Kış

Nem artarken hafif azalma.

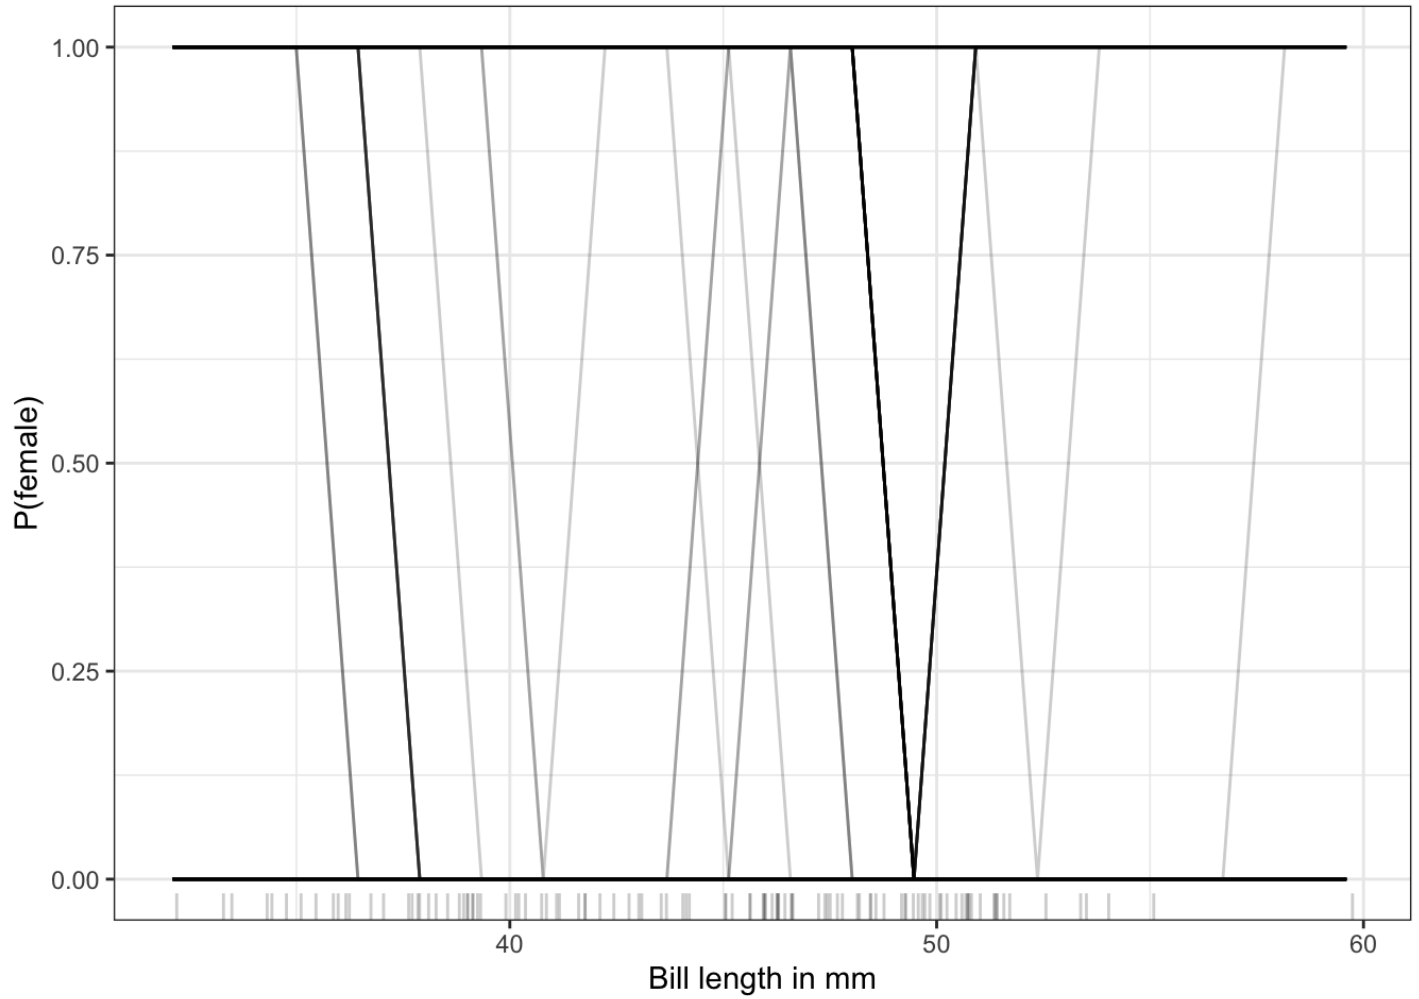
## Yaz

%20–60: yaklaşık sabit.
%60 üzeri: belirgin düşüş.

## Veri desteği

Yaz ve sonbaharda çok düşük nemi dikkatle yorumla.

# Penguenlerde gaga uzunluğu



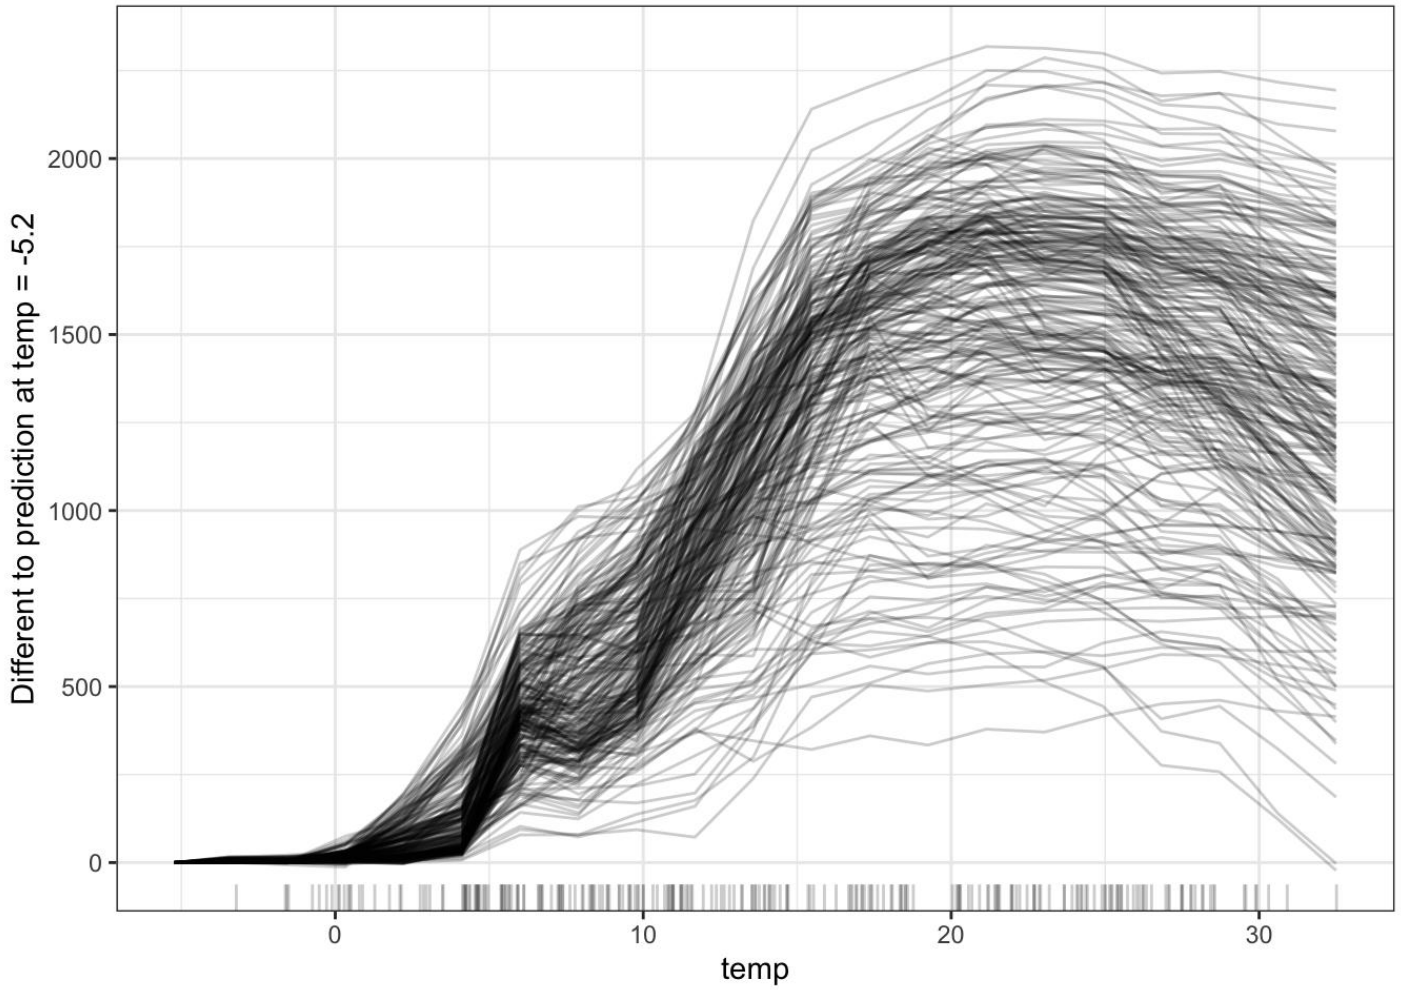

**Her çizgi bir penguen**

Gaga uzunluğu değişir.

Diğer özellikler sabittir.

Keskin değişimler ve üst üste gelen çizgiler okumayı zorlaştırabilir.

# Merkezlenmiş ICE: c-ICE




## Ortak referans

En düşük gözlenen sıcaklık.

Her eğriden, bu sıcaklıktaki kendi tahmini çıkarılır.

Bütün eğriler referansta sıfır olur.

Dikey eksen: tahmin farkı.

# Türevsel ICE: d-ICE

## Özellik biraz değiştiğinde tahminin yönü ve değişme hızı

Pozitif türev: artış
Negatif türev: azalış
Sıfır türev: o noktada sıfır eğim

Aynı özellik değerinde türevler farklıysa, modelin tepkisi diğer özelliklere de bağlıdır.

Bu farklılaşma, modelde etkileşime işaret eder.

Türevlerin standart sapması farklılaşan aralıkları gösterir. Hesaplama uzun sürebilir.

# Güçlü yönler ve sınırlılıklar

## Güçlü yönler

Her çizginin tek gözleme ait olması anlaşılmasını kolaylaştırır.

Bireysel farklılıkları görünür kılar.

Renklendirme ve türevler modeldeki etkileşimleri incelemeye yardımcı olur.

## Sınırlılıklar

Standart gösterim tek özelliğe odaklanır.

İlişkili özellikler gerçekçi olmayan birleşimler oluşturabilir.

Çizgiler üst üste binebilir ve ortalamayı görmek zorlaşabilir.

Okunabilirlik için yarı saydamlık, örneklem ve PDP kullanılabilir. ICE tek başına nedensel sonuç vermez.

# CP ve ICE karşılaştırması

## Ceteris Paribus

Tek gözlemin eğrisi.

Bu gözlem için özellik değiştiğinde tahmin nasıl değişiyor?

Penguen örneğinde bir penguen.
Bisiklet örneğinde bir gün.

## ICE

Birden fazla gözlemin eğrileri.

Modelin tepkisi gözlemler arasında nasıl farklılaşıyor?

Her çizgi bir penguen veya bir gün.

**PDP: her özellik değerinde bireysel tahminlerin ortalaması**

# ICE için yazılım seçenekleri

## R paketleri

iml, ICEbox ve pdp

## Kitaptaki örnekler

iml ile üretiliyor. Benzer yaklaşım: condvis.

## Python

Kitabın belirttiği araç: PiML

# Kaynaklar

## Christoph Molnar

Interpretable Machine Learning

### 12. Ceteris Paribus Plots

https://christophm.github.io/interpretable-ml-book/ceteris-paribus.html

### 13. Individual Conditional Expectation (ICE)

https://christophm.github.io/interpretable-ml-book/ice.html