Bölüm

32

Yorumlanabilirlik Yöntemlerinin Değerlendirilmesi

Açıklamayı kim denetler?

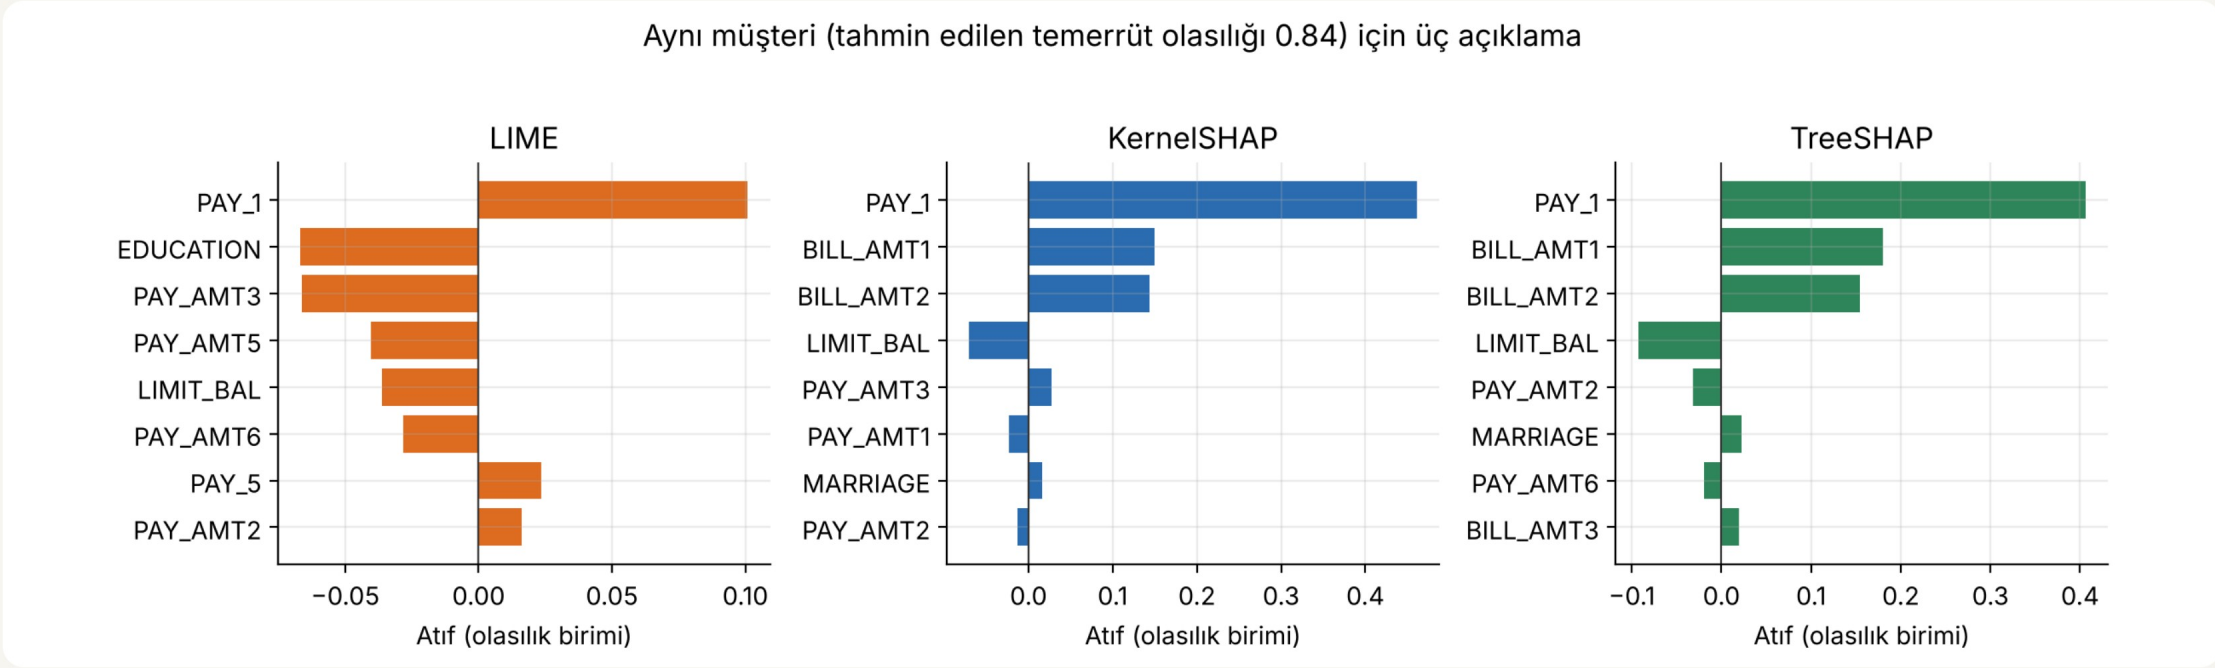
Alt başlıklar ve sunumun akışı

1. Bölüm 32'nin anlatımı, kitabın örnekleriyle
   - Değerlendirme düzeyleri
   - Açıklamaların özellikleri
2. Canlı kod: özellikleri Taiwan kredi verisinde ölçmek
3. Makale: Uyuşmazlık Problemi'nin yeniden üretimi

Berkay Çongar · 20269258007

Sivas Cumhuriyet Üniversitesi · Yapay Zeka ve Veri Bilimi · 2026 Güz

Aynı müşteri, üç açıklama



Üçü de en önemli etken olarak son ayın ödemesini (PAY_1) gösteriyor; sonrası ayrışıyor. LIME eğitim düzeyi diyor, SHAP fatura tutarı. **Hangisi doğru?**

Taiwan kredi verisi · kara kutu: gradyan artırmalı ağaçlar (GBM, test AUC 0,779)

Neden zor?

Tahminin cevabı var, açıklamanın yok

Tahmini değerlendirmek

Model “temerrüt olasılığı 0,96” der. Müşterinin gerçekten temerrüde düşüp düşmediği **bilinir**.

Doğruluk, AUC, karşılaştırma ölçütleri (*benchmark*): hepsi bu etikete dayanır.

Açıklamayı değerlendirmek

Açıklama “en önemli neden son ayın ödemesi” der. Doğru açıklamanın ne olduğu **bilinmez**.

Temel gerçekliğe benzer bir şey ancak **simüle edilmiş veriyle** üretilebilir.

Bölüm 32’nin cevabı: Açıklamayı bir tanığın ifadesi gibi, özellikleri üzerinden değerlendir.

Olanı doğru mu anlatıyor? Tekrar sorulunca aynısını mı söylüyor? Ne kadar emin?

Değerlendirme düzeyleri · Doshi-Velez ve Kim (2017)

Açıklamayı kim, nasıl sınar?

En gerçekçi, en pahalı → En ucuz, tekrarlanabilir

1 · Gerçek görev

Uygulama düzeyi

Alan uzmanı, gerçek iş

Kitabın örneği: Röntgende kırıkları işaretleyen yazılımı radyologlar kendi işlerinde dener.

İyi bir deney tasarımı gerekir. Referans: Bir insan aynı kararı ne kadar iyi açıklardı?

2 · Basit görev

İnsan düzeyi

Uzman olmayan katılımcılar

Kitabın örneği: Katılımcılara birkaç açıklama gösterilir; en iyisini seçerler.

Uzman gerekmediği için daha ucuz; katılımcı bulmak daha kolay.

3 · Vekil görev

İşlev düzeyi

İnsan yok, vekil ölçüt var

Kitabın örneği: Kullanıcılar karar ağaçlarını anlıyorsa ağacın derinliği vekil ölçüttür: sığ ağaç daha iyi.

Koşul: Model türü önceden insanlarla sınanmış olmalı. Kısıt: Ağaç sığlaşırken doğruluk fazla düşmemeli.

Bölümün geri kalanı ve bu sunumdaki bütün ölçümler işlev düzeyinde.

Açıklama nedir?

Açıklama, bir örneğin öznitelik değerlerini modelin tahminine insanın anlayacağı dille bağlar.

Kitabın örneği: Görev, kanser riskini tahmin etmek. Açıklamaya üç farklı yoldan varılabilir.



Bölüm buradan sonra iki liste veriyor: yöntemin 4 ve tekil açıklamanın 9 özelliği. Hepsinin nasıl ölçüleceği ise açık değil.

Açıklama yöntemlerinin özellikleri

Yöntemin dört özelliği

İfade gücü

Açıklamanın dili

Kitapta: EĞER-İSE kuralı, karar ağacı, ağırlıklı toplam, doğal dil

Yarı saydamlık

Modelin içine ne kadar bakıyor?

Kitapta: Doğrusal regresyona özgü yöntemde yüksek; yalnızca girdiyle oynayan yöntemde sıfır

Taşınabilirlik

Kaç tür modelde çalışıyor?

Kitapta: Vekil modeller en taşınabilir; yalnızca RNN'lerde çalışan yöntem en az

Algoritmik karmaşıklık

Bir açıklama ne kadar sürüyor?

Kitapta: Hesaplama süresi darboğaz olduğunda belirleyici

Bizde: TreeSHAP ≈1 ms · LIME ≈16 ms · KernelSHAP ≈66 ms

Kitabın ödünleşimi

Modelin içine bakar

Kazanç: daha çok bilgi kullanır. Bedel: tek model türü.

ör. regresyon ağırlıkları, TreeSHAP

↓ Yarı saydamlık azaldıkça taşınabilirlik artar

Yalnızca girdiyle oynar

Kazanç: her modelde çalışır. Bedel: içerideki bilgiyi kullanamaz.

ör. LIME, KernelSHAP, vekil modeller

Tekil açıklamaların özellikleri

Dokuz özellik, beş soru

Doğru mu anlatıyor?

Doğruluk
Gerçek sonucu tahmin ediyor mu?

Sadakat
Modeli taklit ediyor mu?

Sağlam mı?

Tutarlılık
Farklı modellerde benzer mi?

Kararlılık
Benzer örneklerde benzer mi?

Anlaşılır mı?

Anlaşılabilirlik
İnsan anlıyor mu?

Önem derecesi
En önemlisi belli mi?

Ne kadar emin?

Belirlilik
Modelin güvenini gösteriyor mu?

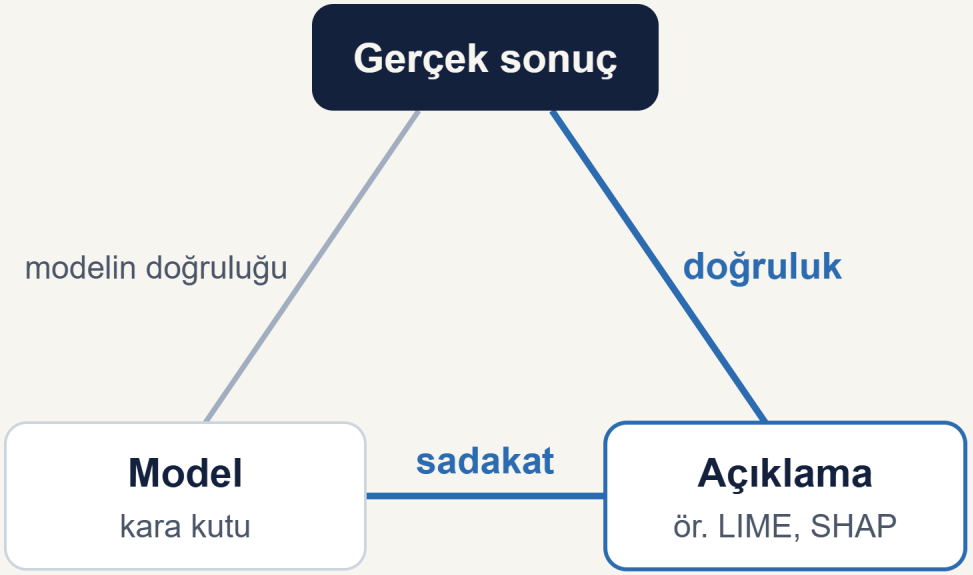
Yenilik
Örnek alışılmadık mı?

Neyi kapsıyor?

Temsil edicilik
Kaç örneği anlatıyor?

Sonraki dört slayt her soruyu kitabın örnekleriyle açıyor.

Doğru mu anlatıyor?



Kitaptaki ilişki: Model doğruysa ve açıklama modele sadıksa, açıklama da doğrudur.

Doğruluk

Açıklama, gerçek sonucu ne kadar iyi tahmin ediyor?

Ne zaman şart? Açıklama modelin yerine karar verecekse.

Ne zaman önemsiz? Model zaten zayıfsa ve amaç onu anlamaksa; o zaman yalnızca sadakat önemli.

Sadakat

Açıklama, kara kutunun tahminini ne kadar iyi taklit ediyor?

En önemli özelliklerden biri: Modele sadık olmayan açıklama modeli anlatamaz.

Yerel sadakat: LIME yalnızca bir bölgede, Shapley değerleri yalnızca tek bir örnekte sadıktır.

Sağlam mı?

Tutarlılık

Aynı örnek, farklı modeller

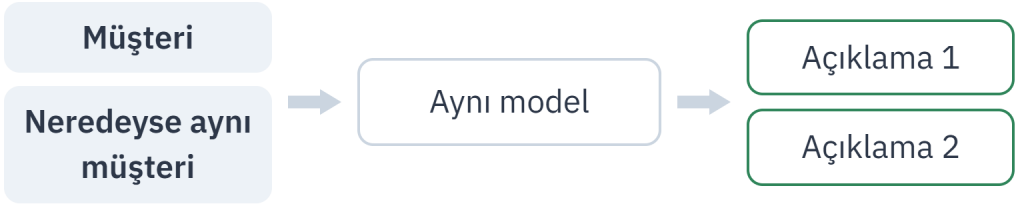


Kitabın örneği: Aynı görevde bir SVM ve bir doğrusal regresyon neredeyse aynı tahmini veriyor. Açıklamaları da benziyor mu?

Rashomon etkisi: İki model aynı tahmine farklı özniteliklerle varabilir; o zaman açıklamaların farklı olması doğrudur. Tutarlılık, modeller benzer ilişkilere dayanıyorsa istenir.

Kararlılık

Aynı model, birbirine çok benzeyen örnekler



Beklenti: Küçük bir fark açıklamayı değiştirmemeli; tabii tahmin de pek değişmiyorsa.

Kararsızlığın iki kaynağı: yöntemin aşırı oynak olması ve rastgele adımlar. Örneğin LIME her seferinde yeni rastgele örnekler üretir. Kitaba göre yüksek kararlılık her zaman istenir.

Anlaşılır mı?

Anlaşılabilirlik

İnsan anlıyor mu? Kitabın deyişiyle “odadaki fil”.

Tanımlaması ve ölçmesi en zor, ama doğru yapılması en önemli özellik. Kime anlattığınıza göre de değişir.

Ölçü 1 · Boyut

Kaç öznitelik ya da kaç kural var? Küçük açıklama daha kolay anlaşılır.

Ölçü 2 · İnsan testi

Açıklamaya bakan kişi, modelin ne diyeceğini tahmin edebiliyor mu?

Öznitelikler de anlaşılır olmalı: “Yaş” herkesin anladığı bir öznitelik; birkaç özniteliğin karmaşık bir dönüşümü öyle değil.

Önem derecesi

En önemli parça belli mi?

EĞER son ödeme ≥ 2 ay gecikmiş
VE 3 ay önce borç tam ödenmemiş
VE 5 ay önce ödeme ≥ 2 ay gecikmiş
İSE tahmini temerrüt olasılığı 0,76

Kitabın sorusu: Bu üç koşuldan hangisi belirleyiciydi? Kural bunu kendisi söylemiyor.

Canlı kodda anlaşılabilirliği açıklamanın boyutu ile sadakati arasındaki ödünleşimle, önem derecesini en önemli üç özniteliğin payıyla ölçüyoruz.

Ne kadar emin, neyi kapsıyor?

Belirlilik

İki hastaya da %4 kanser riski. Model ikisinden de aynı derecede emin mi?

Hasta A · %4 · model emin

Hasta B · %4 · model emin değil

Çubuk: tahminin oynayabileceği aralık

İyi bir açıklama modelin güvenini de gösterir. Açıklamanın kendisi de bir tahmindir; onun da belirsizliği vardır.

Yenilik

Açıklanan örnek alışılmadık bir yerden mi geliyor?



eğitim verisi

yeni örnek

Eğitim verisinden uzak bir örnekte model de açıklama da yanılabilir. Yenilik arttıkça belirlilik düşer.

Temsil edicilik

Açıklama kaç örneği kapsıyor?

Doğrusal regresyon ağırlıkları

bütün modeli, herkesi anlatır

Shapley değerleri

yalnızca tek bir tahmini anlatır

Canlı kodda belirliliği bootstrap ile, yeniliği Isolation Forest ile ölçüyoruz.

Matematiksel mantık

Özellikleri sayıya çevirmek

Sadakat · R^2

$$R^2 = 1 - \Sigma(f - g)^2 / \Sigma(f - \mu)^2$$

Açıklama (g), kara kutunun (f) tahminlerindeki değişimin ne kadarını yakalıyor? μ: ortalama tahmin.

Bizde: vekil ağaç 0,85 · LIME'ın yerel modeli 0,39

Kararlılık · Jaccard

$$J(A, B) = |A \cap B| / |A \cup B|$$

A, B: iki açıklamanın en önemli 5 özniteliği. 4 ortak, toplam 6 öznitelik varsa J = 4/6 ≈ 0,67.

Bizde: tohum değişince LIME 0,84 · SHAP 1,00

Tutarlılık · Spearman ρ

$$\rho = 1 - 6\Sigma d^2 / (n(n^2 - 1))$$

d: bir özniteliğin iki açıklamadaki sıra farkı, n: öznitelik sayısı. Sıralar aynıysa ρ = 1.

Bizde: benzer dört modelin açıklamaları arasında 0,50–0,74

Belirlilik · bootstrap

$$\rho(\, ss[f], ss[\phi] \,)$$

15 bootstrap modeli; ss: modeller arası standart sapma. Tahmin oynadıkça açıklama da oynuyor mu?

Bizde: ρ = 0,87; belirsiz tahminin açıklaması da belirsiz

Kitap ölçme yolunu açık bırakıyor; canlı kodda dördünü de Taiwan verisinde hesaplıyoruz.

Kısım 2 · Canlı kod · uygulama.ipynb

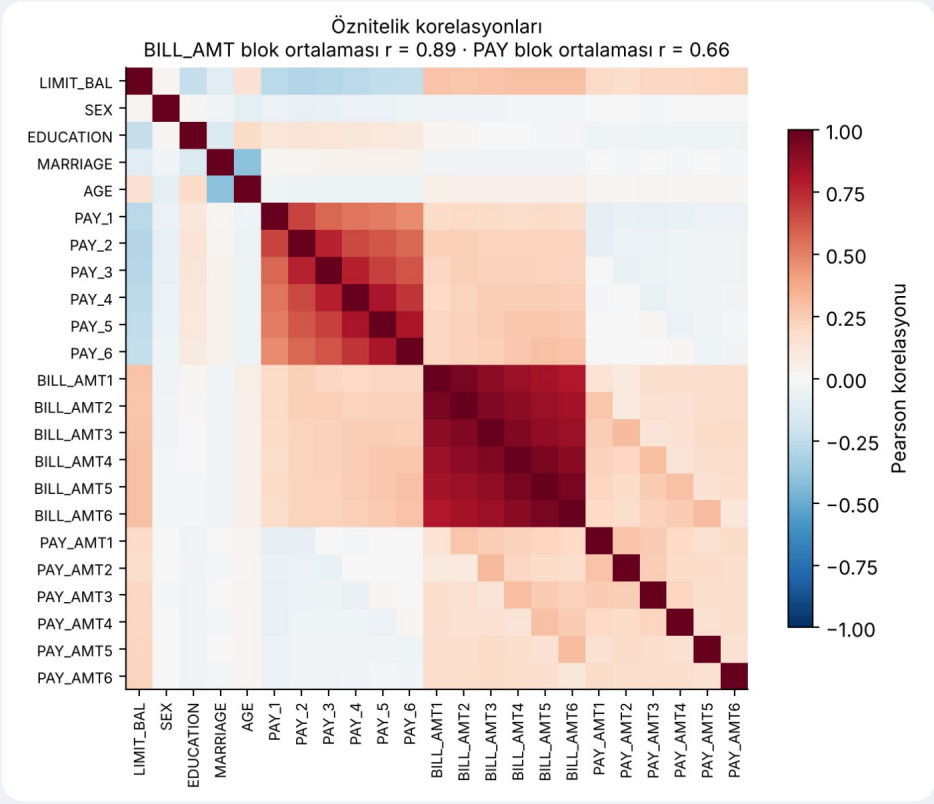
Veri: neden zorlu?

30.000
kredi kartı müşterisi

23
öznitelik

%22
temerrüt: dengesiz sınıflar

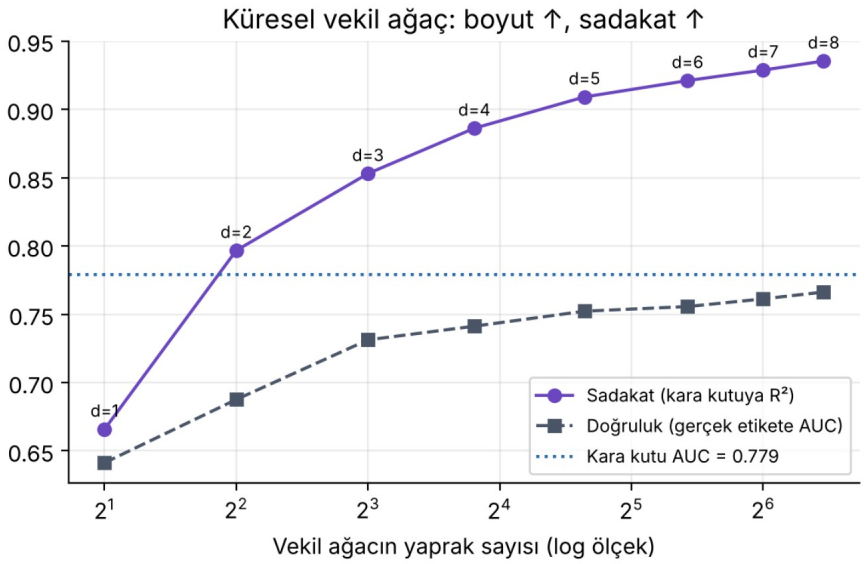
r = 0,89
fatura tutarları arasında: çoklu bağlantı

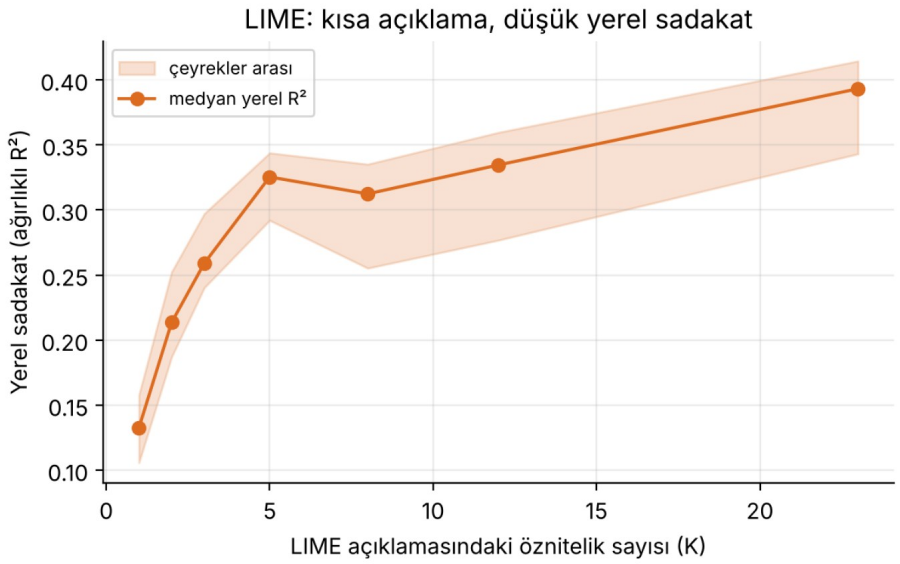


Yeh ve Lien (2009) · UCI, CC BY 4.0 · dosya UCI'nin yayımladığı istatistiklerle doğrulandı

Doğruluk · sadakat · anlaşılabilirlik

Sadakat mi, anlaşılabilirlik mi?





8 yapraklı vekil ağaç kara kutuyu R^2 0,85 ile taklit ediyor: Model büyük ölçüde PAY_1'e dayanıyor.

LIME 23 özniteliğin hepsiyle bile yerel R^2 0,39'da kalıyor.

Sadakat: kara kutuya R^2 · doğruluk: gerçek etikete AUC · SHAP yöntemleri tanım gereği toplamsal (hata ≈ 0)

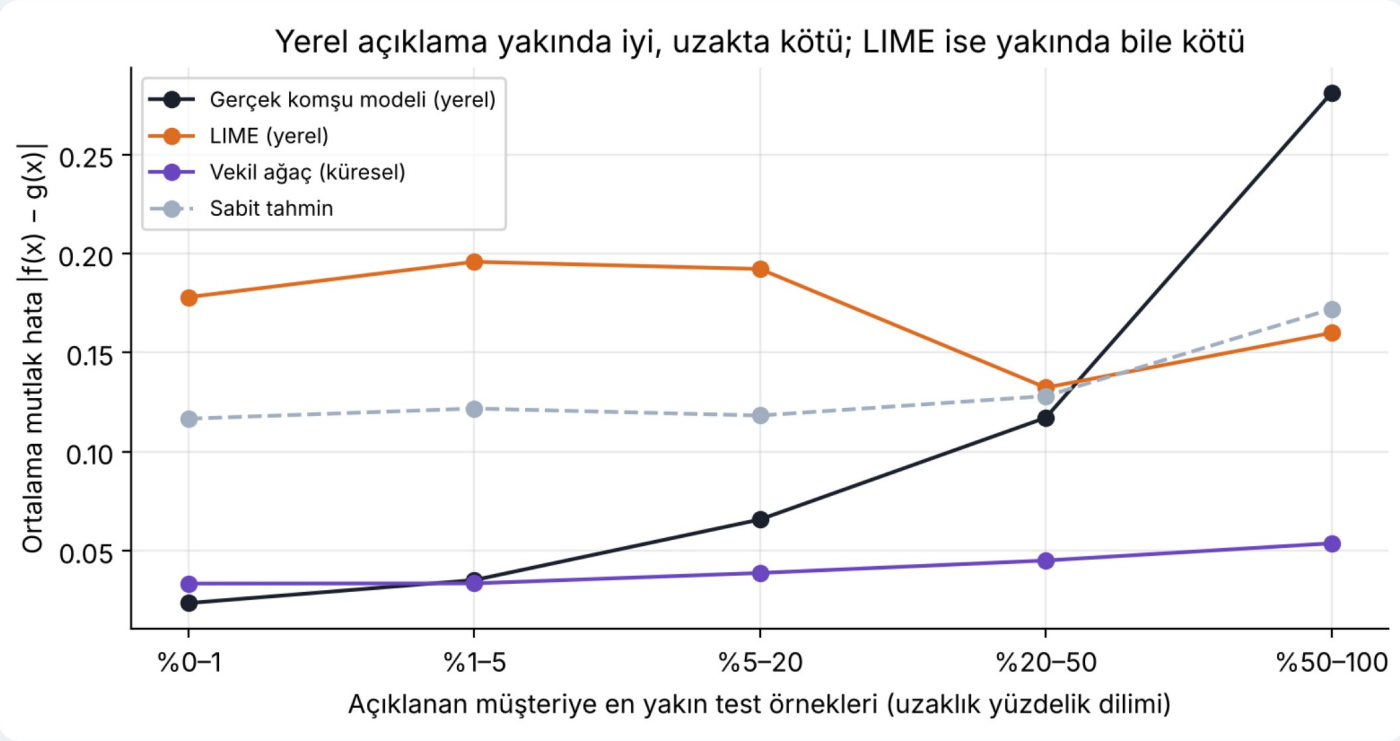
Temsil edicilik · bir zafiyet

LIME bu veride “yerel” değil

0,17

LIME’ın yerel modeli, açıklanan müşterinin **kendisinde** bile kara kutudan bu kadar sapıyor (medyan, olasılık birimi).

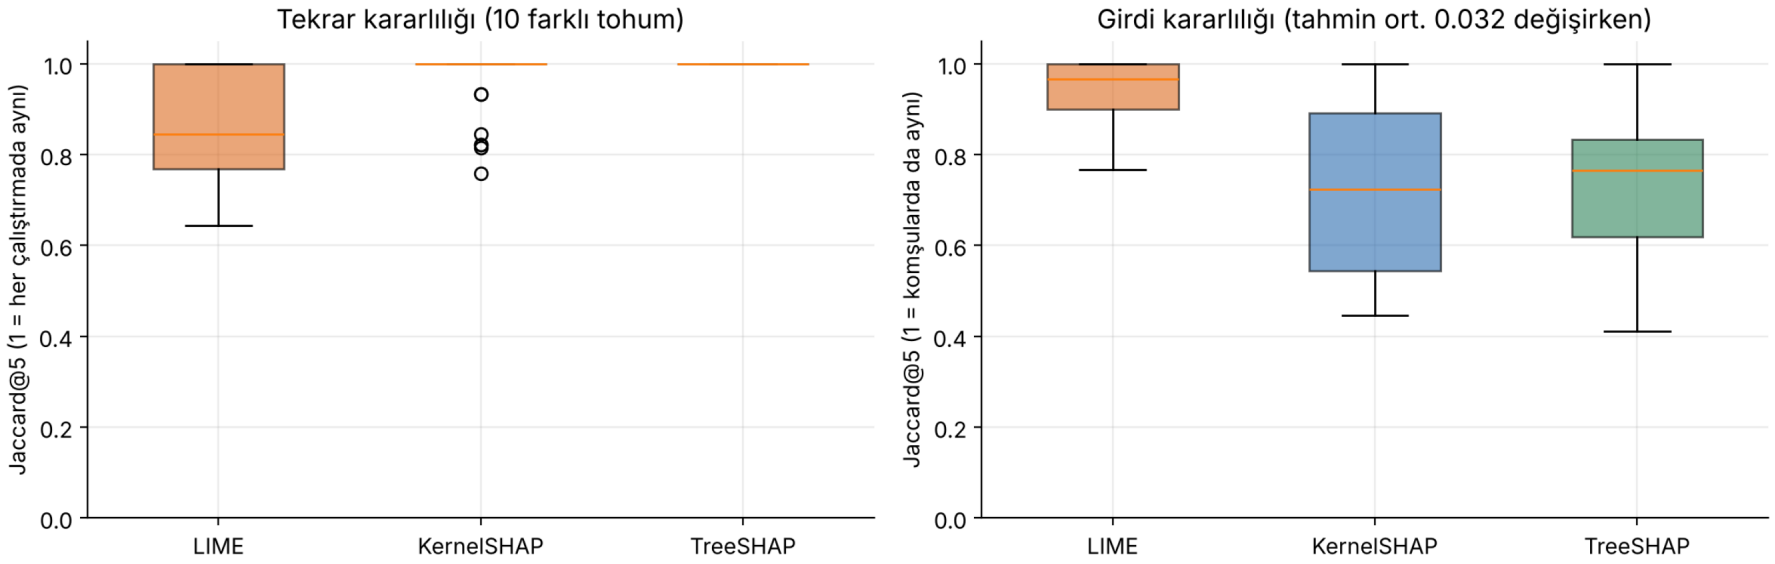
Neden? 23 boyutta LIME’ın örnekleri müşteriden ortalama $\sqrt{23} \approx 4{,}8$ standart sapma uzağa düşüyor; çekirdek bunları neredeyse eşit ağırlıklandırıyor.



Gerçek komşu modeli: müşteriye en yakın %1’lik gerçek müşterilerle kurulmuş doğrusal model (başvuru çizgisi)

Kararlılık

İki tür kararlılık, iki farklı kazanan



Tohum değişince: SHAP yöntemleri 1,00; LIME 0,84. Rastgelelik kararsızlık üretir.

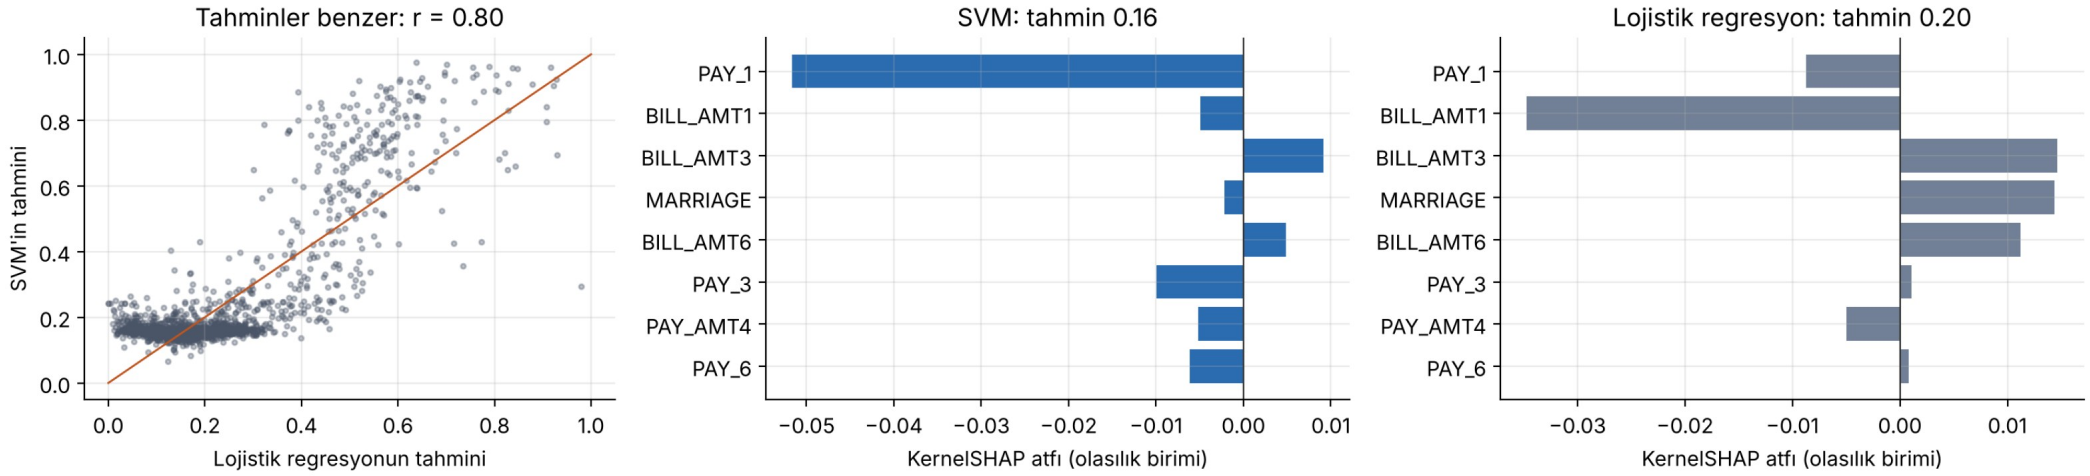
Girdi azıcık değişince: LIME 0,97; SHAP 0,72–0,76. LIME'ın kararlılığı, geniş bölgeyi ortalamasından geliyor.

Jaccard@5: iki açıklamanın ilk 5 özniteliğinin örtüşmesi · komşu: her öznitelikte 0,05 standart sapmalık gürültü

Tutarlılık · kitabın örneği birebir

Aynı görev, iki model: SVM ve lojistik regresyon

Kitabın tutarlılık örneği: aynı müşteri, iki model (bu müşteride açıklamalar arası ρ = 0.17)



Tahminler arası korelasyon

r = 0,80

Açıklamalar arası sıra korelasyonu (medyan)

ρ = 0,34

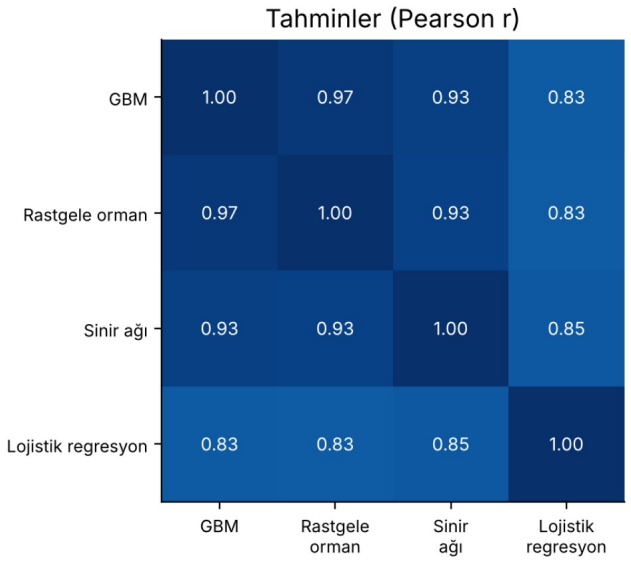
İlk 5'te ortaklık (Jaccard@5 medyanı)

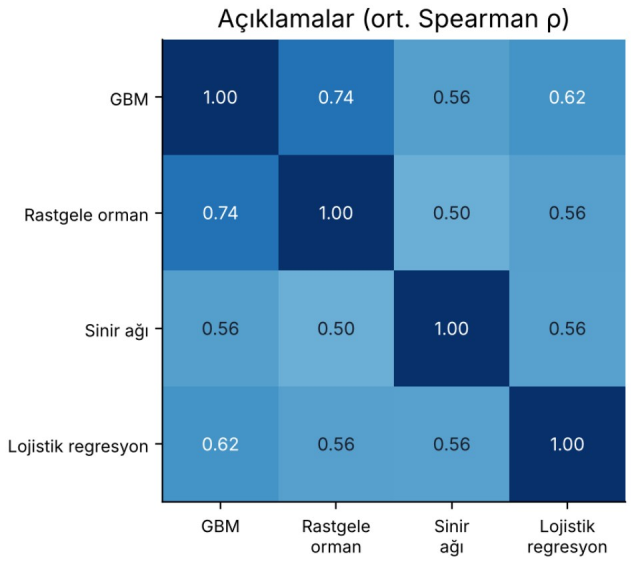
0,43

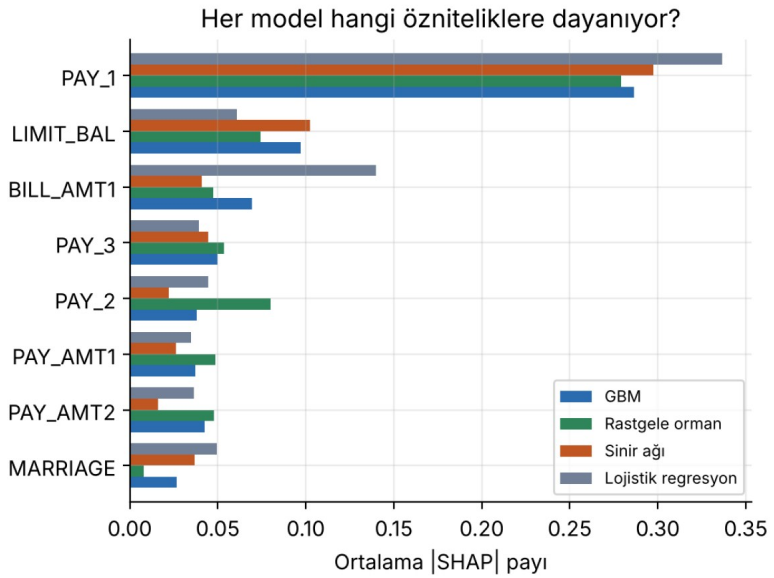
Kitapta SVM ve doğrusal regresyon · bizde SVM ve lojistik regresyon, ikisi de KernelSHAP ile (aynı arka plan) · 40 müşteri · test AUC: SVM 0,725 · LR 0,715

Tutarlılık

Benzer tahmin, farklı açıklama: Rashomon







Tahminler arası korelasyon

0,83–0,97

Açıklamalar arası sıra korelasyonu

0,50–0,74

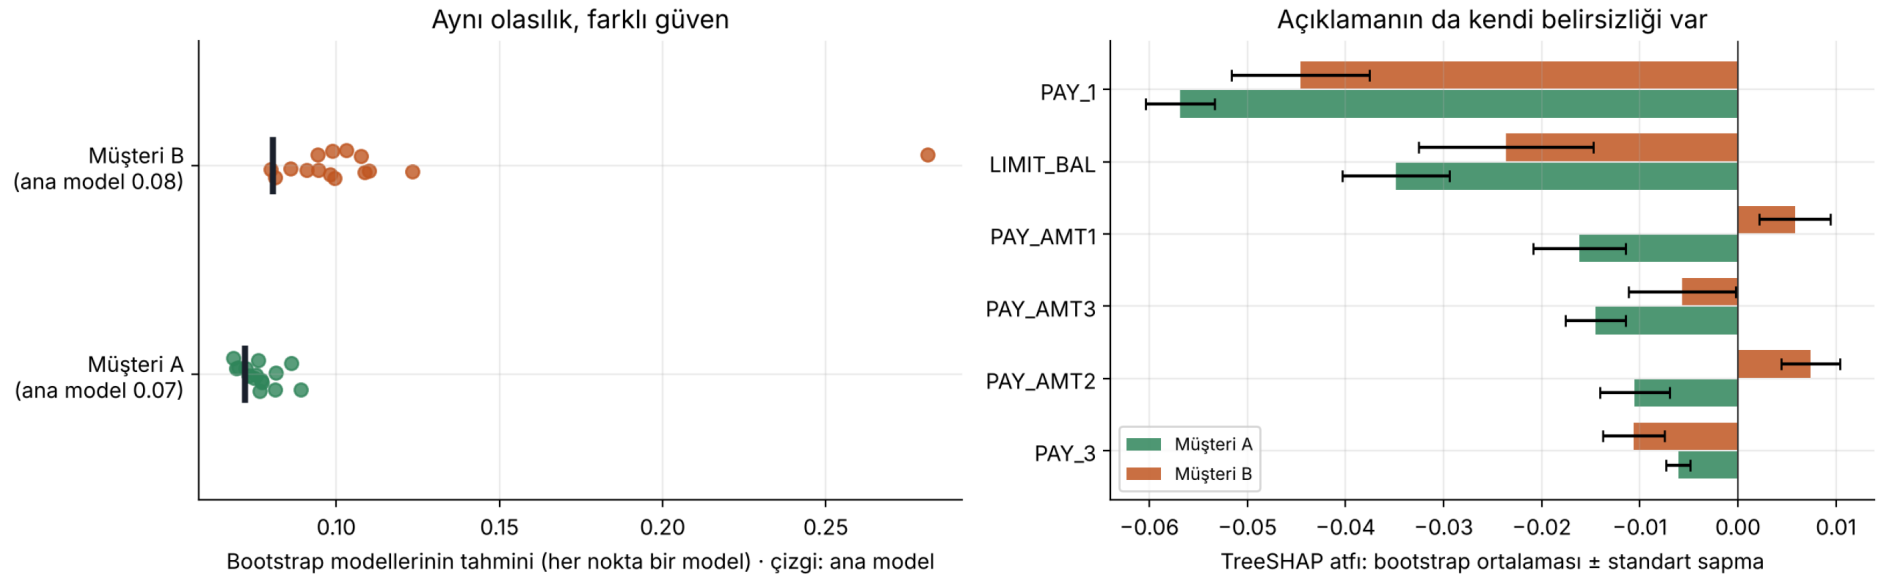
Aynı bilgi, farklı öznitelik

RF → PAY_2 · LR → BILL_AMT1

Dört model aynı yöntemle (KernelSHAP, aynı arka plan) açıklandı · test AUC: GBM 0,779 · RF 0,777 · NN 0,770 · LR 0,715

Belirlilik · kitabın örneği birebir

Aynı olasılık, farklı güven



Ana modelin tahmini

A %7,2 · B %8,1

Bootstrap tahminlerinin yayılımı

A 0,6 · B 4,7 puan

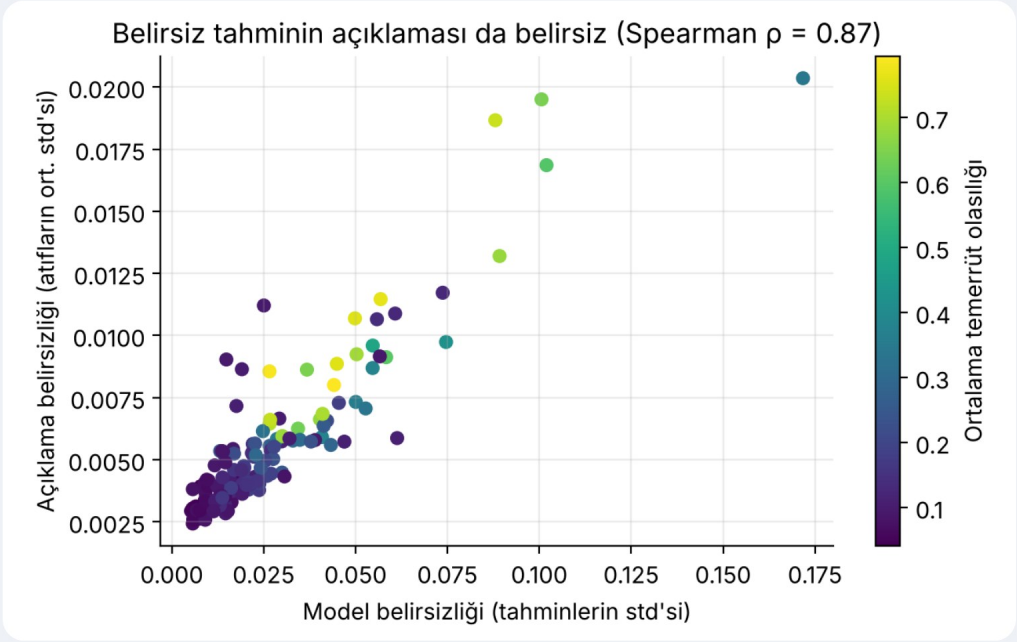
Aynı sayının arkasındaki güven farkı

≈ 8 kat

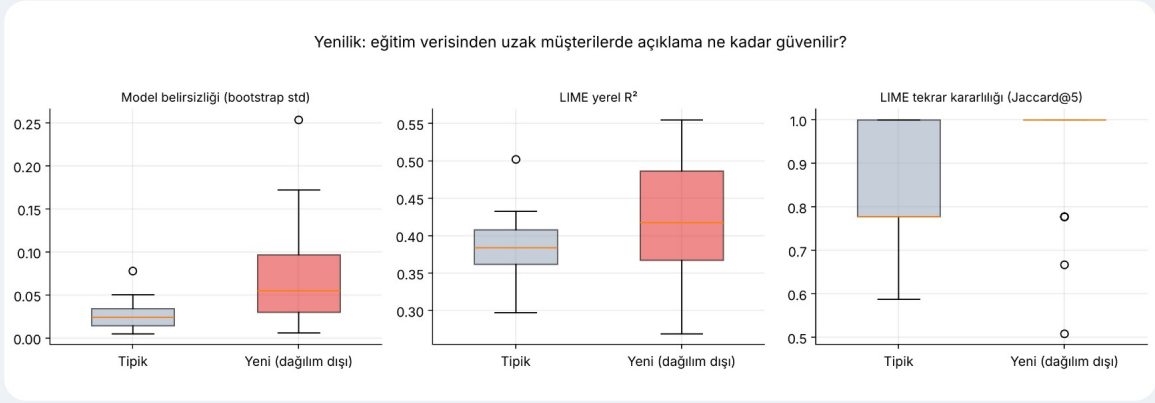
Kitapta iki hastaya %4 kanser olasılığı · bizde GBM'in neredeyse aynı olasılığı verdiği iki müşteri · 15 bootstrap GBM · yayılım: standart sapma

Belirlilik · yenilik

Açıklama, belirsizliğini söylemiyor



ρ = 0,87: Belirsiz tahminin açıklaması da belirsiz, ama tek bir SHAP grafiği bunu göstermez.



Yeni (dağılım dışı) müşteride modelin belirsizliği 0,024'ten 0,055'e çıkıyor, ama LIME'ın R²'si düşmüyor (0,38 → 0,42).

Açıklama, örneğin "yeni" olduğunu kendiliğinden bildirmiyor; yeniliği ayrıca ölçmek gerekiyor.

Belirsizlik: 15 bootstrap GBM · yenilik: Isolation Forest skoru en yüksek 40 müşteri ile tipik 40 müşteri

Uygulamanın özeti

Karne: tek bir “en iyi” yöntem yok

Yöntem	Süre (ms)	Sadakat	Tekrar	Girdi	Kapsam
LIME	16	yerel R^2 0,39	0,84	0,97	yerel · her model
KernelSHAP	66	toplamsal (tam)	1,00	0,72	yerel · her model
TreeSHAP	1,3	toplamsal (tam)	1,00	0,76	yerel · ağaçlar
Vekil ağaç	—	küresel R^2 0,85	1,00	—	küresel · her model

Bölüm 32’nin pratik çıktısı: Önce kullanım amacına göre hangi özelliğin önemli olduğuna karar ver, sonra yöntemi seç.

Tekrar ve girdi kararlılığı: medyan Jaccard@5 · vekil ağaç: derinlik 3, 8 yaprak, bir kez eğitilir

Uyuşmazlık Problemi

Krishna, Han, Gu, Pombra, Jabbari, Wu ve Lakkaraju (2022). *The Disagreement Problem in Explainable Machine Learning: A Practitioner's Perspective.*

21 / 25

Görüşülen veri bilimcilerin 21'i, açıklama yöntemlerinin birbiriyle çeliştiği durumlarla karşılaşmış.

Peki çeliştiklerinde hangisi haklı?

6 açıklama yöntemi · 6 uyum metriği · 4 model · makalenin verisi COMPAS + kendi verimiz Taiwan + simülasyon

Makalenin ölçüm aracı

İki açıklama ne kadar aynı?

Aynı müşteri, iki yöntemin ilk 5 özniteliği:

Sıra	Yöntem A	Yöntem B
1	PAY_1 (+)	PAY_1 (+)
2	LIMIT_BAL (–)	BILL_AMT1 (–)
3	BILL_AMT1 (+)	LIMIT_BAL (–)
4	PAY_2 (+)	PAY_AMT1 (–)
5	AGE (+)	PAY_2 (+)

FA 0,8 Aynı öznitelikler mi? (4 ortak / 5)

RA 0,2 Aynı sırada mı? (yalnızca 1. sıra)

SA 0,6 Ortak olanların yönü aynı mı? (BILL_AMT1 ters)

SRA 0,2 Sıra ve yön birlikte

RC, PRA Tüm özniteliklerde sıra benzerliği (Spearman, çiftler)

> Dikkat: Rastgele iki açıklamanın FA'sı sıfır değil, **k/d**. COMPAS'ta FA@5 için bu 5/7 ≈ 0,71.

Yeniden üretim kurulumu

Önce makalenin kendi verisinde

	Makale	Bizim çalışma
Veri	COMPAS, 7 öznitelik	Aynı; ProPublica filtreleri
Örnek	4.937 kişi · 1.482 test	Aynı sayılar (6.172 × %80)
Etiket	COMPAS risk puanı	“High” = yüksek risk
Modeller	LR · GBT · RF · NN	Aynı mimariler
Yöntemler	LIME 3.000 · SHAP 128 · IG 1.500	Aynı ayarlar
Raporlanmamış	IG tabanı, SmoothGrad gürültüsü	Ortalama · aralığın %10’u

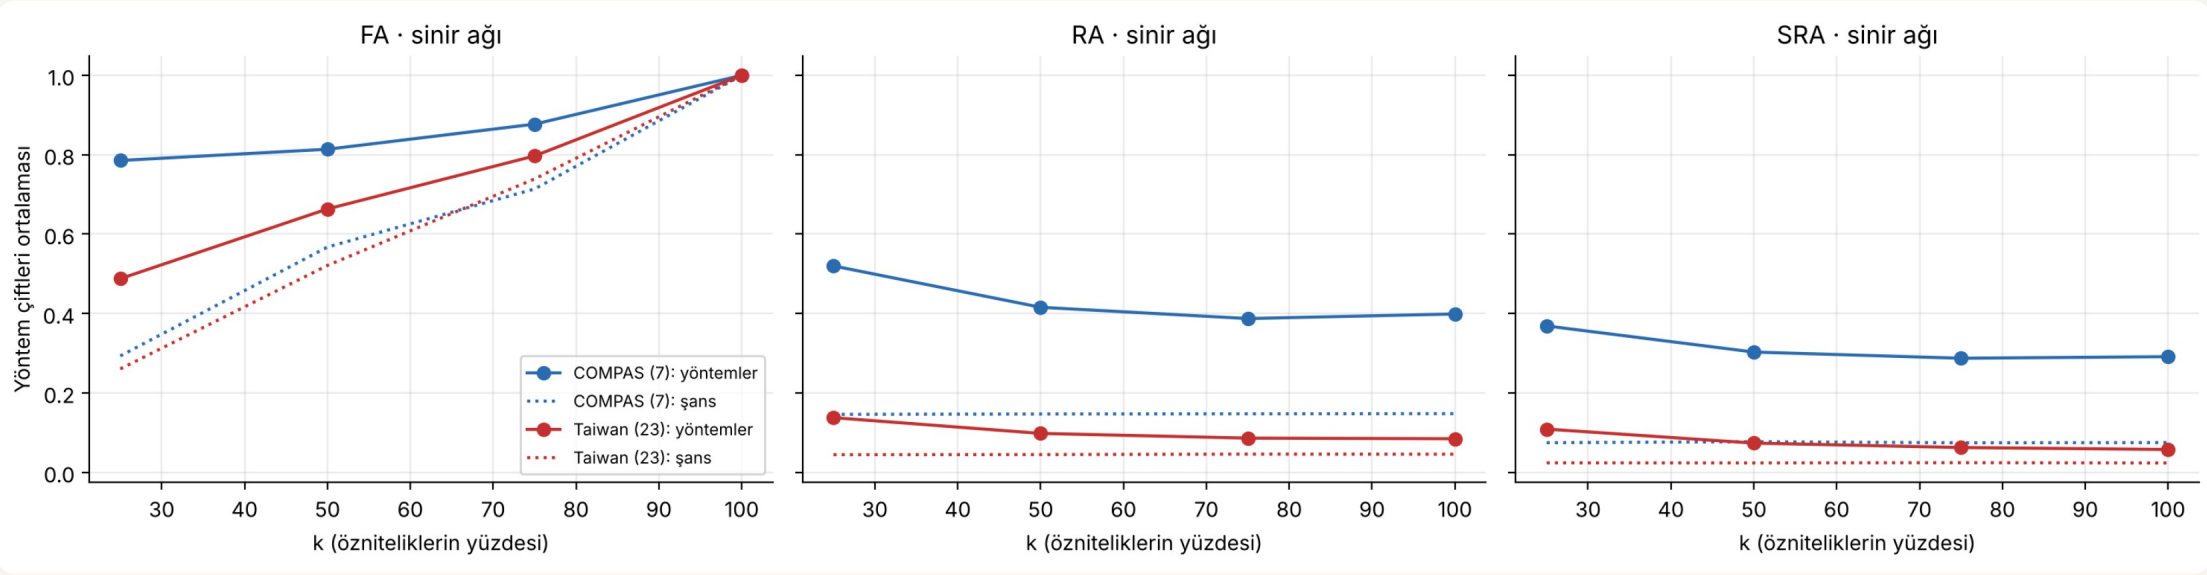
Test doğruluğu

Model	Makale	Biz
LR	0,84	0,842
GBT	0,83	0,846
RF	0,82	0,823
NN	0,84	0,844

Sinir ağının türevi elle hesaplandı; sonlu farklarla fark 10^{-11}.

Makalenin iddiaları yeniden üretildi

Uyuşmazlık gerçek, Taiwan'da daha büyük



COMPAS · sinir ağı · RA@5

0,387 (şans 0,145)

Taiwan · sinir ağı · RA@5

0,152 (şans 0,042)

COMPAS · sinir ağı · k = 1 → 7

RA 0,61 → 0,40

Düz çizgi: yöntem çiftlerinin ortalaması · noktalı: rastgele açıklamayla uyum (şans düzeyi)

Katkımız 1 · Birinci ilkelerden

Yöntemler iki farklı soru soruyor

Yöntem	Lojistik regresyonda	Aile
Grad	$p(1-p) \cdot w$	Eğim
SmoothGrad	$E[p(1-p)] \cdot w$	Eğim
LIME	$\approx c \cdot w$ (yerel eğim)	Eğim
Grad×Input	$p(1-p) \cdot w \cdot x$	Katkı
IG	$w \cdot x \cdot$ (ortak çarpan)	Katkı
KernelSHAP	$\approx w \cdot (x - E[x])$	Katkı

Fark tek bir çarpan: x

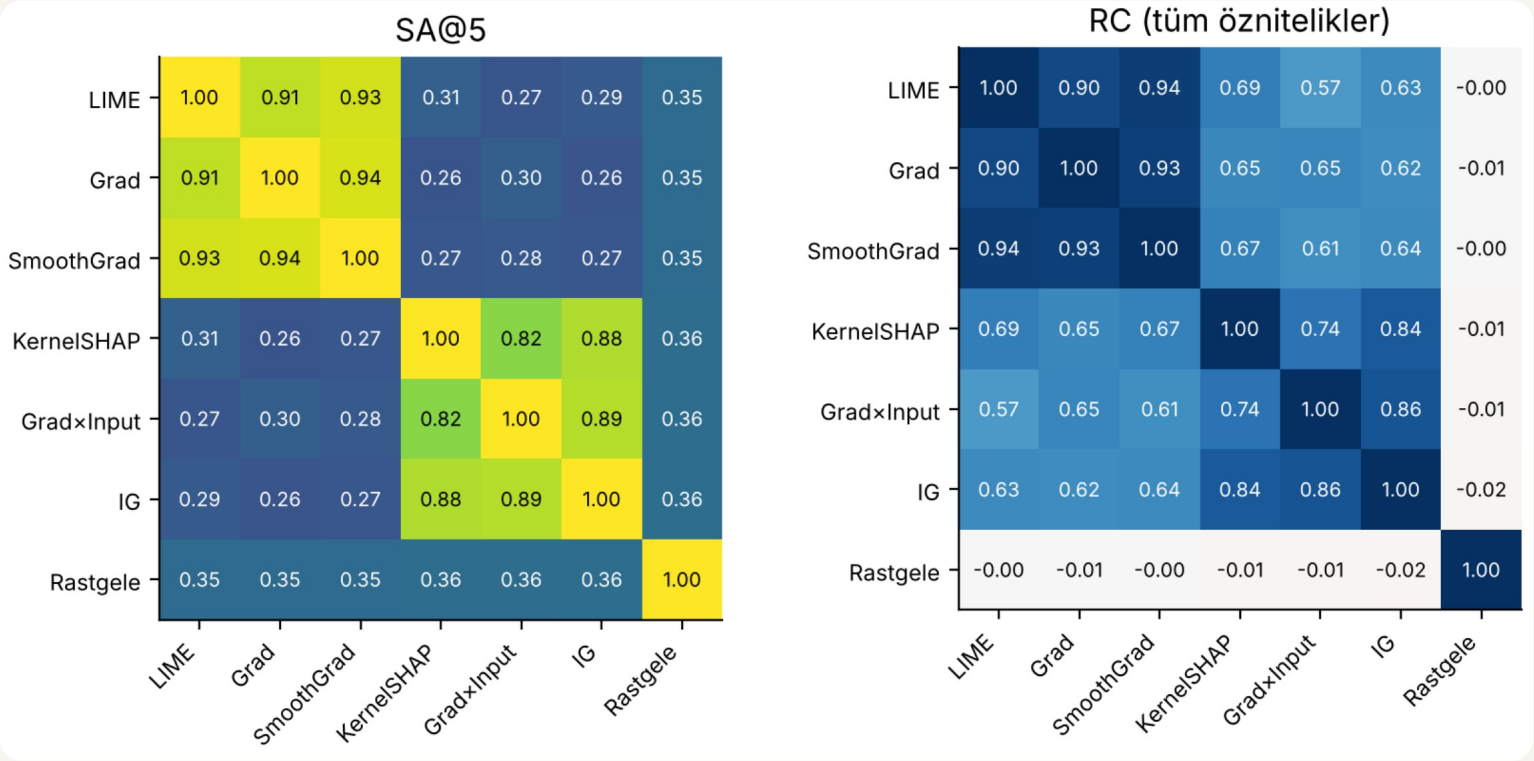
Eğim: “Bunu biraz değiştirirsem tahmin ne kadar değişir?”

Katkı: “Bu kişinin tahminine bu öznitelik ne kadar kattı?”

Öngörü: Aile içinde uyum tam (lojistik regresyonda $\rho = 1$), aileler arasında işaret uyumu yarı yarıya.

Öngörü veride tuttu

Uyum haritasında iki blok



Aile içi işaret uyumu

0,82–0,94

Aileler arası işaret uyumu

0,26–0,31

Şans düzeyi 0,35: şanstan bile düşük

Lojistik regresyonda aile içi ρ

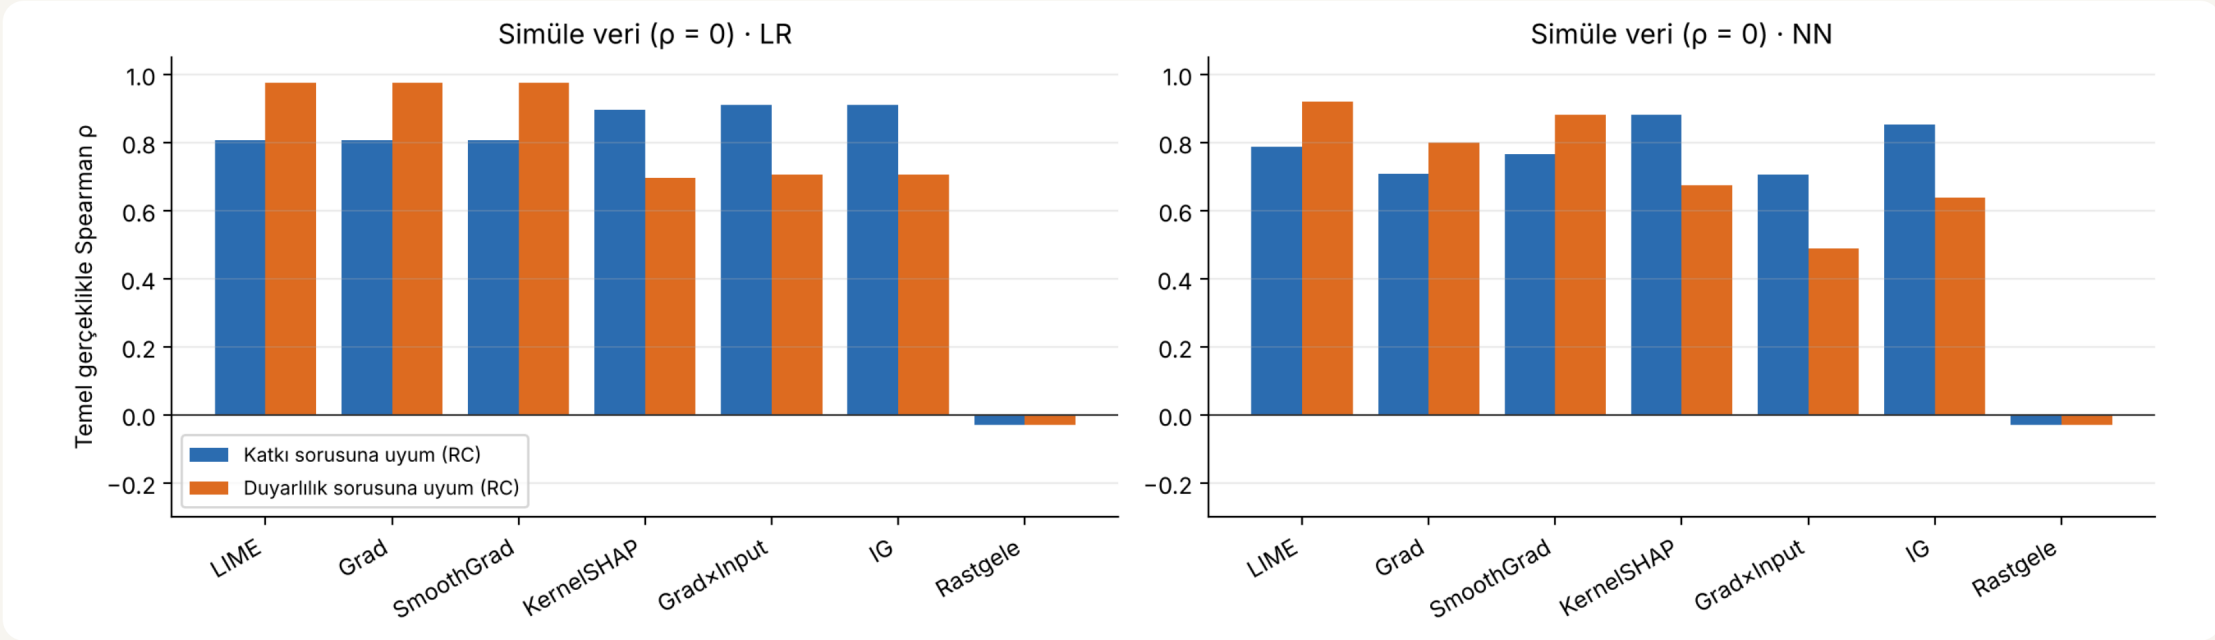
1,000

COMPAS'ta da Taiwan'da da

COMPAS · sinir ağı · k = 5 · yöntemler aileye göre sıralı: LIME, Grad, SmoothGrad | KernelSHAP, Grad×Input, IG

Katkımız 2 · Temel gerçekliği simülasyonla üretmek

Hangisi haklı? Soruya bağlı



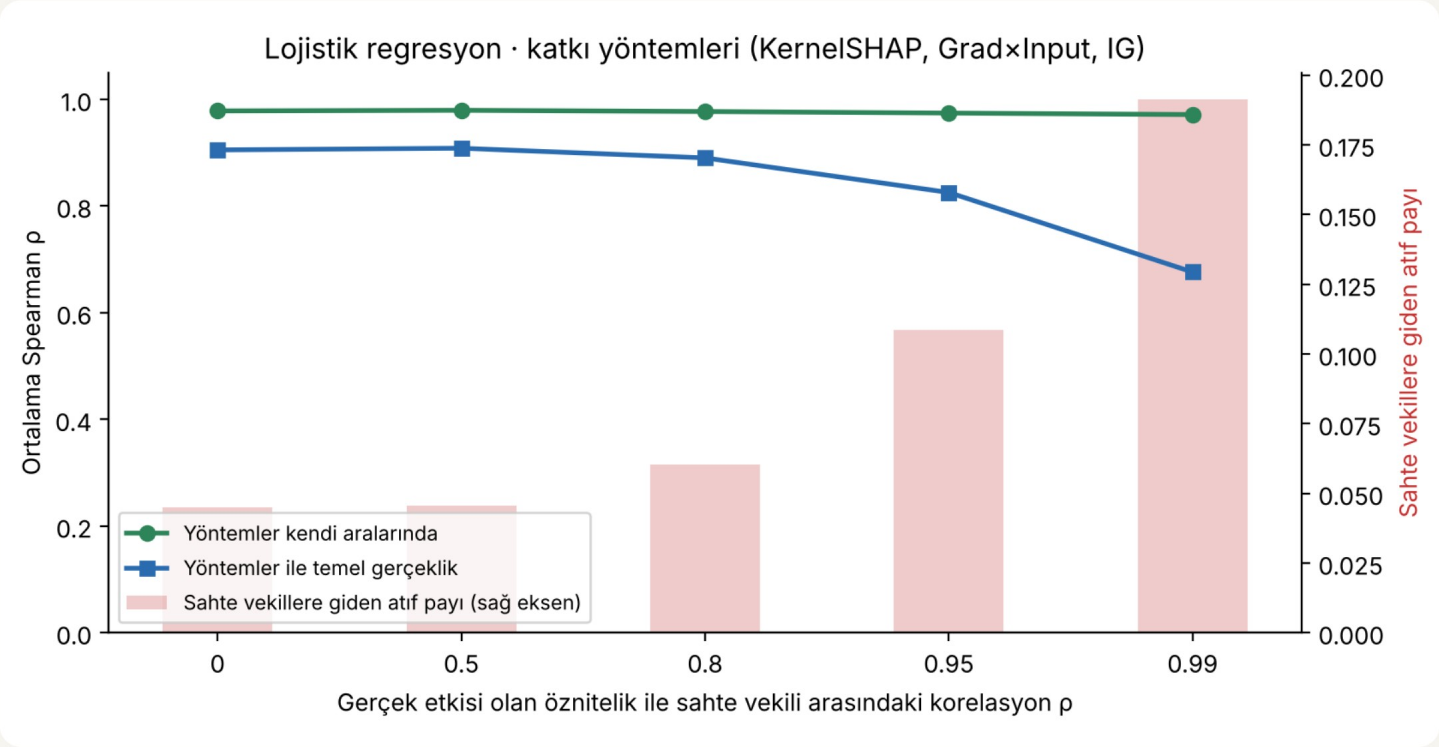
Eğim ailesi duyarlılık gerçeğine yakın: LR'de ρ = 0,976

Katkı ailesi katkı gerçeğine yakın: LR'de ρ = 0,90–0,91

Veri bilinen bir lojistik modelden üretildi: 8 öznitelik, β = (1,5; −1,2; 1,0; −0,8; 0,6; 0; 0; 0)

Katkımız 3 · Çoklu bağlantı altında

Uyum, doğruluk değildir



ρ = 0,99 olduğunda

0,97

yöntemlerin kendi aralarındaki uyum

0,68

yöntemlerin gerçekle uyumu (ρ = 0'da 0,91)

%19

gerçek etkisi sıfır olan özniteliklere giden atıf

Lojistik regresyon · KernelSHAP, Grad×Input, IG · her ρ için 3 tekrar · sahte vekil: etkisi sıfır, gerçek bir öznitelikle ρ kadar ilişkili

Savunma

İddialar ve sonuçlarımız

Makalenin iddiası	Bizim sonucumuz	Karar
Yöntemler sıkça anlaşmaz	Taiwan NN'de RA@5 = 0,152	Destekleniyor
k arttıkça RA, SRA düşer	COMPAS NN'de RA 0,61 → 0,40	Destekleniyor
Öznitelik ↑ → uyuşmazlık ↑	Şansa göre düzeltilmiş FA: COMPAS 0,57 → Taiwan 0,31	Şerhle destekleniyor
Karmaşık model daha uyumsuz	RC: LR 0,821 → NN 0,395 (Taiwan)	Destekleniyor
Bazı çiftler hep uyumlu	LR'de aile içi ρ = 1,000	Nedeni türetildi
(Makalede yok)	Uyum yüksek, gerçekle uyum düşük olabilir	Yeni bulgu

Sınırlılıklar: Ön işleme ve dört ayar makalede raporlanmamış; uygulayıcı çalışması (insan düzeyi) yeniden üretilmedi.

Tüm sayılar ve sapmalar: makale-yeniden-uretim/berkaycongar-20269258007/makale.md

Sonuç

Üç mesaj

1

Önce soruyu seç, sonra yöntemi

Eğim mi soruyorsun, katkı mı? Uyuşmazlığın bir kısmı hata değil, farklı soruların doğru cevapları.

2

Uyum, doğruluk değildir

Yöntemler aynı yanlış modeli sadakatle açıklayıp birbirleriyle tam uyuşabilir.

3

Vekil ölçütler gerekli ama yeterli değil

Hepsi işlev düzeyinde kaldı. Açıklamanın gerçekten işe yarayıp yaramadığını insan düzeyinde sınamak gerekir.

Kaynaklar

Molnar, C. (2025). *Interpretable Machine Learning* (3. baskı), Bölüm 32. christophm.github.io/interpretable-ml-book

Doshi-Velez, F. ve Kim, B. (2017). Towards a rigorous science of interpretable machine learning. arXiv:1702.08608.

Robnik-Šikonja, M. ve Bohanec, M. (2018). Perturbation-based explanations of prediction models. *Human and Machine Learning*, 159–175.

Krishna, S., Han, T., Gu, A., Pombra, J., Jabbari, S., Wu, S. ve Lakkaraju, H. (2022). The disagreement problem in explainable machine learning: A practitioner's perspective. arXiv:2202.01602.

Ribeiro, M. T., Singh, S. ve Guestrin, C. (2016). "Why should I trust you?" Explaining the predictions of any classifier. *KDD*.

Lundberg, S. M. ve Lee, S.-I. (2017). A unified approach to interpreting model predictions. *NeurIPS*.

Sundararajan, M., Taly, A. ve Yan, Q. (2017). Axiomatic attribution for deep networks. *ICML*.

Smilkov, D., Thorat, N., Kim, B., Viégas, F. ve Wattenberg, M. (2017). SmoothGrad: Removing noise by adding noise. arXiv:1706.03825.

Yeh, I.-C. ve Lien, C.-H. (2009). The comparisons of data mining techniques for the predictive accuracy of probability of default of credit card clients. *Expert Systems with Applications*, 36(2).

Angwin, J., Larson, J., Mattu, S. ve Kirchner, L. (2016). Machine bias. *ProPublica*. COMPAS verisi: github.com/propublica/compas-analysis